Entrepôt de données

Système d'Information d'Aide à la Décision

2017/2018

Objectifs

- Comprendre l'importance de l'information dans les métiers.
- Analyser les limites des systèmes de production existants pour les besoins en traitement de l'information, notamment dans les applications décisionnelles.
- Introduire le concept d'entrepôt de données comme une solution alternative et en décrire les propriétés.
- Distinguer les différents niveaux de stockage de données qui composent une architecture à base d'entrepôt
- Comprendre les étapes de la construction de ces niveaux de stockage.
- Comprendre les concepts du modèle de données multidimensionnel

Plan

1. **Systèmes d'information & Aide à la décision**
2. **Introduction aux entrepôts de données**
3. **Conception des entrepôts de données**
4. **ETL : Extraction, Transformation et Chargement de données**
5. **Outils d'analyse et de reporting**
6. **Mise en œuvre d'entrepôt de données**

Chapitre I

SYSTÈMES D'INFORMATION & AIDE À LA DÉCISION

Eléments de contenu

- SI opérant vs SI de pilotage
- Caractéristiques d'un SIAD
- Architecture d'un SIAD
- Systèmes transactionnels vs Systèmes décisionnels
  - BD Production / Entrepôt de données
  - OLTP / OLAP
  - BD relationnelles / BD multidimensionnelles

Conséquences de la productivité informationnelle

- **Nouvelles catégories de BD :**
  - Data Warehouse
  - Data mart
  - BD multi-dimensionnelle
- **Nouvelles catégories d'applications :**
  - OLAP
  - Analyse multi-dimensionnelle
  - Data Mining
- **Nouvelles catégories d'utilisateurs :**
  - Décideurs
  - Analystes
  - Commerciaux

Catégories de données

- ***Données opérationnelles :***
  - Données utilisées par le système opérant et correspondant aux activités standards de l'entreprise (commandes, factures, etc..)
  - Utilisées par les applications OLTP
- ***Données informationnelles :***
  - Données utilisées par le système de pilotage comme support d'aide à la décision
  - Résultat de transformations de données opérationnelles.
  - Utilisées par les applications OLAP
- ***Données non structurées :***
  - Données non alphanumériques (multimédia : audio, son, image)
  - Traitées généralement par l'applicatif.
  - Utilisées dans les applications éducatives, loisir, médecine, géographie, etc..

Types de SI

Le SI peut être décomposé en deux types :

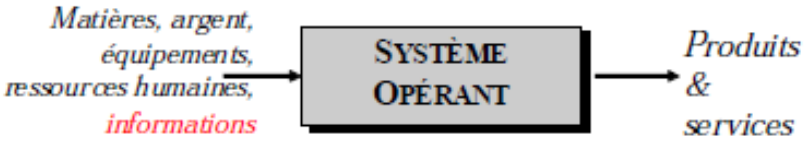
- SI **opérant**
- SI de **pilotage**



Système opérant

Système dans lequel s'effectuent les **transformations physiques** ou **intellectuelles** sur les flux qui traversent l'entreprise en vue de produire des **sorties valorisées**.

- **Flux en entrée** :
  - Matières
  - Argent
  - équipements
  - ressources humaines
  - informations
- **Sorties :**
  - Produits
  - Services



Système de pilotage

Système dans lequel les décisions sont prises concernant :

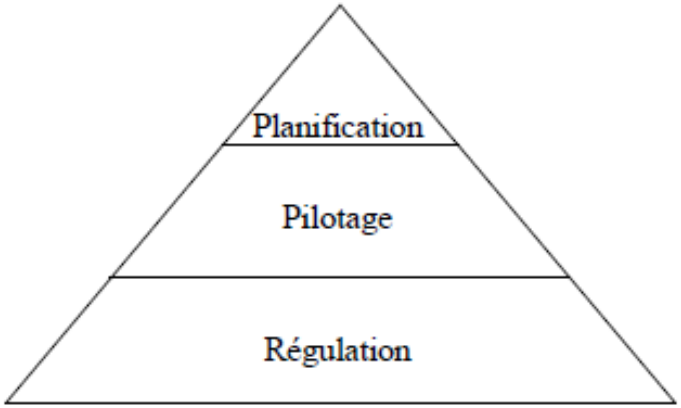
- les objectifs assignés au système opérant
- l'affectation des ressources au système opérant
- le contrôle des résultats obtenus
- la régulation



Types d'activités dans une entreprise

Les activités de gestion dans une entreprise sont de trois types :

- Planification stratégique (planification)
- Contrôle managérial (pilotage)
- Contrôle opérationnel (régulation)



Types d'activités dans une entreprise

- **Planification stratégique (planification)** : C'est le niveau le plus haut hiérarchiquement. Il consiste à :
  - définir les objectifs de l'entreprise,
  - définir les moyens et les scénarios pour parvenir aux objectifs, dans une vision à long terme (3 à 10 ans).
  - fournir au niveau inférieur un cadre d'objectifs à atteindre et une orientation pour les mettre en œuvre.

Types d'activités dans une entreprise

- **Contrôle managérial (pilotage)** : C'est le niveau hiérarchique moyen. Il met en œuvre les objectifs élaborés par le niveau supérieur. Il détermine les moyens d'atteindre les objectifs globaux :
  - en les décomposant en sous-objectifs,
  - en allouant les ressources nécessaires,
  - en mettant en place les moyens de contrôle et
  - en prenant les initiatives correction en cas de besoin.
- **Contrôle opérationnel (régulation)** : C'est le niveau hiérarchique le plus bas. Il agit sur les flux qui traversent l'organisation en se basant sur les directives du niveau supérieur.

Caractéristiques des informations en fonction du type d'activité

Principales caractéristiques de l'information :

- **Précision** : Une information est dite précise lorsqu'elle décrit une réalité d'une manière la plus fidèle possible, la plus complète possible et sans aucune ambiguïté.

  Exemple : La commande n° 123 a été expédiée le 16 septembre 1996 et a un poids total de 5,6 kilogrammes.

- **Rapidité** : Le temps entre le moment où un événement se produit et celui où l'information le concernant devient utilisable doit être le plus court possible.

  Exemple : Le cours d'une valeur en bourse doit être disponible quelques secondes après son établissement.

Caractéristiques des informations en fonction du type d'activité

- **Niveau d'agrégation** : C'est le fait qu'une valeur représente une donnée élémentaire ou le résultat d'une élaboration plus ou moins complexe.

  Exemple : Montant de la commande 123 : 50.

  Montant total des commandes du mois d'avril : 1000.

- **Provenance** : Permet de savoir si l'information est interne à l'organisation ou externe.

  Exemple : Information en provenance de fournisseurs, clients, réglementation, concurrence, données économiques, etc.).

- **Orientation** : Orientation **vers le présent** sur la base du passé ou orientations **vers le futur** sur la base du présent.

  Exemple : Situation des machines dans un atelier pour décider du lancement d'un lot de fabrication (*orientation vers le présent*)

  Budget (*orientation vers le futur*).

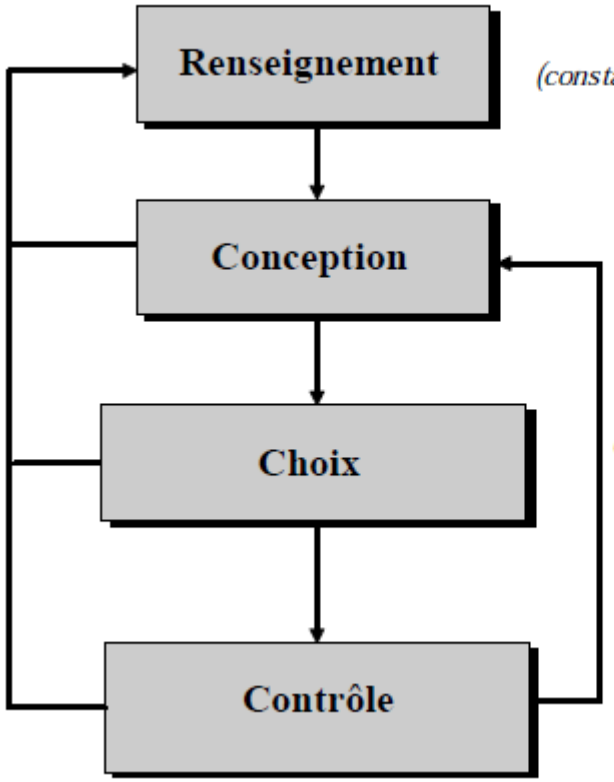
Caractéristiques des informations en fonction du type d'activité

Caractéristique de l'information	Contrôle opérationnel	Planification stratégique
Précision	*Élevée*	*Réduite*
Rapidité	*Grande*	*Faible*
Agrégation	*élémentaire*	*Élevée*
Provenance	*Interne*	*Externe*
Orientation	*Vers le présent*	*Vers le futur*

Modèle IDC

Processus de décision : Selon H. Simon, le processus de prise de décision se fait selon un modèle dit

Intelligence - Design - Choice (IDC)



Identifier et formuler le problème (constatation d'un différence entre la réalité et ce qui est souhaité)

Imaginer des solutions alternatives possibles et en déterminer les conséquences potentielles

Choisir une solution parmi les alternatives

Vérifier que la solution est conforme aux attentes

Modèle IDC

- **Utilisation du SI comme aide au processus de prise de décision :**

  Le SI intervient aux différents niveaux :

  - ***Phase de renseignement*** : Le SI doit permettre un accès aisé aux informations nécessaires.
  - ***Phase de conception*** : Le SI doit offrir des possibilités de modélisation et de calcul d'impact.
  - ***Phase de contrôle*** : Le SI doit disposer de mécanismes de saisie et de maintenance des valeurs des variables décrivant le système géré.

☞ Le SI doit :

- avoir la souplesse adaptée à l'utilisateur
- être maîtrisable par l'utilisateur

Types de décisions : structurées ou non structurées

Les décisions sont de deux types :

- Décisions structurées
- Décisions faiblement ou non structurées

- **Décisions structurées** :

  Une décision est dite structurée quand :

  - Les informations nécessaires à son élaboration sont disponibles
  - Les alternatives possibles sont énumérables
  - Les mécanismes d'évaluation des solutions sont connus

  Exemples :

  Gestion de stock,

  Planification de fabrication en raffinerie

☞Les décisions structurées sont **programmables**.

Types de décisions : structurées ou non structurées

- **Décisions faiblement ou non structurées** :

  Une décision est dite faiblement ou non structurée quand :

  - Les informations nécessaires à son élaboration sont plus ou moins disponibles
  - Les alternatives possibles sont non énumérables (explosion combinatoire).
  - Les critères à satisfaire sont contradictoires.

  Exemples :

  - Décisions faiblement structurées : Ordonnancement de fabrication, préparation de budget, lancement d'un produit.
  - Décisions non structurées : Gestion de projet, publicité, R&D

☞En la **simplifiant**, une décision faiblement structurée peut devenir structurée et donc programmable.

Type de décision et SI

- Les décisions structurées sont exécutables via des procédures automatisées.

  Elles constituent le **Système d'Information Transactionnel** (SIT).

  Le système informatisé correspondant est composé d'applications de type OLTP (On Line Transaction Processing).

  Les décisions peu ou pas structurées ne peuvent pas être totalement prises en se basant uniquement sur le SIT.

☞ *Nécessité d'un autre système d'information au dessus du SIT susceptible d'apporter une aide à ces décisions. C'est le* ***Système d'Information d'Aide à la Décision*** *(****SIAD****).*

- Le SIAD a les caractéristiques suivantes :
  - Utilise les données du SIT.
  - Dispose en plus d'informations propres.
  - Fournit un accès aisé aux informations pour les décideurs.
  - Offre des possibilités de modélisation et de simulation.
  - Laisse une place plus ou moins importante à l'informel.

SIAD : Système Informatique d'Aide à la Décision

Définition :

C'est un système ***interactif*** qui, à travers un ***dialogue***, permet à un décideur ***d'amplifier*** son raisonnement dans l'identification et la résolution de problèmes ***mal structurés***.

Caractéristiques d'un SIAD :

- **Interactif** : Échange entre un logiciel et un utilisateur

  ➔Importance de l'ergonomie
- **Outil de dialogue** : entre l'utilisateur et le système et indirectement entre l'utilisateur et lui-même.
- **Aide à la décision** : Il n'est pas question de fournir une solution à un problème (comme dans le cas de la recherche opérationnelle) mais d'aider et accompagner l'utilisateur dans son propre raisonnement.
- **Problèmes mal structurés** : C'est plutôt dans ce type de problèmes que les SIAD trouvent leur raison d'être.

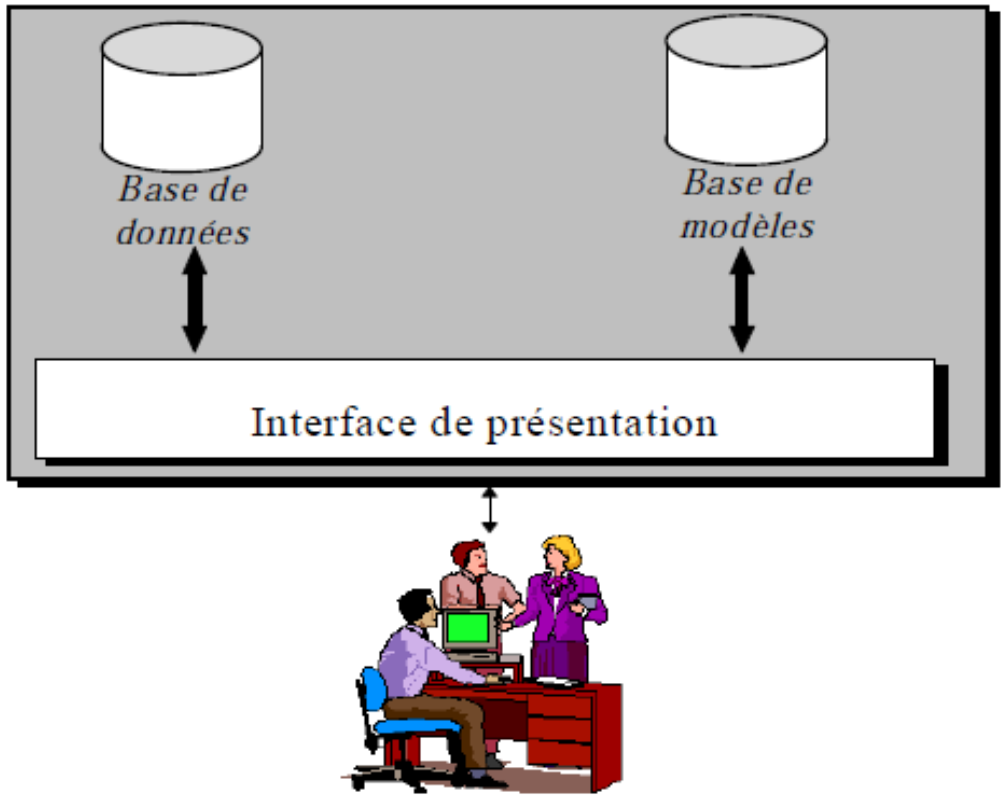
SIAD : Système Informatique d'Aide à la Décision

Architecture d'un SIAD :

Un SIAD est composé des éléments suivants :

- **Base de données** : C'est une base de données spécifique au SIAD ou celle du système d'information transactionnel (SIT). Dans le premier cas, la base contient des données internes (transformation des données de production), des données privées à l'utilisateur et des données externes.
- **Base de modèles** : C'est un ensemble de modèles de calcul et de mise en forme de données.
- **Interface de présentation** : C'est la partie visible du système pour l'utilisateur. Elle assure la communication entre ce dernier et le système.

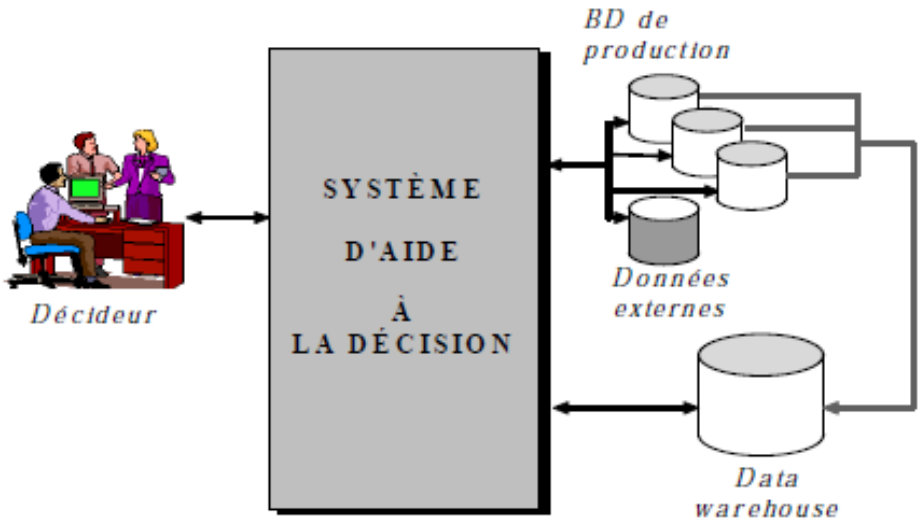
SIAD : Système Informatique d'Aide à la Décision



BD Production / Entrepôt de données

Un système d'aide à la décision peut utiliser deux types de source de données :

- Une base de données de production
- Un entrepôt de données (data warehouse)



BD Production / Entrepôt de données

Utilisation d'une base de données de production :

- C'est la base contenant les données relatives au **système d'information opérant**.
- Les données sont : **précises**, **non agrégées** et d'une utilisation **orientée vers le présent**.
- Les données ne contiennent pas d'historique.
- Les données ne contiennent pas d'informations externes à l'entreprise.
- On peut avoir **plusieurs bases** de données, une base par domaine.
- Pour pouvoir être utilisées à des fins décisionnelles, ces données doivent être **transformées** et **enrichies** par des données externes.
- C'est le système d'aide à la décision qui prend en charge les fonctions de transformation et d'enrichissement

BD Production / Entrepôt de données

Utilisation d'un entrepôt de données :

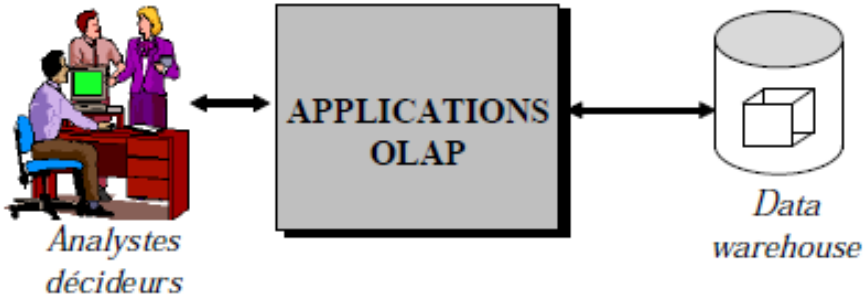
- C'est une base contenant les données relatives au **système d'information stratégique**.
- Les données sont : **très peu précises**, **agrégées** et d'une utilisation **orientée vers le futur**.
- Les données contiennent des historiques.
- Présence d'informations externes à l'entreprise.
- Généralement une seule base de données mais assez volumineuse.
- Utilisable directement par des décisionnaires.
- Alimentée périodiquement à partir de base(s) de données de production.
- Utilisée exclusivement en consultation

OLTP / OLAP

Les applications informatiques peuvent être classées en deux catégories :

- Applications OLTP (On-Line Transactional Processing)
- Applications OLAP (On-Line Analytical Processing)





OLTP / OLAP

Applications OLTP :

- L'intégrité et la sécurité des données sont privilégiées.
- Requêtes simples
- Utilisées par des services de production : commerciaux, administratifs, production, etc..
- Nécessitent la connaissance des structures des données.
- Utilisent des bases de données de production (relationnelles)
- Manipulent des données homogènes.
- Nombre d'utilisateurs simultanés important.
- Applications critiques.

  Exemples d'applications :
  - Gestion bancaire
  - Systèmes de réservation
  - Gestion commerciale, personnel, production, etc.

OLTP / OLAP

Applications OLAP :

- L'analyse et la manipulation des données sont privilégiées.
- Requêtes complexes
- Applications d'aide à l'élaboration de stratégies
- Utilisées par les DG, les services marketing, financiers, contrôleurs de gestion, etc..
- Ne nécessitent pas la connaissance des structures des données.
- Utilisent des data warehouses (modèle multidimensionnel)
- Manipulent des données hétérogènes.
- Nombre d'utilisateurs simultanés faible.

Exemples d'applications :

  - Analyse des tendances
  - Analyse des comportements

BD relationnelles / BD multidimensionnelles

Les données nécessaires pour effectuer des analyses et en déduire des orientations stratégiques peuvent être stockées dans des structures :

- relationnelles ou
- multidimensionnelles.

BD relationnelles / BD multidimensionnelles

Bases de données relationnelles :

- Structure tabulaire
- Croisement des données à l'aide des jointures
- Pas de redondance (doublons, agrégation)
- Les résultats de requêtes sont sous forme de listes
- La représentation des hiérarchies est difficile

➔ *Structures peut adaptées aux applications de type OLAP.*

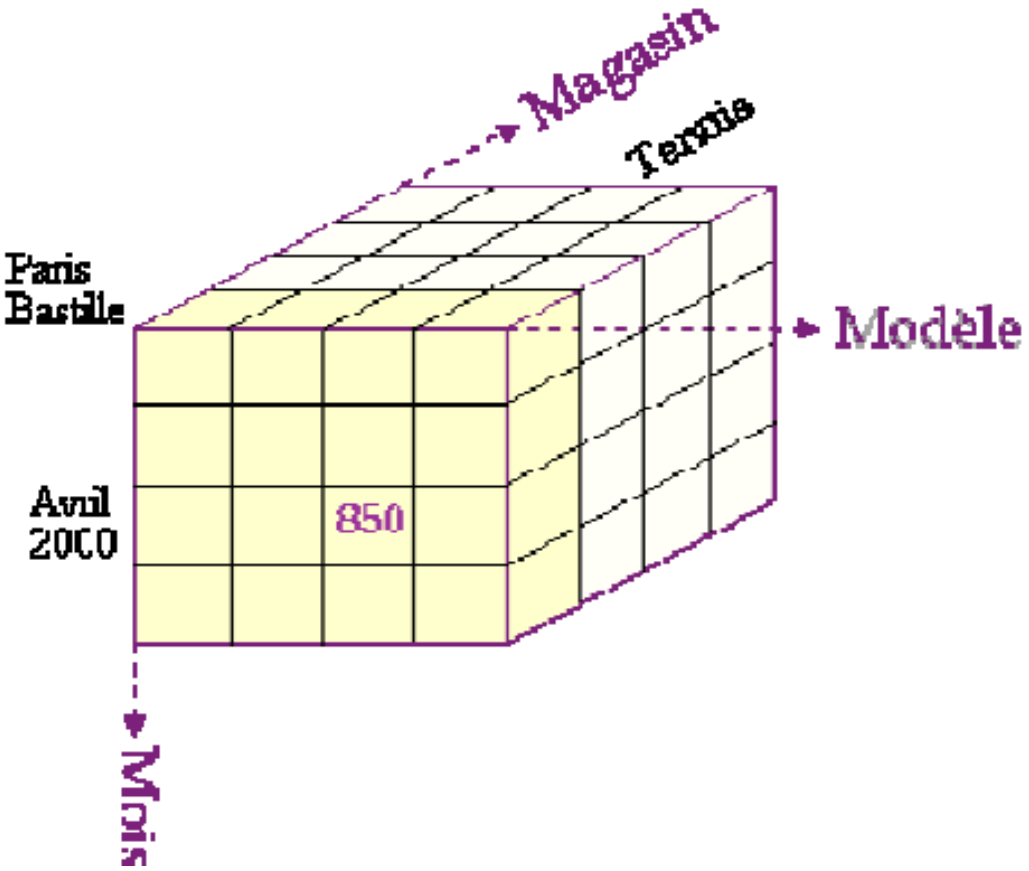
BD relationnelles / BD multidimensionnelles

Bases des données multidimensionnelles :

- Les données sont organisées selon des axes
- Chaque axe correspond à un axe d'analyse.
- Une base de données multidimensionnelle est un hypercube avec autant de dimensions que d'axes d'analyse (neuf en général).
- Possibilité de redondance des données.
- Les requêtes peuvent exploiter toutes les combinaisons d'axes.
- Temps d'accès stable
- Moins de risque d'erreurs dans la formulation des requêtes

➔*Structures bien adaptées aux applications de type OLAP.*

BD relationnelles / BD multidimensionnelles



Chapitre 2

INTRODUCTION AUX ENTREPÔTS DE DONNÉES

Eléments de contenu

- Définition
- Caractéristiques d'un ED
- Comparaison BD de production et ED
- Exemples d'utilisation d'un ED
- Notion de Magasin de Données(Data Mart)
- Architecture d'un ED
  - Données sources
  - Méta-données
  - Extraction, Transformation et Chargement (ETL)
- Cycle de développement d'un ED
- Exploitation d'un ED
- Utilisateurs d'un ED
- Techniques d'utilisation d'un ED

Introduction

Caractéristiques du contexte économique des années 90 :

- Concurrence aiguë
- Rigueur économique
- Client de plus en plus informé et exigent

Chaque entreprise souhaite conquérir une nouvelle clientèle et augmenter les profits.

Solution :

Disposer du maximum d'informations sur le client dans une structure centrale facilement accessible aux utilisateurs (analystes, décideurs).

☞ **Entrepôt de données**

(DATA WAREHOUSE)

Définition

Le DW est une collection de données orientées sujet, intégrées, non volatiles et historisées, organisées pour le support d'un processus d'aide à la décision.

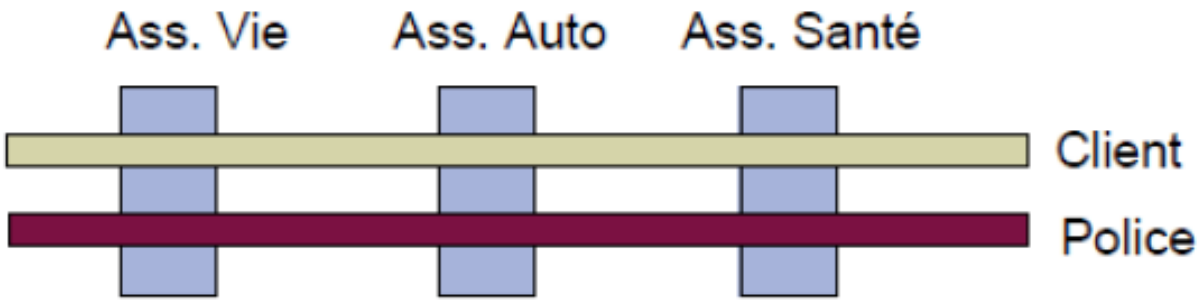
W.H. Inmon (1996)

C'est une BD à des fins d'analyse !!

Caractéristiques d'un ED

Données orientées sujet

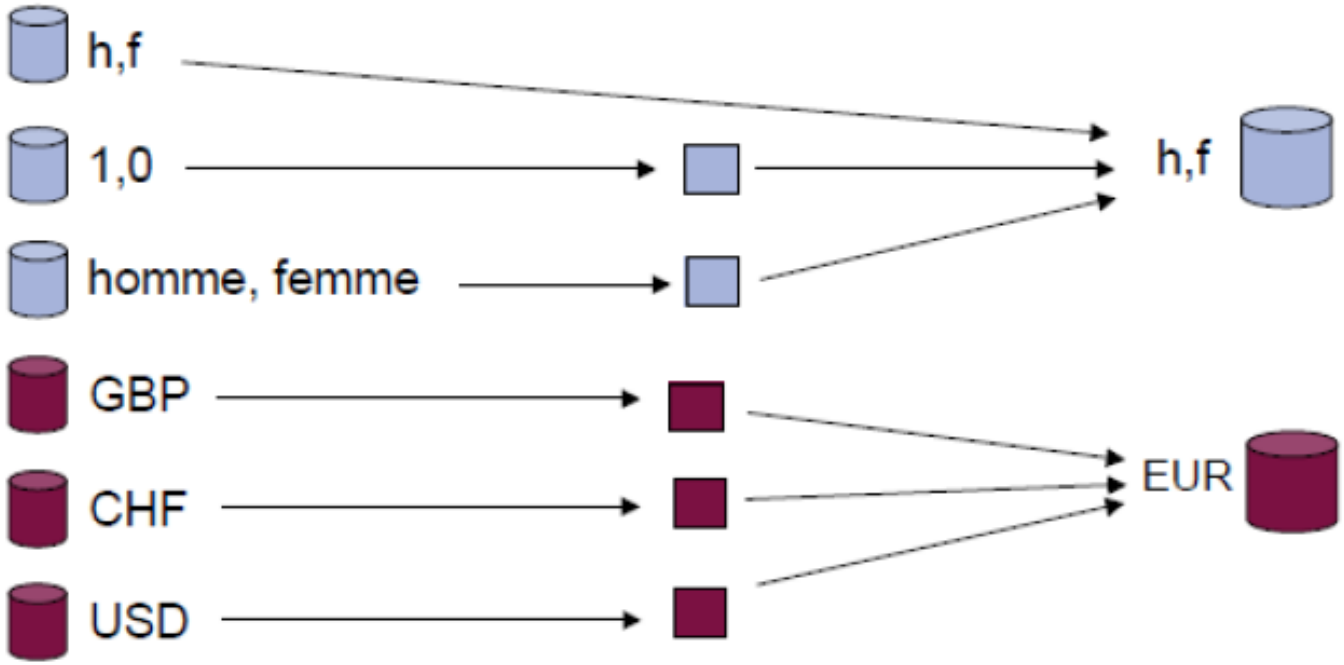
- Regroupe les informations des différents métiers
- Ne tiens pas compte de l'organisation fonctionnelle des données



Caractéristiques d'un ED

Données intégrées

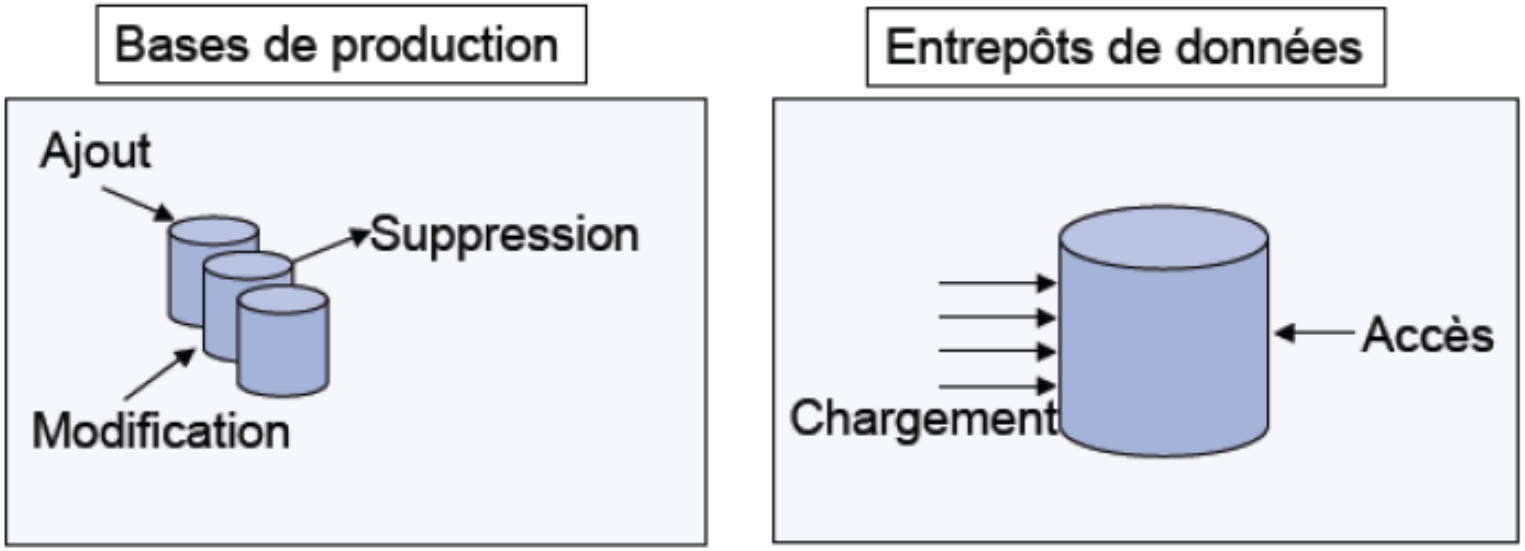
- Normalisation des données
- Définition d'un référentiel unique



Caractéristiques d'un ED

Données non volatiles

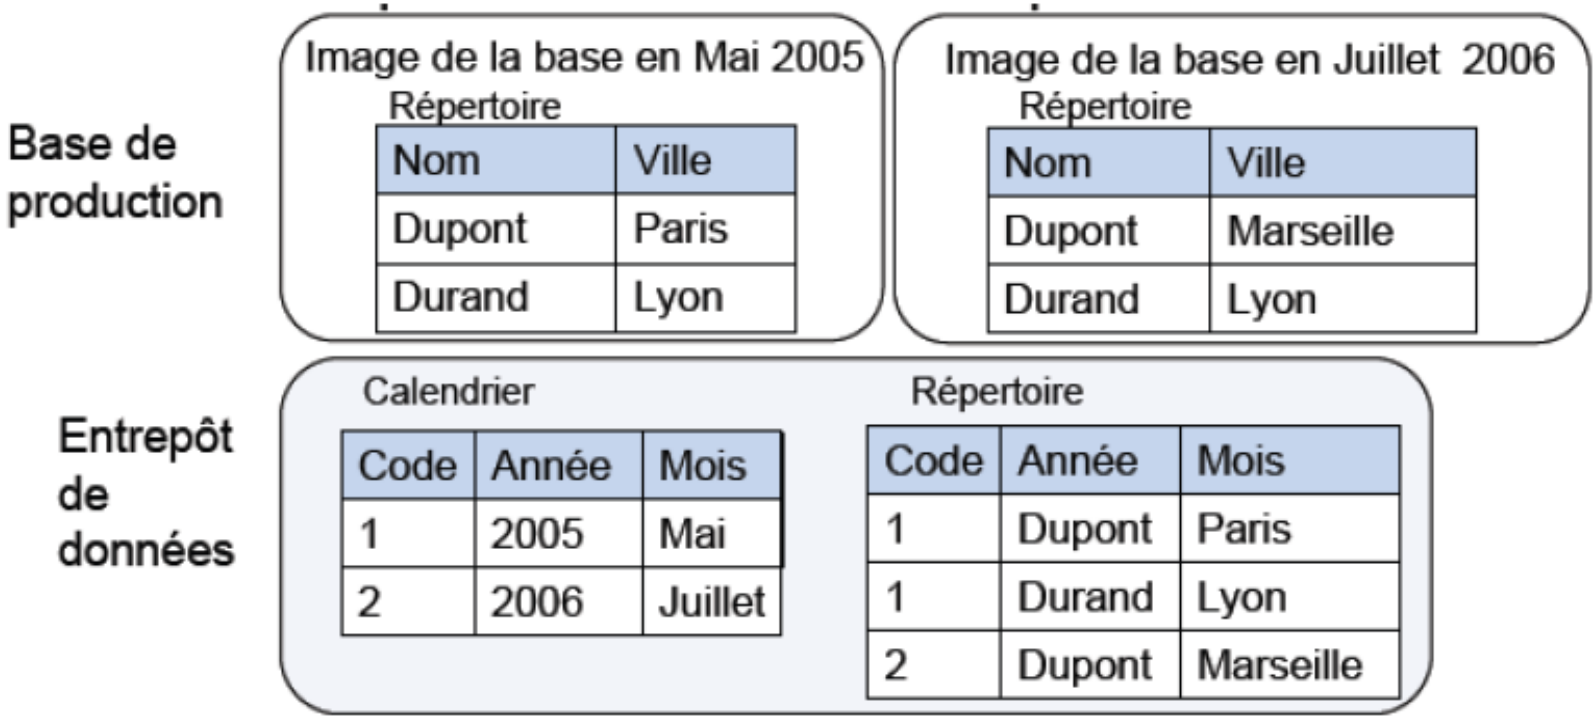
- Traçabilité des informations et des décisions prises
- Copie des données de production



Caractéristiques d'un ED

Données historisées / datées

- Les données persistent dans le temps
- Mise en place d'un référentiel temps



Comparaison BD de production et ED

Caractéristiques	Base de production	ED
Type de contenu	Données de gestion	Informations stratégiques
Type d'utilisateurs	Gestionnaires	Décideurs, Analystes
Redondance	Très peu (normalisation)	Fréquente (dénormalisation)
Types d'accès	Consultation et mise à jour	Uniquement consultation
Utilisation	Transactionnelle (OLTP)	Décisionnelle (OLAP)
Historique	quelques jours ou quelques mois	Des années
Exigences en performances	Sévères	Lâches

Pourquoi un ED ?

- Mieux gérer et exploiter le gisement informationnel de l'entreprise à des fins décisionnelles

- Obtenir des informations détaillées et stratégiques pour l'entreprise sur un sujet afin de prendre les meilleures décisions.

  ☞ *Support d'aide à la décision*

  ☞ *Un ED doit permettre aux personnes adéquates d'obtenir les informations adéquates au moment adéquat.*

- Principaux domaines d'utilisation :
  - Profil client
  - Marketing
  - Finance
  - Ventes

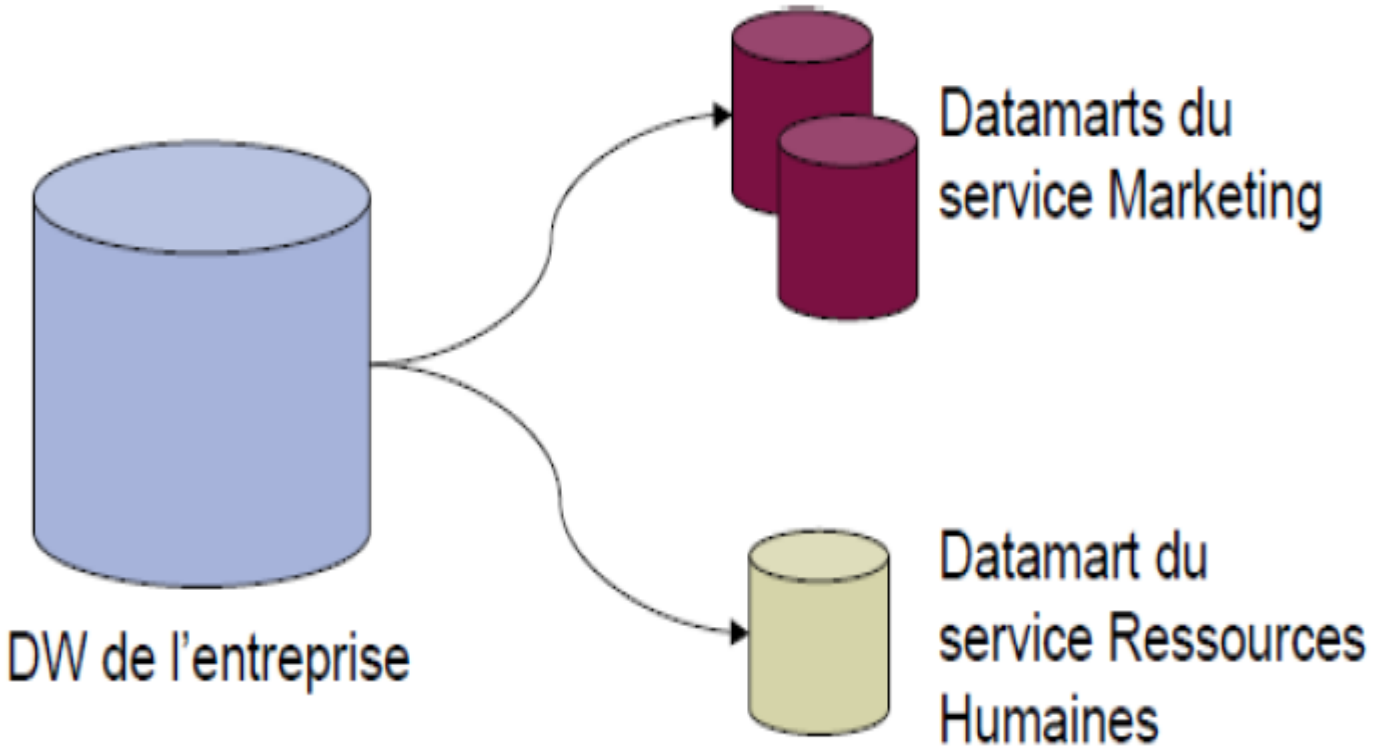
Exemples d'utilisation d'un ED

- **Clientèle :**
  - Qui sont nos clients ?
  - Pourquoi sont-ils nos clients ?
  - Comment les conserver ou les faire revenir ?
  - Ces clients sont-ils intéressants pour moi ?
- **Marketing :**
  - Où placer ce produit dans les rayons ?
  - Comment cibler plus précisément le mailing concernant ce produit ?
- **Ventes :**
  - Prévision des ventes dans un hypermarché pendant un week-end.
  - Prévision du personnel

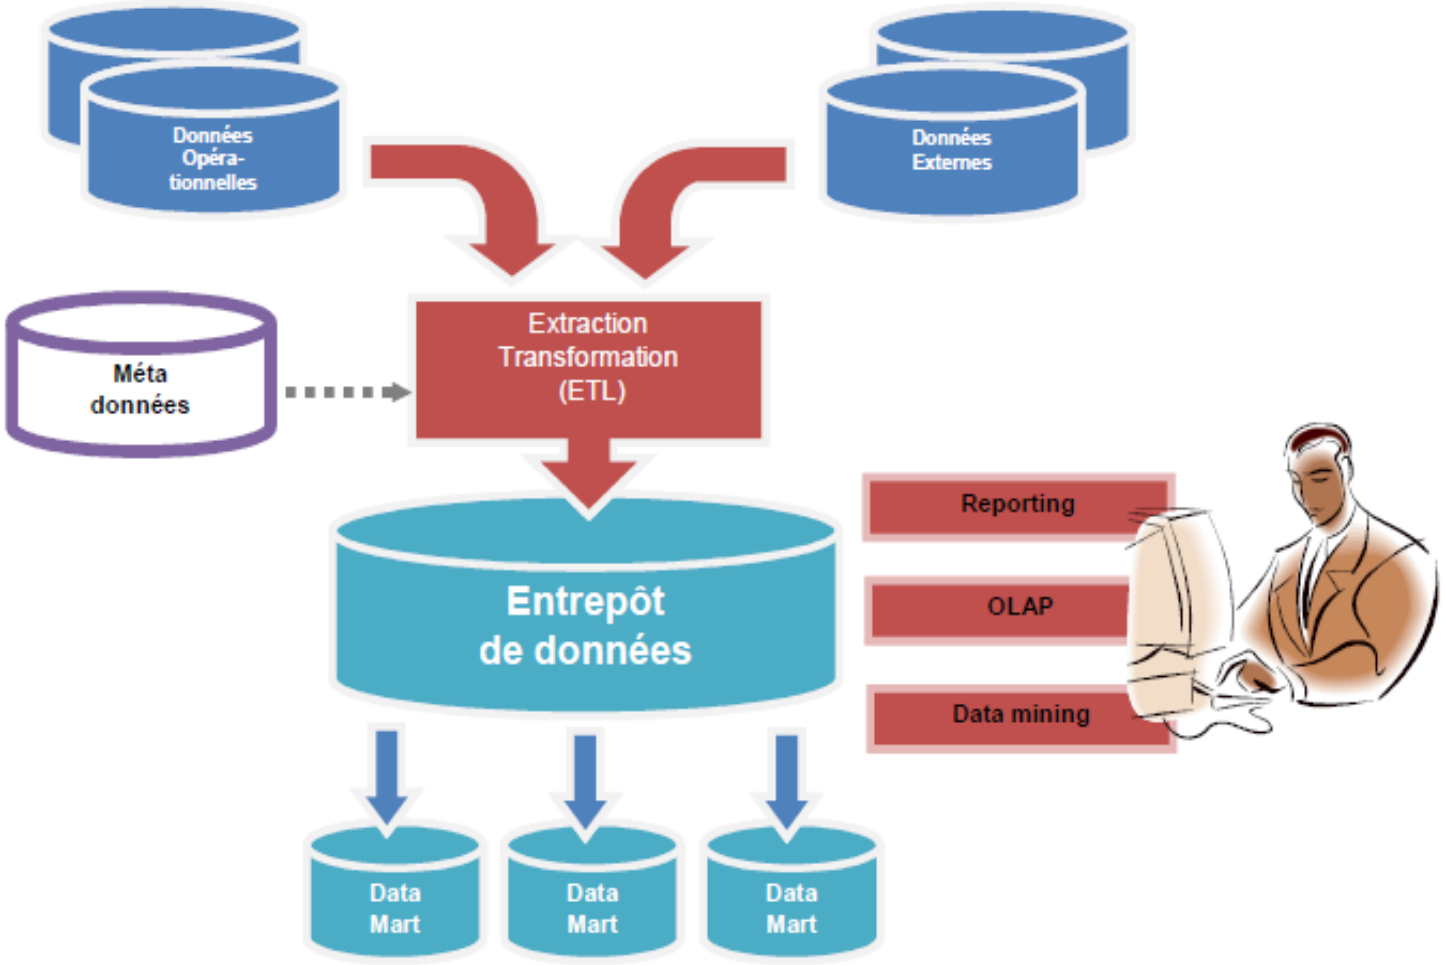
Notion de Magasin de Données (Data Mart)

- C'est l'implémentation d'un ED pour un domaine d'activité restreint.
- C'est un sous-ensemble d'un ED.
- Une entreprise dispose souvent de plusieurs data marts, un par département ou service.
- Les données d'un data mart sont extraites à partir d'un data warehouse.
- Cas particulier : On peut avoir un ensemble de data marts sans ED
- La présence de data marts ou non dépend de l'architecture du SID (centralisée, répartie, dupliquée)

Notion de Magasin de Données (Data Mart)



Architecture d'un ED



Données sources

Ce sont les données sources utilisées pour alimenter l'ED. Elles regroupent :

- **Données de production** : données opérationnelles utilisées dans les applications transactionnelles (OLTP). Elles peuvent provenir de bases de données (relationnelles ou non) ou de fichiers.
- **Données légataires** (legacy data) : données off-line (archivées) car elles ne sont plus nécessaires aux applications transactionnelles. Elles permettent de disposer d'historique pour les analyses de tendance (data mining).
- **Autres données internes** : données internes structurées ou non et non utilisées par les applications transactionnelles : *rapports, graphiques, feuilles de calcul et documents papier.*
- **Données externes** : données gérées et manipulées par d'autres entreprises. Elles peuvent être sous forme informatique (CD-ROM, Internet) ou papier (presse économique, rapports d'organismes et institutions spécialisés)

Méta-données

Les méta-données sont stockées dans une métabase contenant :

- Une description des données stockées dans l'ED
- Les correspondances entre données sources et celles de l'ED
- Les règles d'extraction, création, stockage et mise à jour des données
- Un glossaire des objets manipulés par les utilisateurs
- Les requêtes, rapports, index et profils prédéfinis
- Les règles de rafraîchissement et de réplication entre l'ED et les DM éventuels

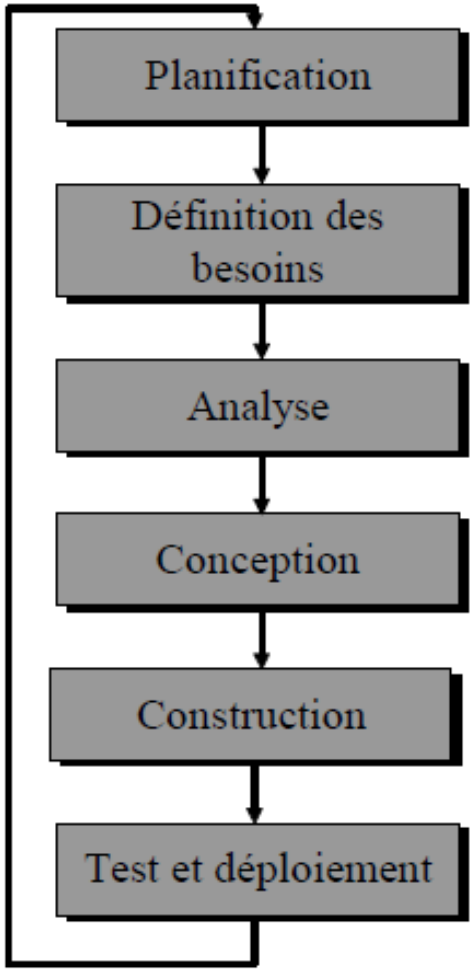
Extraction, Transformation et Chargement (ETL)

Couche applicative consistant à :

- **Intégrer** différents types de données en provenance de systèmes différents pour créer des nouvelles données.
- **Partitionner** les données en séries temporelles pour les analyser
- Effectuer des **calculs** pour obtenir des informations **sommaires** nécessaires aux utilisateurs
- **Transformer et formater** des données en provenance de sources différentes pour pouvoir les combiner de façon uniforme et consistante.

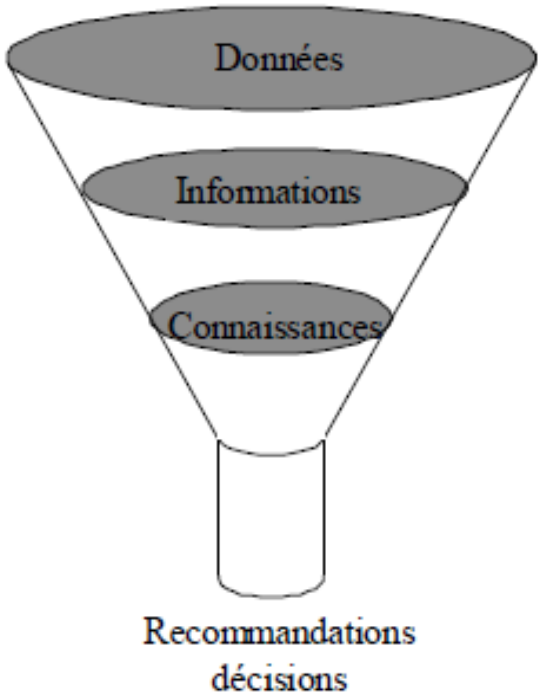
Cycle de développement d'un ED

Le cycle de développement d'un ED est globalement le même que celui d'un SI quelconque.

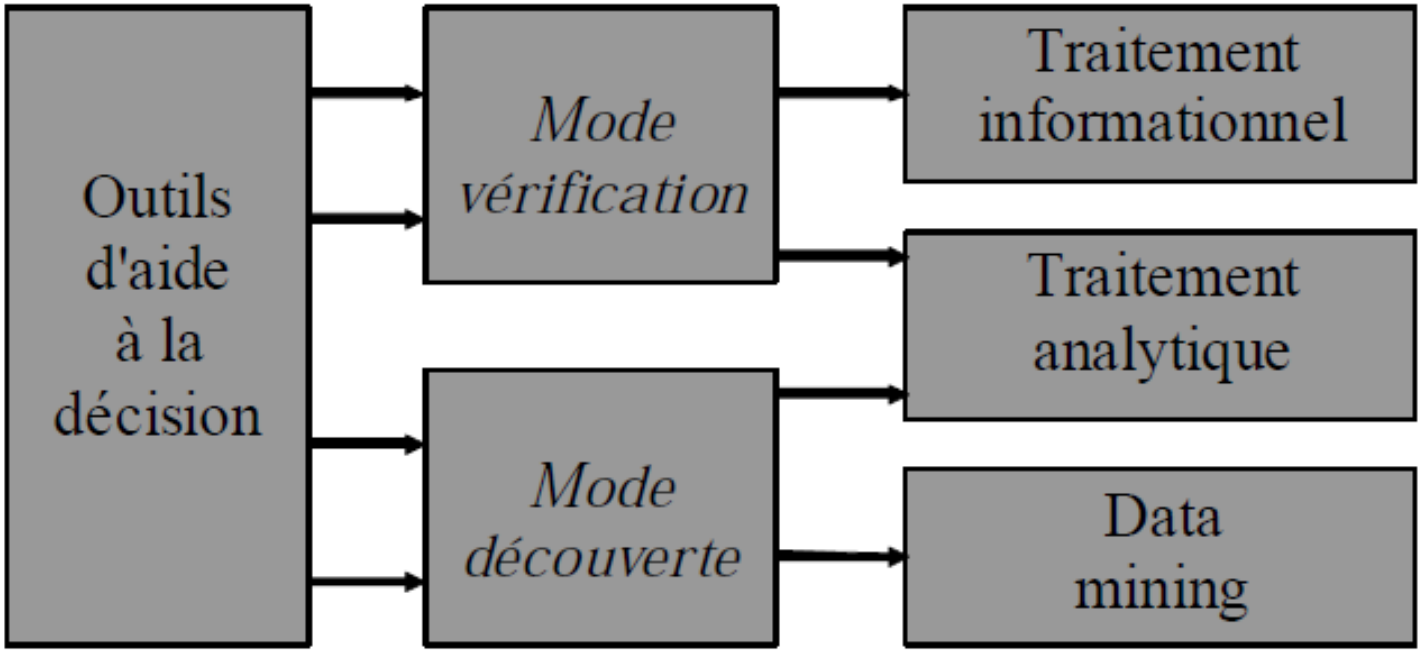


Exploitation d'un ED

- Un ED doit aider à :
  - Comprendre le passé
  - Planifier le futur
- Passage du stade des **données** vers celui des **recommandations** et des **décisions**.



Techniques d'utilisation d'un ED



Utilisation d'un ED : Traitement informationnel

Le traitement informationnel permet de répondre à des questions de type :

- Est ce que la vente des articles de sports est saisonnière ? Quels sont les articles concernés et de quelle manière ?
- Nombre de voitures vendues le mois dernier ? Comment se situe ce nombre par rapport aux ventes du même mois des cinq dernières années ?

Le traitement informationnel permet :

- La consultation et l'extraction des données à partir de l'ED
- L'analyse des données
- La présentation des données sous forme de rapports (tableaux, matrices, graphiques)

Utilisation d'un ED : Traitement analytique

Le traitement analytique (ou OLAP) permet de répondre à des questions de type :

- Combien de voiture rouge ont été vendues en novembre en France, en Italie et en Allemagne ? Quel été le nombre pour la même période de l'année précédante et celle d'avant ?
- Quel est le stock de TV 55 cm dont le prix est inférieur à 3000. Donner ce nombre à la fin de chaque trimestre pour les cinq dernières années.

Le traitement analytique permet :

- une présentation multidimensionnelle des données indépendamment du mode de stockage dans l'ED.
- une extraction et une analyse des données effectuées en passes successives : drill-down multi niveaux, agrégation, etc.
- une analyse statistique et des tendances
- Affichage des données en graphiques 2D et 3D avec des facilités de pivotement selon des axes (différentes perspectives).

Utilisation d'un ED : Data mining (Fouille de données)

- Le data mining permet d'exploiter le gisement informationnel contenu dans un ED pour découvrir d'autres informations cachées : habitudes et comportement des clients.
- Les informations déduites permettent de bien cibler les clients, les produits, les régions, etc.
- Le data mining permet de :
  - Comprendre ce qui s'est passé (Quoi)
  - Trouver une explication de ce qui est passé (Pourquoi)
  - Déduire les actions à entreprendre

Chapitre 3

CONCEPTION DES ENTREPÔT DE DONNÉES

Notion de modèle

« Un modèle est la représentation d'un objet, d'un système ou d'une idée sous une forme quelconque autre que celle de l'entité représentée elle-même.

Sa fonction est de nous aider à expliquer, à comprendre, ou à améliorer un système.

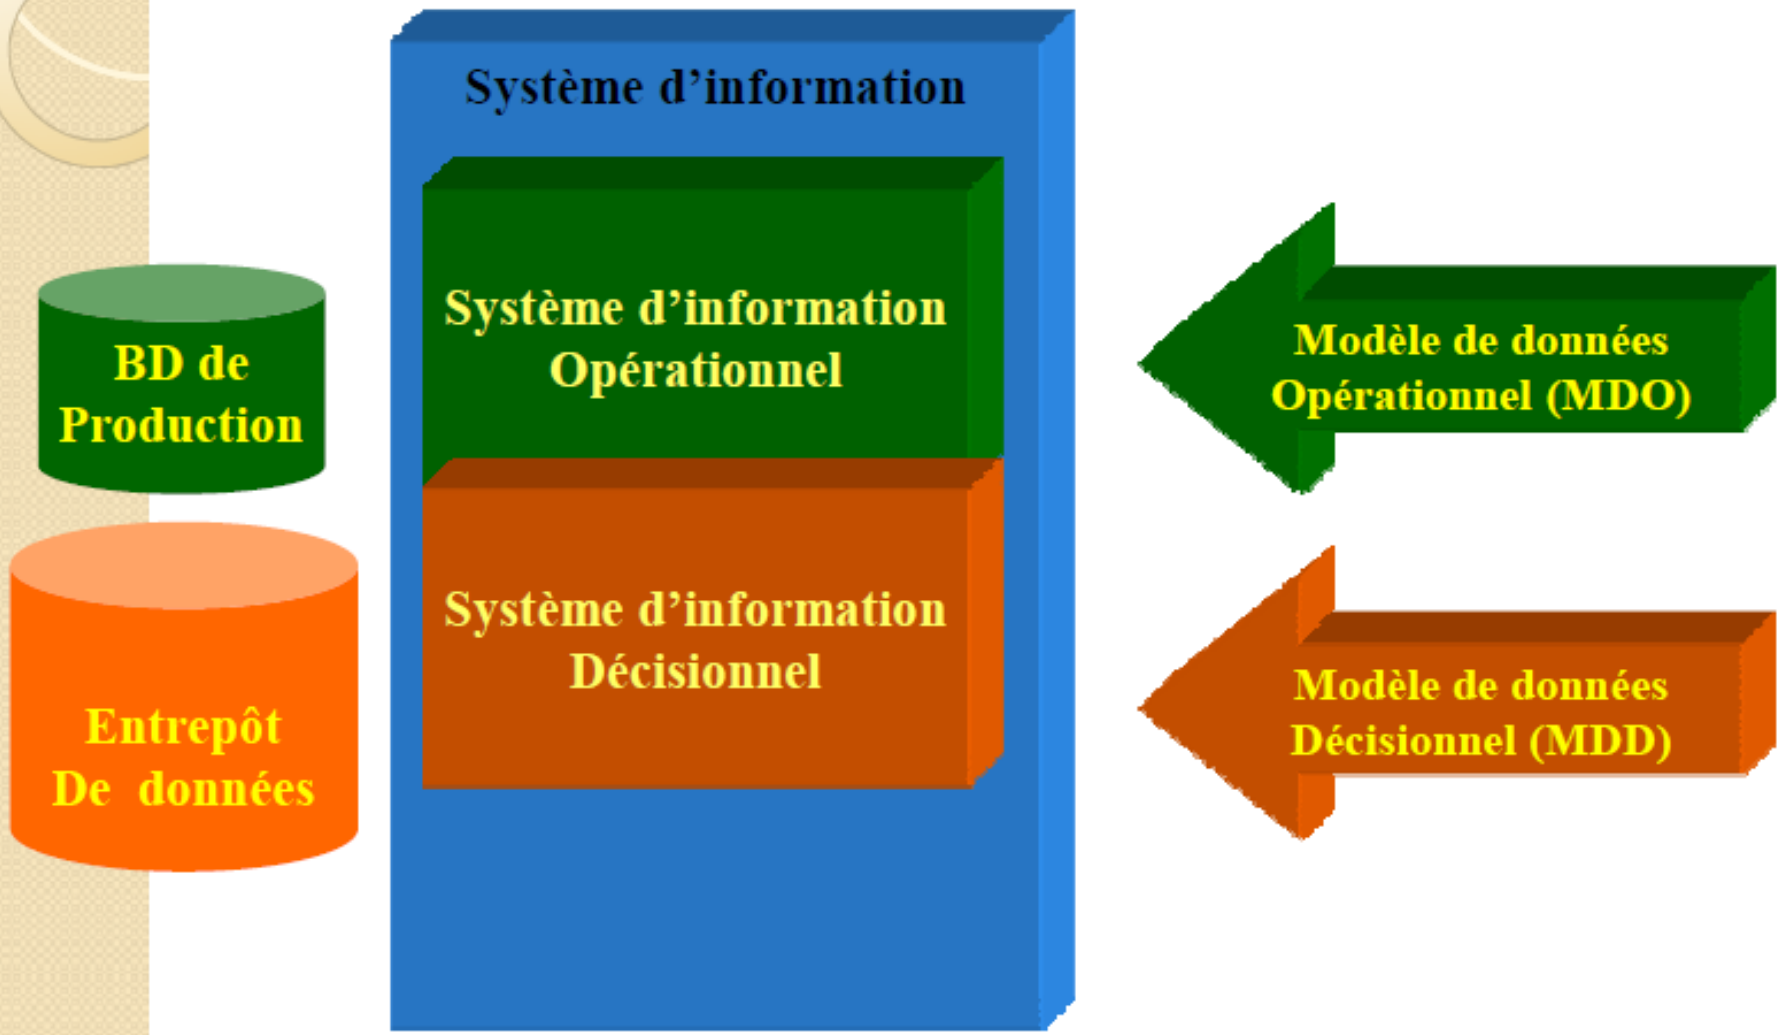
Le modèle d'un objet peut être une réplique exacte de cet objet (bien qu'exécutée dans un matériau différent et à une échelle différente), ou une abstraction des propriétés saillantes de l'objet. » (*)

(*) D'après R.E Shannon, « Systems simulation, the art and science », Prentice Hall 1975

Types de modèles

- Modèles de données (vue statique)
- Modèles de traitements (vue dynamique)
- Modèles de flux (communications)
- Modèle d'architectures (implémentation)
- …

Types de modèles de données



Différences entre MDO et MDD

SI Opérationnel

- Données élémentaires
- Forte normalisation
- Consultation et màj
- Image actuelle de l'entreprise
- Structures internes non accessibles directement aux utilisateurs

BD de Production

Applications OLTP



SI Décisionnel

- Informations
- Forte dénormalisation
- Consultation
- Image successives de l'entreprise dans le temps (historique)
- Accessibles directement aux utilisateurs



Applications OLAP

Entrepôt de données

Différences entre MDO et MDD

- **MDO :**
  - **Modélisation « en réseau » :** toute entité (ou table) peut être reliée à toute autre entité (ou table).
- **MDD :**
  - **Modélisation « multi-dimensionnelle » :** Un ensemble d'entités (ou tables) périphériques sont reliées par une association (ou table) centrale.
    - Entités (ou tables) périphériques : **Dimensions**
    - Association (ou table) centrale : **Faits**

Différences entre MDO et MDD

Modèle entité-relation (ER):

- Représente les données sous la forme d'entités (tables) et de relations (références ou tables);
- Normalisation du schéma (ex: 3FN).

Modèle dimensionnel:

- Représente les données comme des faits et des dimensions;
- Les dimensions ne sont pas normalisées.

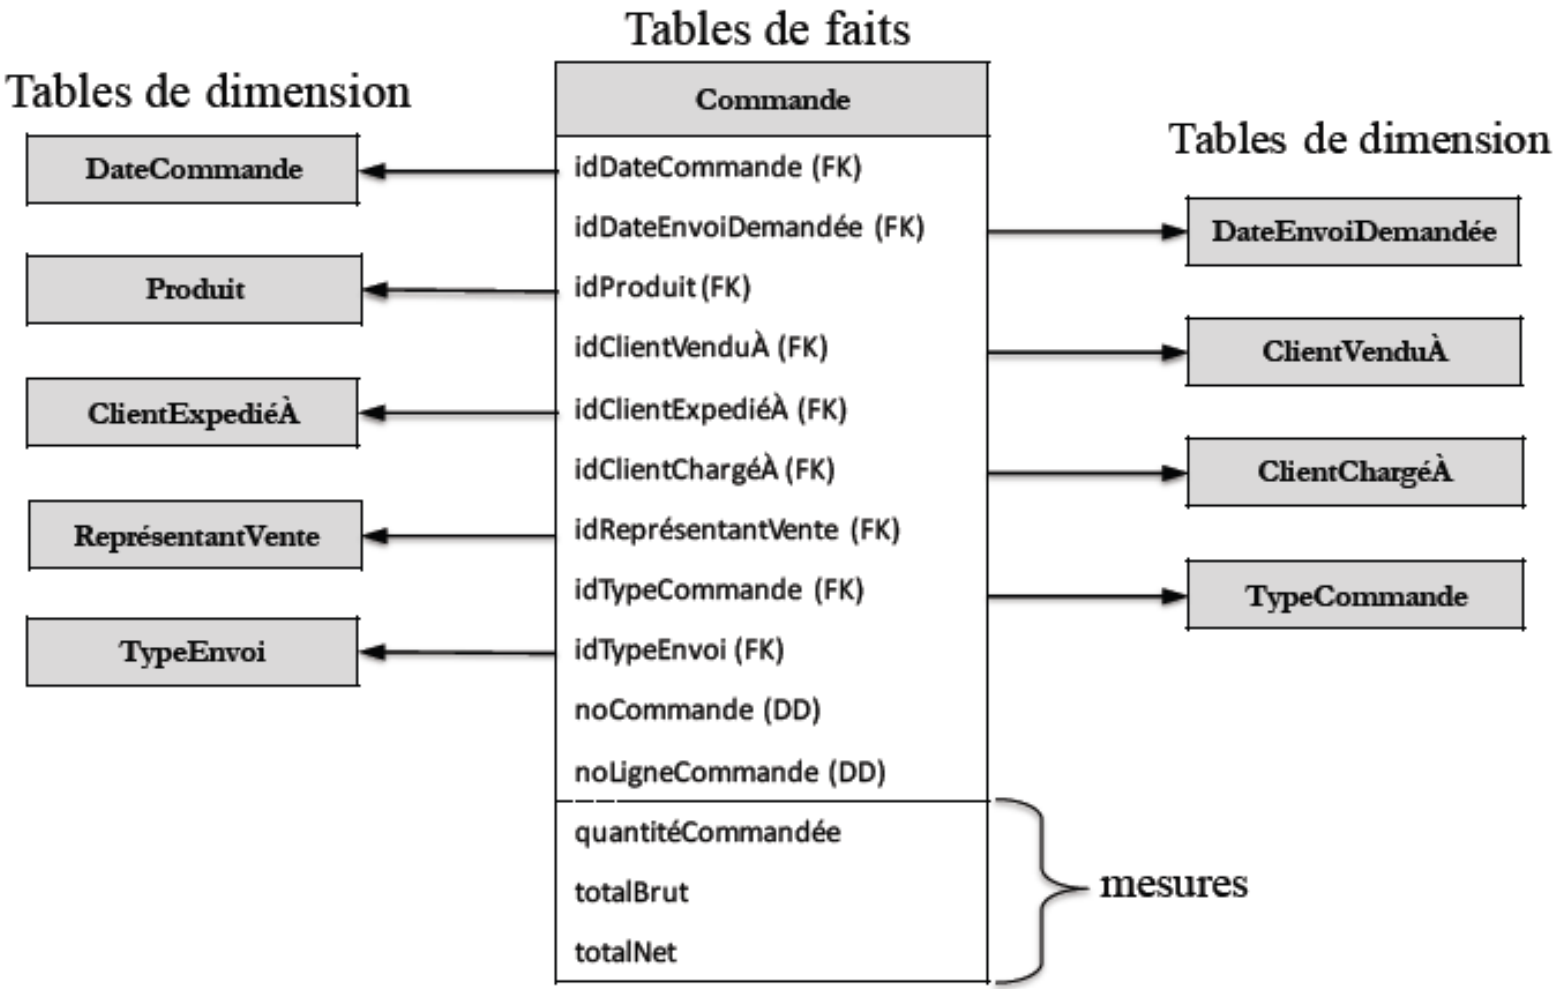
Avantages du modèle dimensionnel:

- Compréhensibilité:
  - Les données sont regroupées selon des catégories d'affaires qui ont un sens pour les utilisateurs d'affaires;
- Performance:
  - La dénormalisation évite les jointures coûteuses;
  - Autres optimisations (ex: index de jointure en étoile).

Modélisation multi-dimensionnelle

- Représente les données sous la forme d'un **schéma en étoile**:
  - Table de faits entourée de plusieurs tables de dimension (normalement entre 8 et 15)
- Les faits (mesures) sont généralement des valeurs numériques provenant des processus d'affaires;
- Les dimensions fournissent le contexte (*qui, quoi, quand, où, pourquoi et comment*) des faits;
- Les tables ne sont pas normalisées

Modélisation multi-dimensionnelle



Modélisation multi-dimensionnelle

Tables de faits

- Correspondent à un événement d'affaires
  - Ex: achat d'un produit par un client, envoi du produit au client, commande de matériaux auprès d'un fournisseur, etc.
- Contiennent deux types de colonnes:
  - Des métriques associées à l'événement d'affaire:
    - Ex: total des ventes, nombre d'items commandés, etc.
  - Des clés étrangères vers les tables de dimension:
    - Ex: ID du client qui fait la commande, ID du produit commandé, etc.
- Contiennent typiquement un très grand nombre de lignes:
  - Jusqu'à plusieurs milliards de lignes;
  - Souvent plus de 90% des données du modèle.

Modélisation multi-dimensionnelle

Mesure

- Élément de donnée sur lequel portent les analyses, en fonction des différentes dimensions.

- Ces valeurs sont le résultat d'opérations d'agrégation sur les données
  - Exemple :
    - Coût des travaux
    - Nombre d'accidents
    - Ventes
    - …

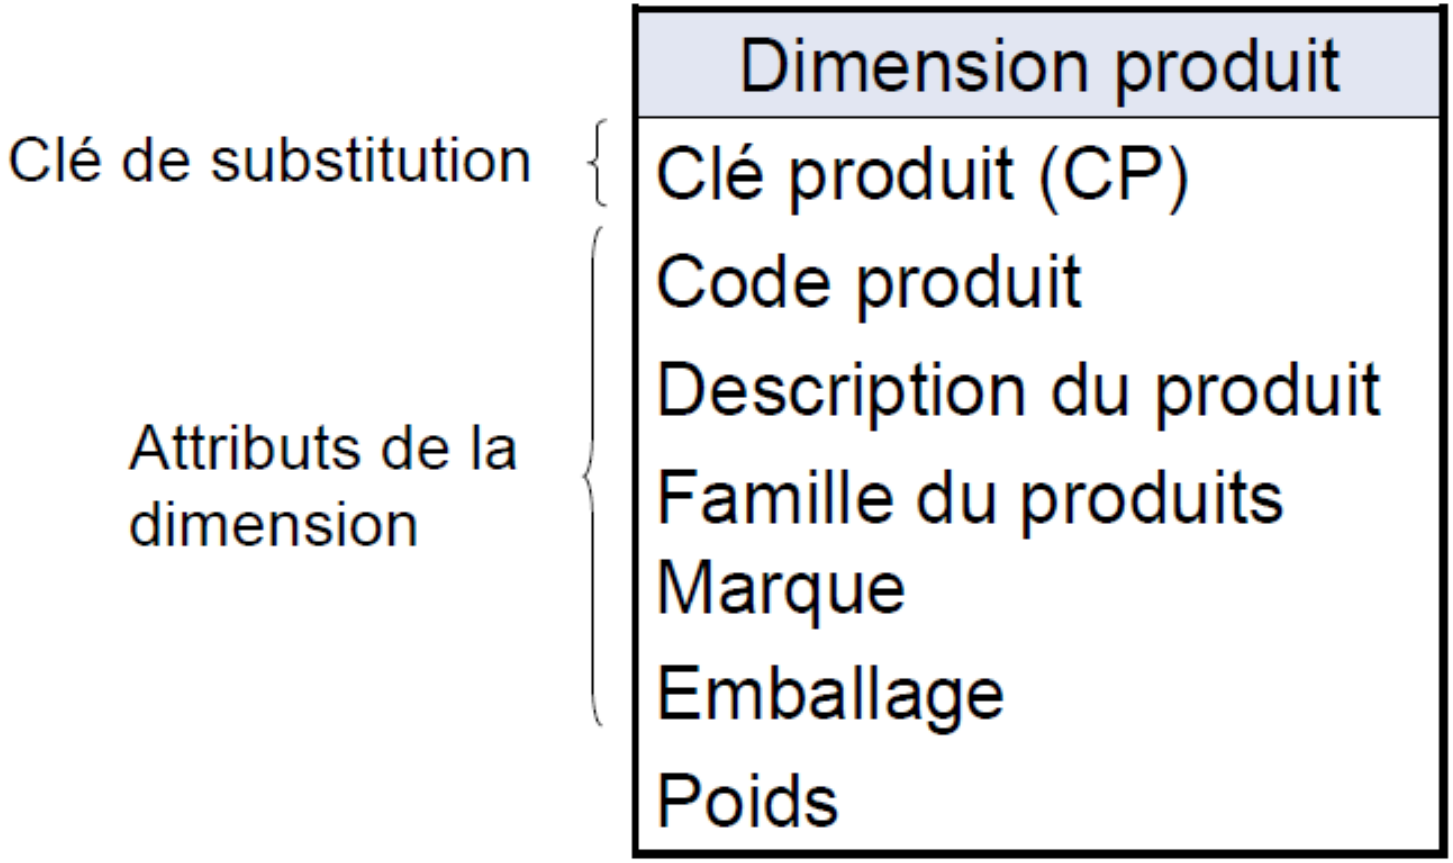
Modélisation multi-dimensionnelle

Tables de dimension

- Axes d'analyse avec lesquels on veut faire l'analyse
  - Géographique, temporel, produits, etc.
- Chaque dimension comporte un ou plusieurs attributs/membres
- **Une dimension est tout ce qu'on utilisera pour faire nos analyses**.
- Chaque membre de la dimension a des caractéristiques propres et est en général textuel
- ***Remarque importante*** :
  - tables de dimension << Table de fait

Modélisation multi-dimensionnelle

Tables de dimension



Modélisation multi-dimensionnelle

Mesures versus attributs de dimension

- Mesures:
  - Dépendent d'un événement d'affaires;
  - Ont souvent des valeurs continues (ou un grand nombre de valeurs discrètes possibles);
  - Servent dans le calcul d'indicateurs de performance;
  - Ex: montant total et quantité d'une commande.
- Attributs (numériques) de dimension:
  - Indépendants des événements d'affaires;
  - Ont souvent des valeurs discrètes;
  - Servent à filtrer ou étiqueter les faits;
  - Ex: jour et heure d'une transaction, âge d'un client, etc.

Modélisation multi-dimensionnelle

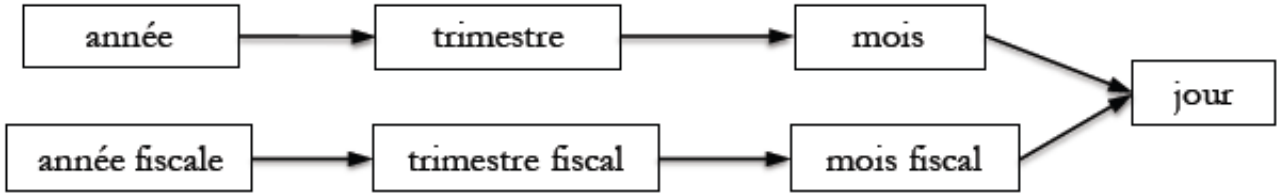
Clés d'une tables de faits

- Clés primaires:
  - La clé primaire est typiquement une **clé composée**, formée d'un sous-ensemble des clés étrangères vers les tables de dimension:
    - Ex: (*idDateTransaction*, *idClient*, *idProduit*).
- Clés étrangères:
  - Les clés étrangères ne devraient jamais être nulles
    - Sinon on peut violer le principe d'intégrité référentielle;
    - Utiliser plutôt une valeur spéciale dans la table de dimension;
    - Ex: une ligne "*Aucun spécial*" dans la dimension RabaisSpécial si le client n'a eu droit à aucun rabais lors d'une transaction)

Modélisation multi-dimensionnelle

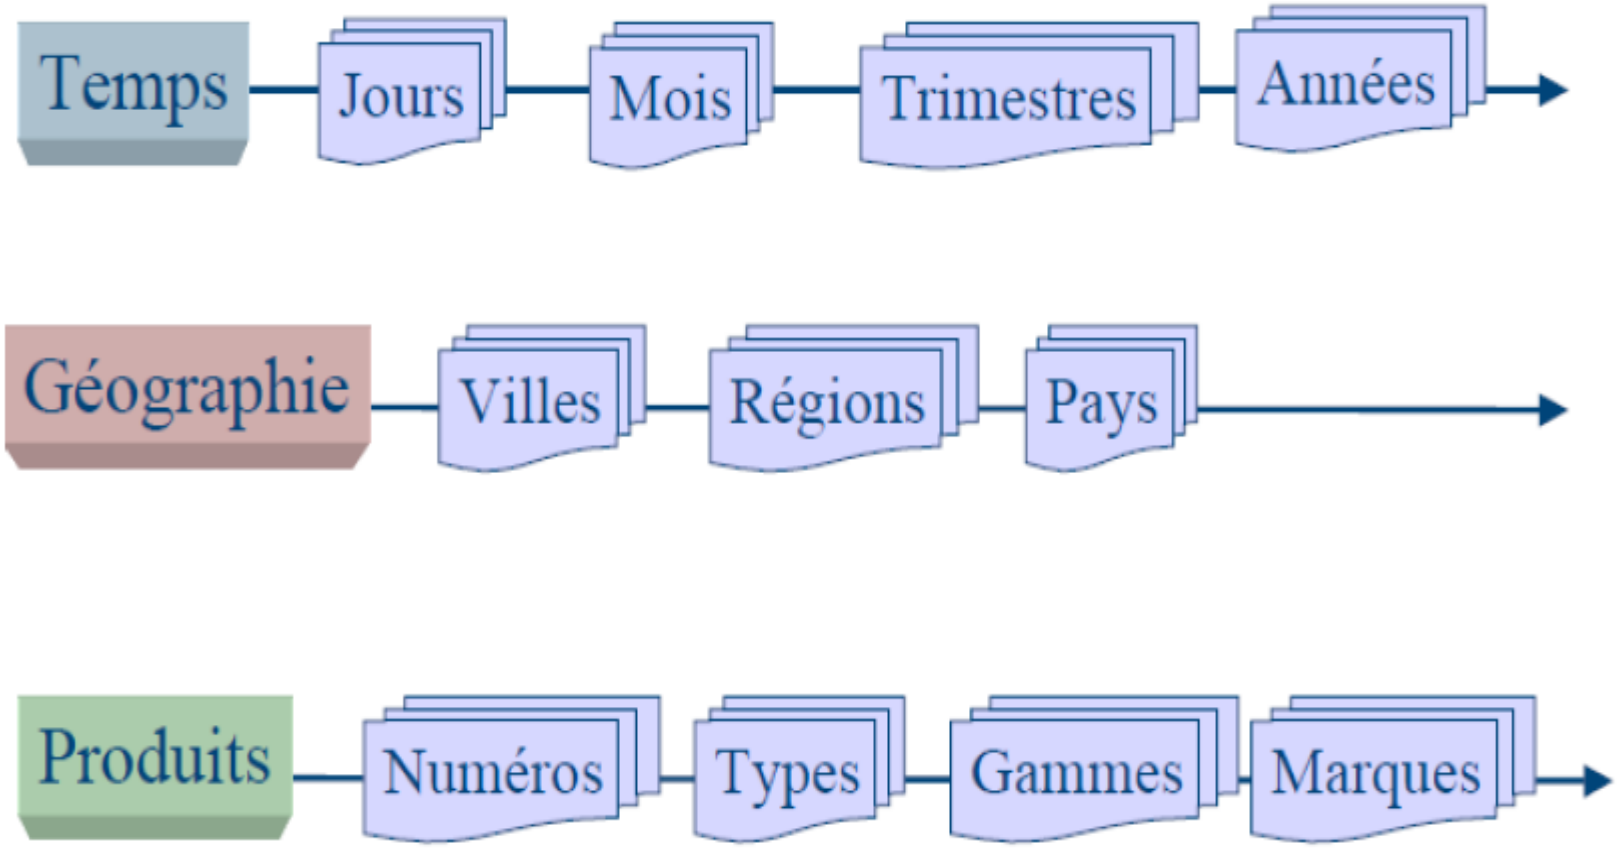
Hiérarchies dimensionnelles

- Ensemble d'attributs d'une table de dimension ayant une relation hiérarchique (*x* est inclus dans *y*);
- Correspondent à des relations de type 1 à plusieurs;
- Définissent les chemins d'accès dans les données (*drill-down paths*);
- Peuvent être simples:
  - **Produit** : tous ⇒ catégorie ⇒ marque ⇒ produit;
  - **Lieu** : tous ⇒ pays ⇒ province ⇒ ville ⇒ code postal.
- Ou multiples:



Modélisation multi-dimensionnelle

Hiérarchies dimensionnelles



Modélisation multi-dimensionnelle

Dimension temporelle

Dimension: Temps
idDate (PK)
date
jourDeSemaine
jourDuMois
jourDeAnnée
jourDansMoisFiscal
jourDansAnnéeFiscale
congéFérié
jourDeTravail
semaineDuMois
...

- Mettre toutes ces valeurs, même si la plupart peuvent être déduites d'une seule colonne;
- Pré-générer les lignes de la table (ex: 10 prochaines années) pour faciliter la référence et éviter les mises à jour

Modélisation multi-dimensionnelle

- La modélisation multi-dimensionnelle peut être effectuée à l'aide de deux types de schémas :
  - Schéma en **étoile**
  - Schéma en **flocon de neige**
  - Schéma en **constellation**

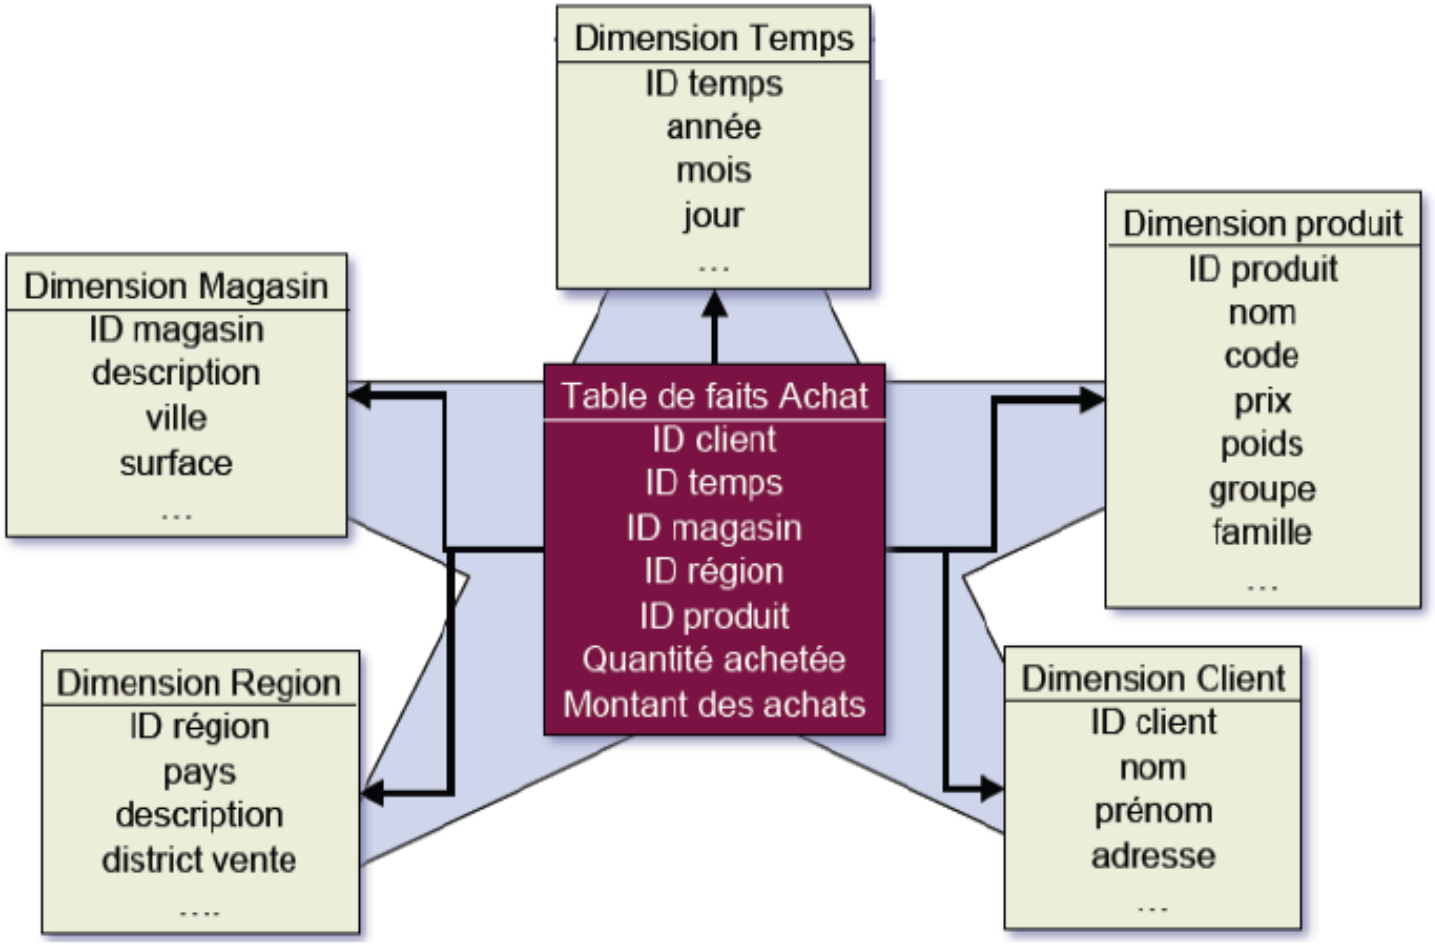
Modélisation multi-dimensionnelle

Modèle en étoile

- Une table de fait centrale et des dimensions
- Les dimensions n'ont pas de liaison entre elles
- Avantages :
  - Facilité de navigation
  - Nombre de jointures limité
- Inconvénients :
  - Redondance dans les dimensions
  - Toutes les dimensions ne concernent pas les mesures

Modélisation multi-dimensionnelle

Modèle en étoile



Modélisation multi-dimensionnelle

Modèle en flocon

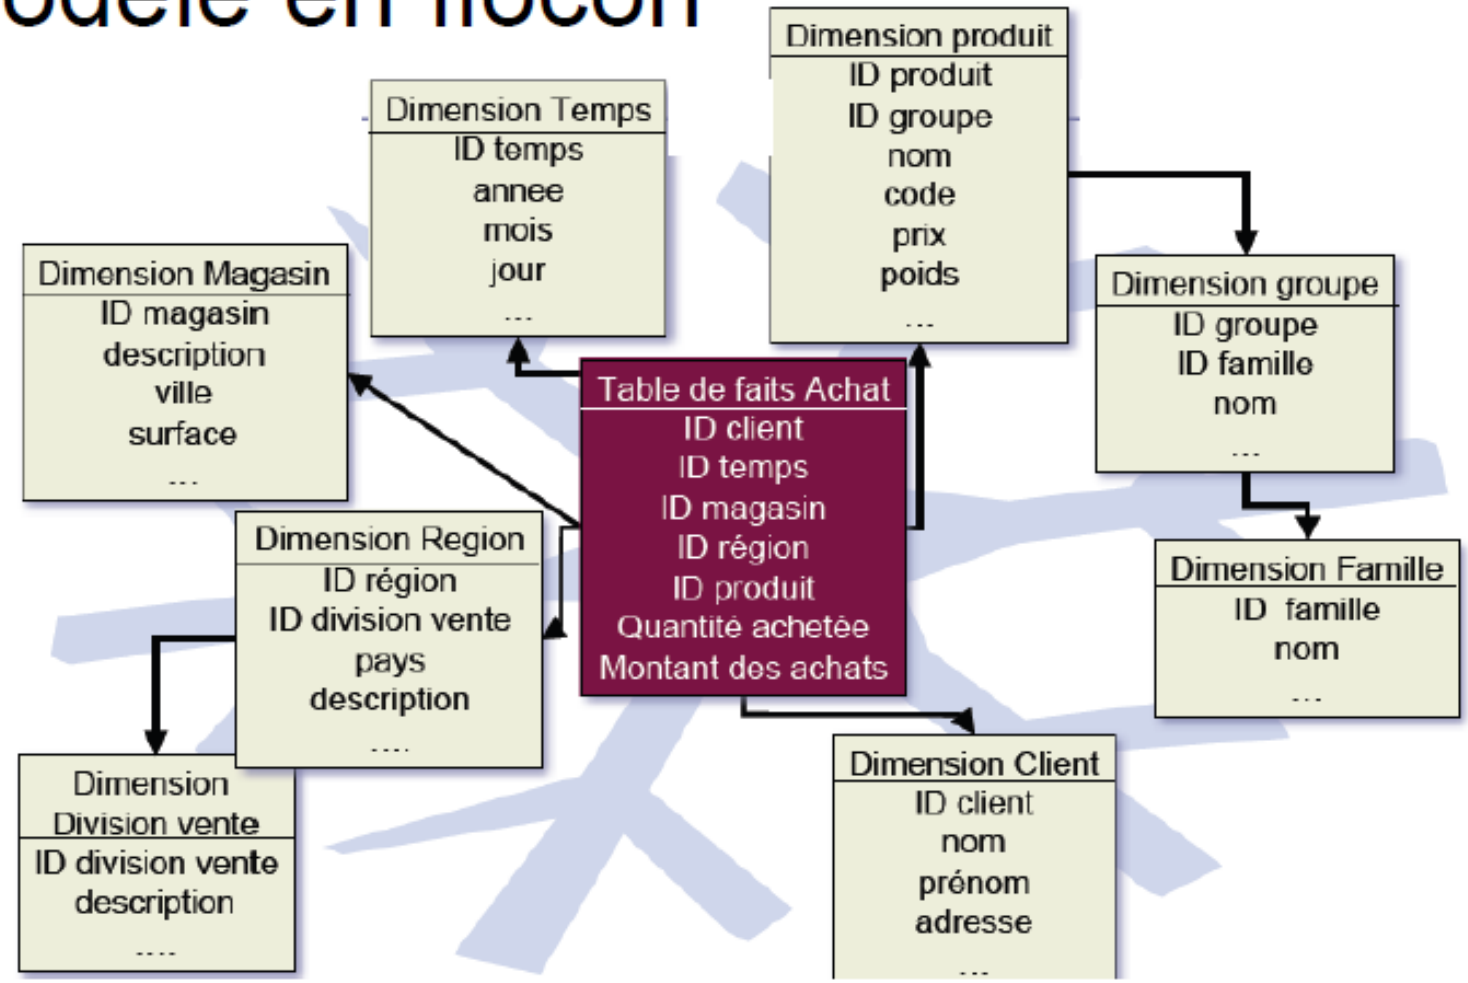
- Modèle en étoile + normalisation des dimensions
  - Une table de fait et des dimensions en sous-hiérarchies
  - Un seul niveau hiérarchique par table de dimension
  - La table de dimension de niveau hiérarchique le plus bas est reliée à la table de fait (elle a la granularité la plus fine)

- Avantages :
  - Normalisation des dimensions
  - Economie d'espace disque (réduction du volume)

- Inconvénients :
  - Modèle plus complexe (nombreuses jointures)
  - Requêtes moins performantes
  - Navigation difficile

Modélisation multi-dimensionnelle

Modèle en flocon



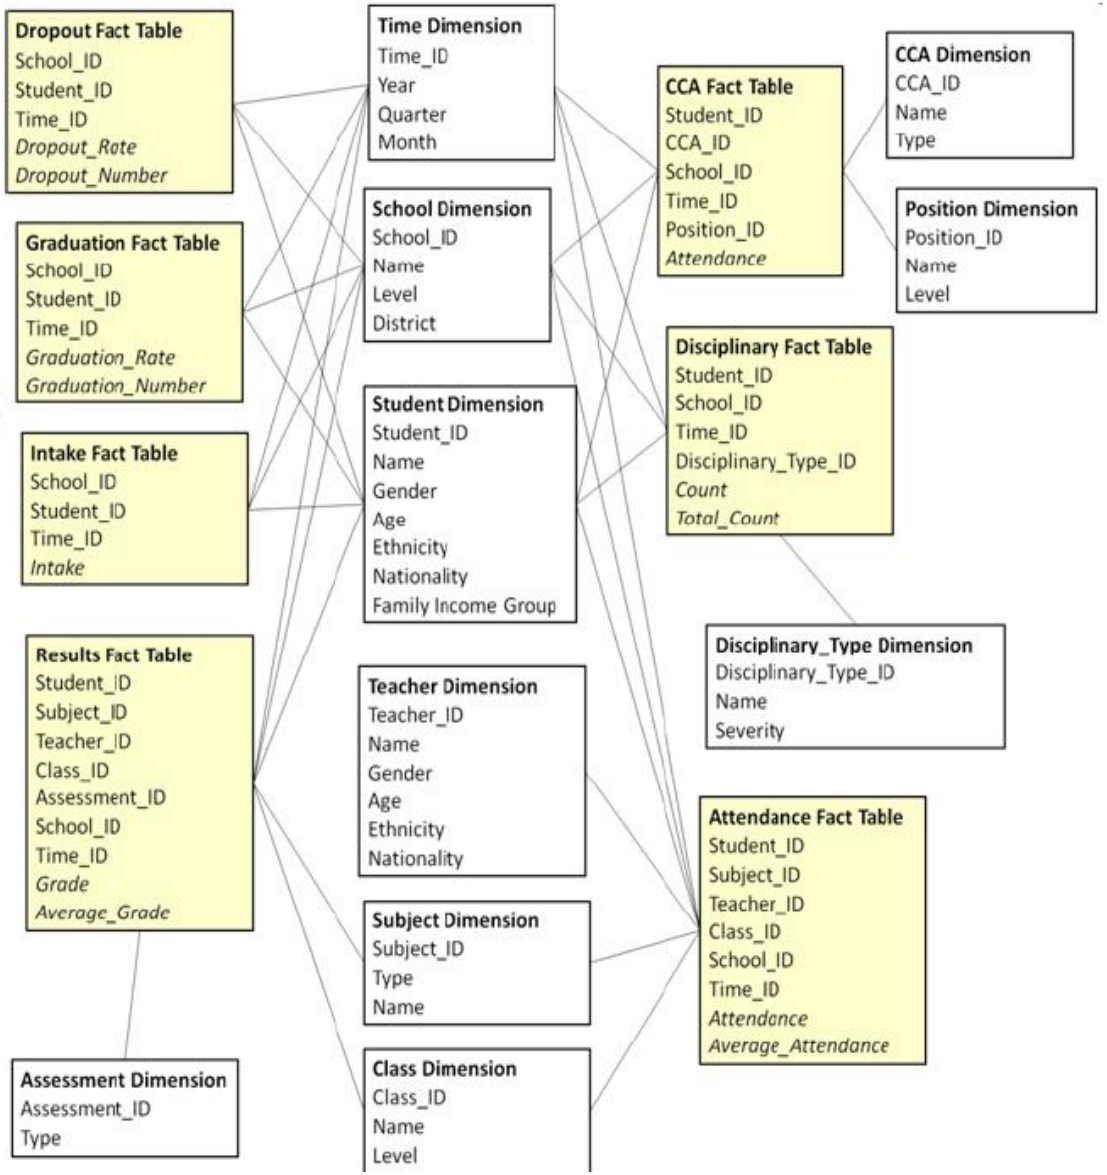
Modélisation multi-dimensionnelle

Constellation

- Série d'étoiles
  - Fusion de plusieurs modèles en étoile qui utilisent des dimensions communes
  - Plusieurs tables de fait et tables de dimensions, éventuellement communes

Modélisation multi-dimensionnelle

Constellation



Éléments de la modélisation des données décisionnelles

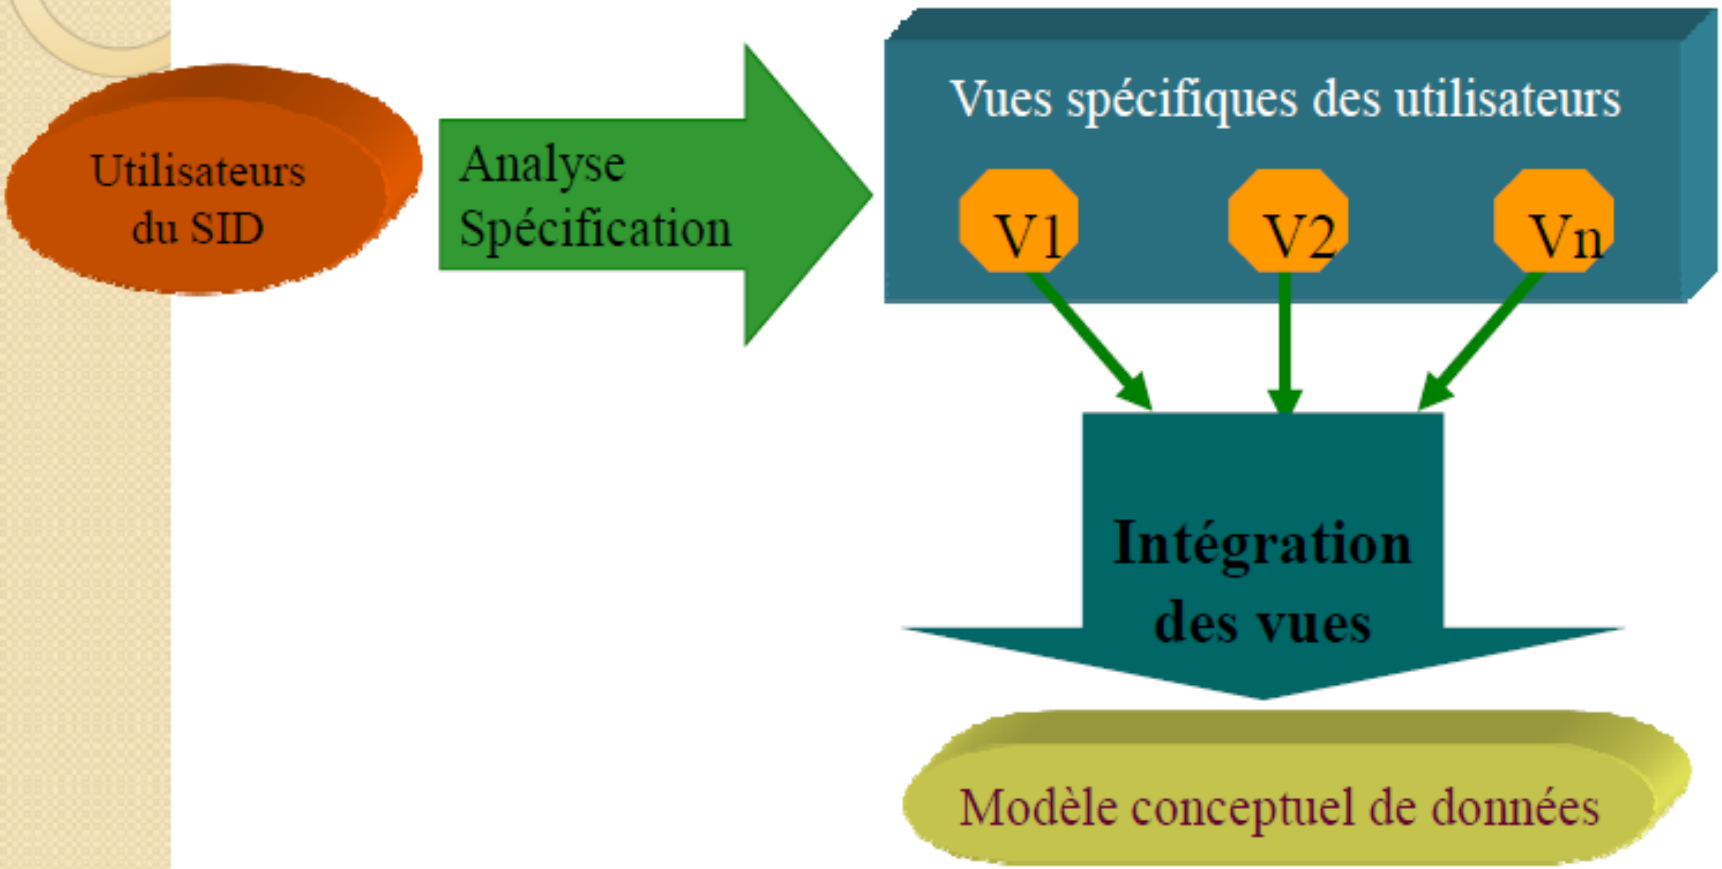
« L'activité de l'utilisateur décisionnel est la recherche de mesures déterminées par des corrélations et des consolidations sur des ensembles de données définis indépendamment des modalités actuelles du fonctionnement de l'entreprise. »(*)

(*) J-M. Gourné, « Le projet décisionnel », Editions Eyrolles, 1998

Éléments de la modélisation des données décisionnelles

- La modélisation des données décisionnelles se base sur les concepts suivants :
  - Vue
  - Fait
  - Dimension
  - Contexte
  - Domaine

Démarche de construction d'un MDD



Règles d'élaboration et d'intégration des vues

- Compte tenu de la nature consultative et non transactionnelle des applications OLAP, la structure des vues externes se déduit directement des requêtes des utilisateurs, et non des connexions possibles entre les entités.
- A l'intérieur d'un domaine, il existe un ou plusieurs sous-ensembles de vues liées entre elles par certains critères de cohérence sémantique et structurelles. Ces sous-ensembles sont appelés contextes.

Règles d'élaboration et d'intégration des vues

- Une requête décisionnelle a pour objet d'établir un rapprochement entre des entités plus ou moins nombreuses. Les résultats attendus sont systématiquement déterminés par des associations.
- Chaque vue a pour élément central une association autour de laquelle gravitent deux ou plusieurs entités, et correspond à une représentation des informations sous forme de tableau à deux ou plusieurs dimensions.

Règles d'élaboration et d'intégration des vues

- La liste exhaustive des requêtes possibles (et donc des vues) n'est jamais figée.
  - La normalisation du MDD permet d'anticiper et d'intégrer automatiquement dans chaque contexte le plus grand nombre possible de «vues probables» d'après la structure des «vues connues».
- Entre deux entités intervenant dans une même vue, il doit exister un et un seul chemin de navigation sémantique, et ce chemin doit être le plus court possible.

Notion de domaine

- Un domaine concerne un utilisateur ou un ensemble cohérent d'utilisateurs, et implique un vocabulaire commun et une manière commune d'appréhender l'information.
- Exemples :
  - Domaine financier,
  - Domaine GRH,
  - Domaine commercial, …

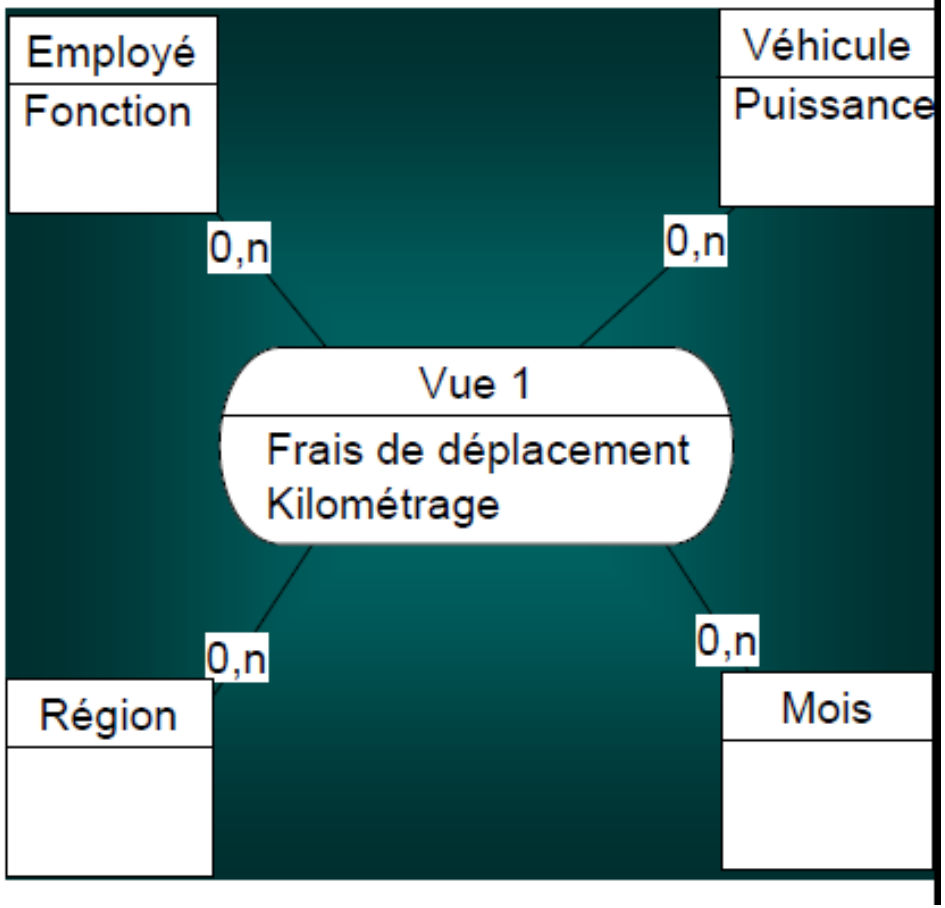
Notion de vue

- C'est la représentation d'une ou plusieurs requêtes de l'utilisateur du SID.
- A une requête correspond une et une seule vue.
- A une vue peuvent correspondre plusieurs requêtes

Exemple

Requête :
« Quels ont été les frais de déplacement et le kilométrage des commerciaux de la région Nord ayant des véhicules de 10 à 14 CV en avril 2004 ? »

Vue correspondante :
Frais de déplacement, kilométrage
Par Employé (fonction)
Par Véhicule (puissance)
Par Région
Par Mois



Notion de Fait et de Condition

- Une vue est représentée par une association entre deux ou plusieurs entités.
- Les propriétés de l'association sont des faits (ou mesures).
- Les propriétés des entités intervenant dans la vue sont des conditions.

Cardinalité dans une vue

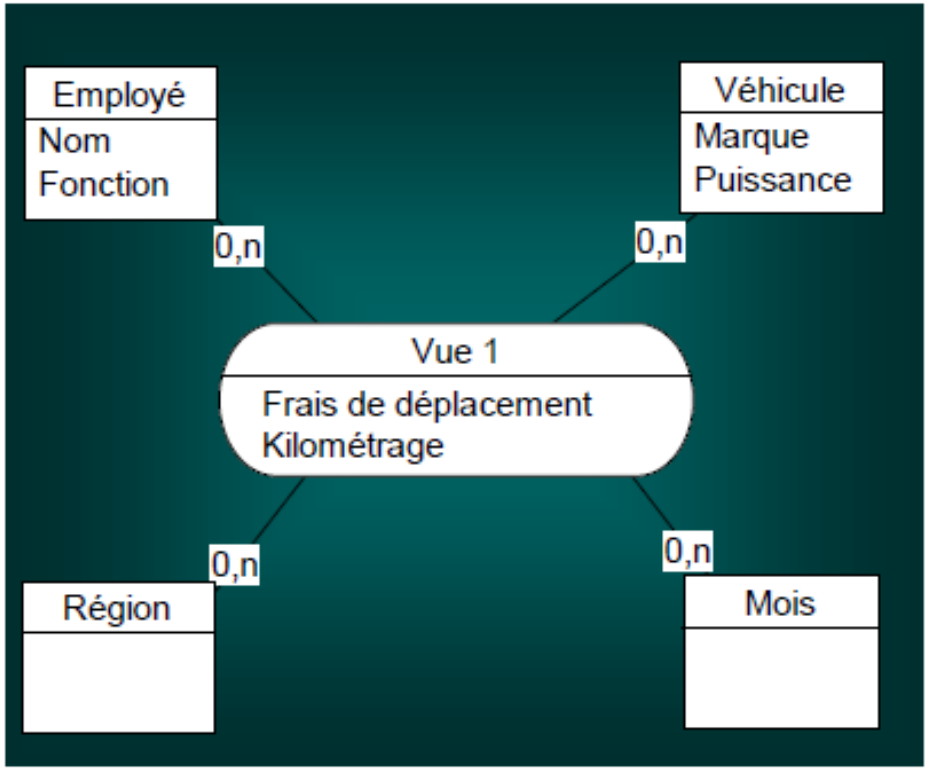
- Les cardinalités de l'association représentant une vue sont toujours de type (0, n) ou (1, n).
- Différence entre (0, n) et (1, n) : uniquement au niveau sémantique, aucune conséquence pratique.

Règle

- Un fait n'est pas seulement un élément du résultat de la requête, mais il doit être déterminé par l'association des conditions.

« Donner la liste des noms des commerciaux de la région Nord ayant des véhicules de 10 à 14 CV avec, pour chacun, les frais de déplacement, le kilométrage et la marque du véhicule, pour le mois de juillet 2003 »

Frais de déplacement, kilométrage
/ Employé (nom, fonction)
/ Véhicule (marque, puissance)
/ Région
/ Mois

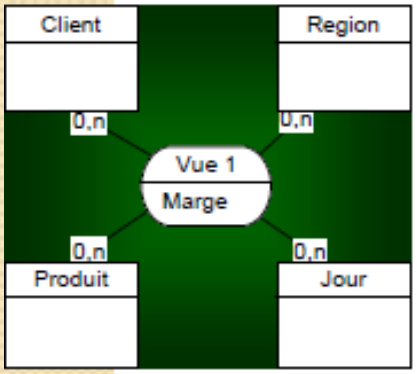


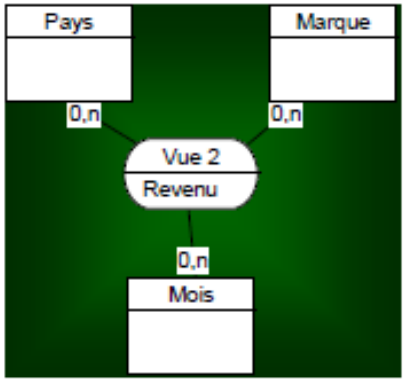
Notion de contexte

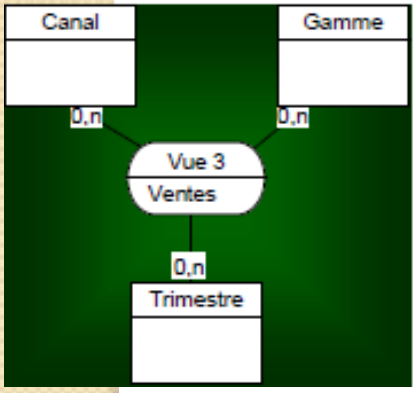
- C'est un niveau intermédiaire entre la vue et le domaine.
- Un contexte et un ensemble de faits et de conditions assemblés selon des critères sémantiques de cohérence.
- Un contexte (comme une vue), est caractérisé par une association unique, groupant tous les faits relevés dans un ensemble cohérent de vues.
- Certaines des entités qui gravitent autour de l'association peuvent être liées par des dépendances fonctionnelles de type hiérarchique.

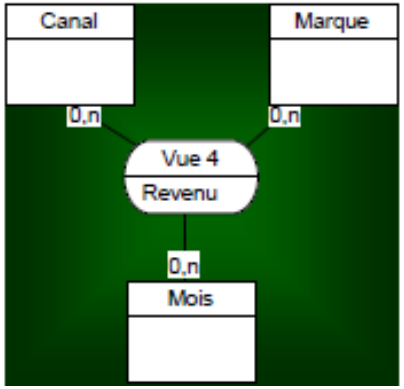
Notion de contexte
Exemple

Soient les quatre vues suivantes :









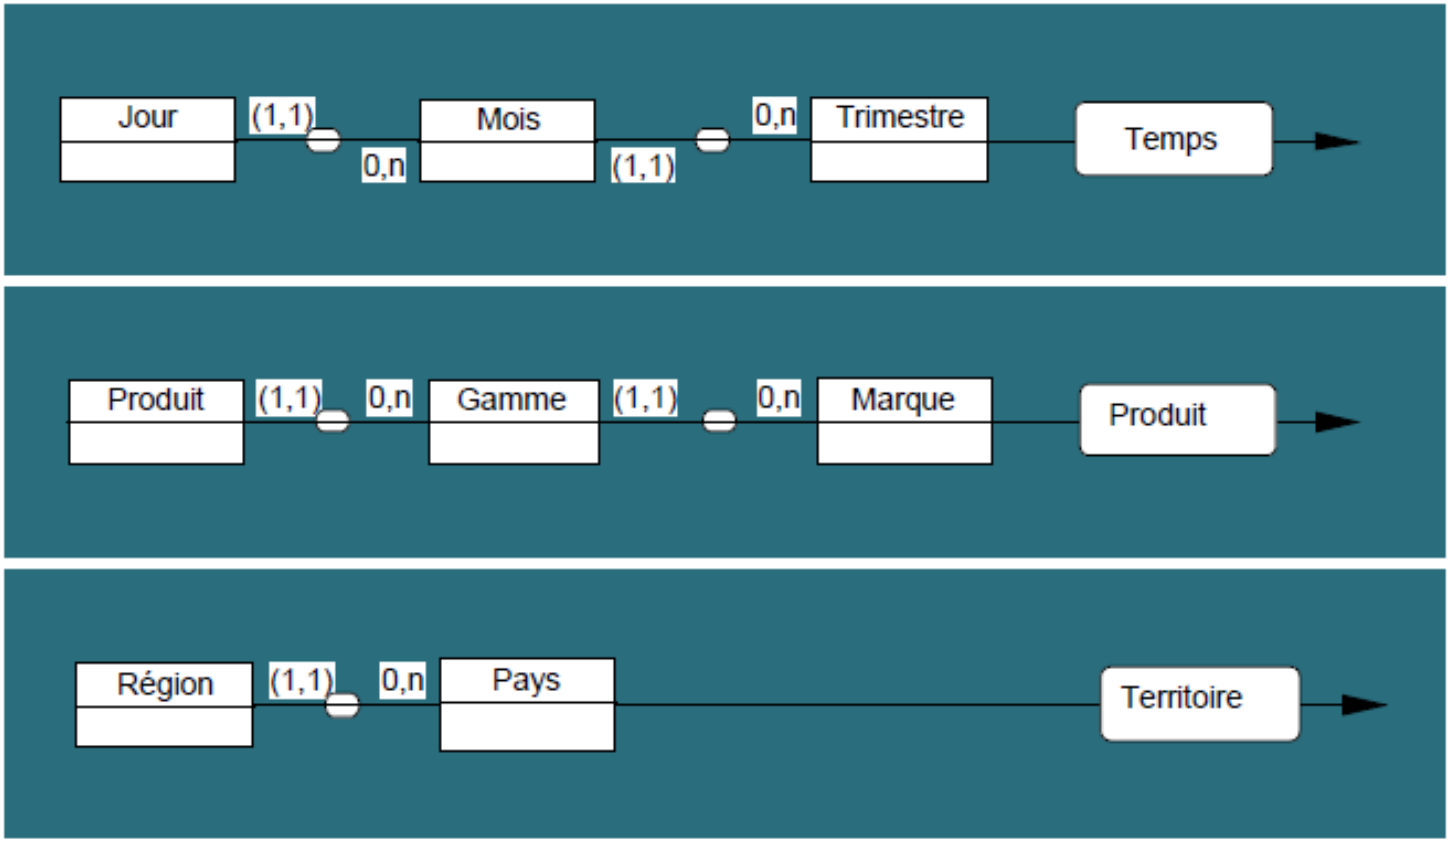
Constatations :

- Certaines informations, entités ou faits, se trouvent dans plusieurs vues.
- Certaines entités, appartenant à des vues différentes, sont fonctionnellement liées les unes aux autres.

Notion de hiérarchie

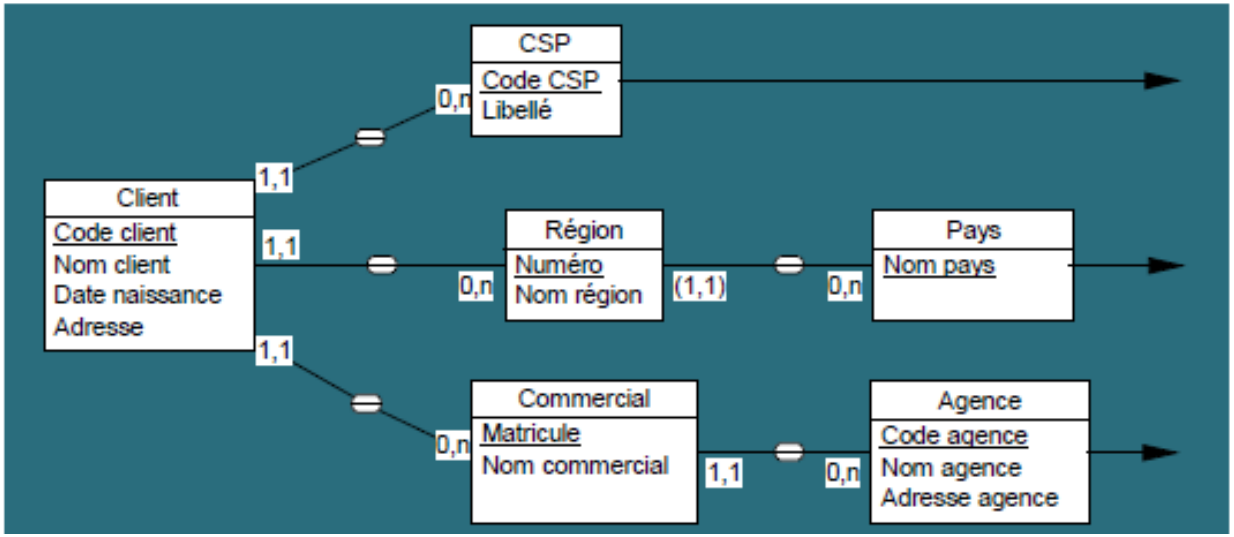
- Dans un contexte données, certaines entités peuvent être liées par des liens d'appartenance ou de regroupement hiérarchique.
- Les hiérarchies représentent pour les utilisateurs des chemins de consolidation d'indicateurs.

Notion de hiérarchie
Exemple



Hiérarchie et dimension

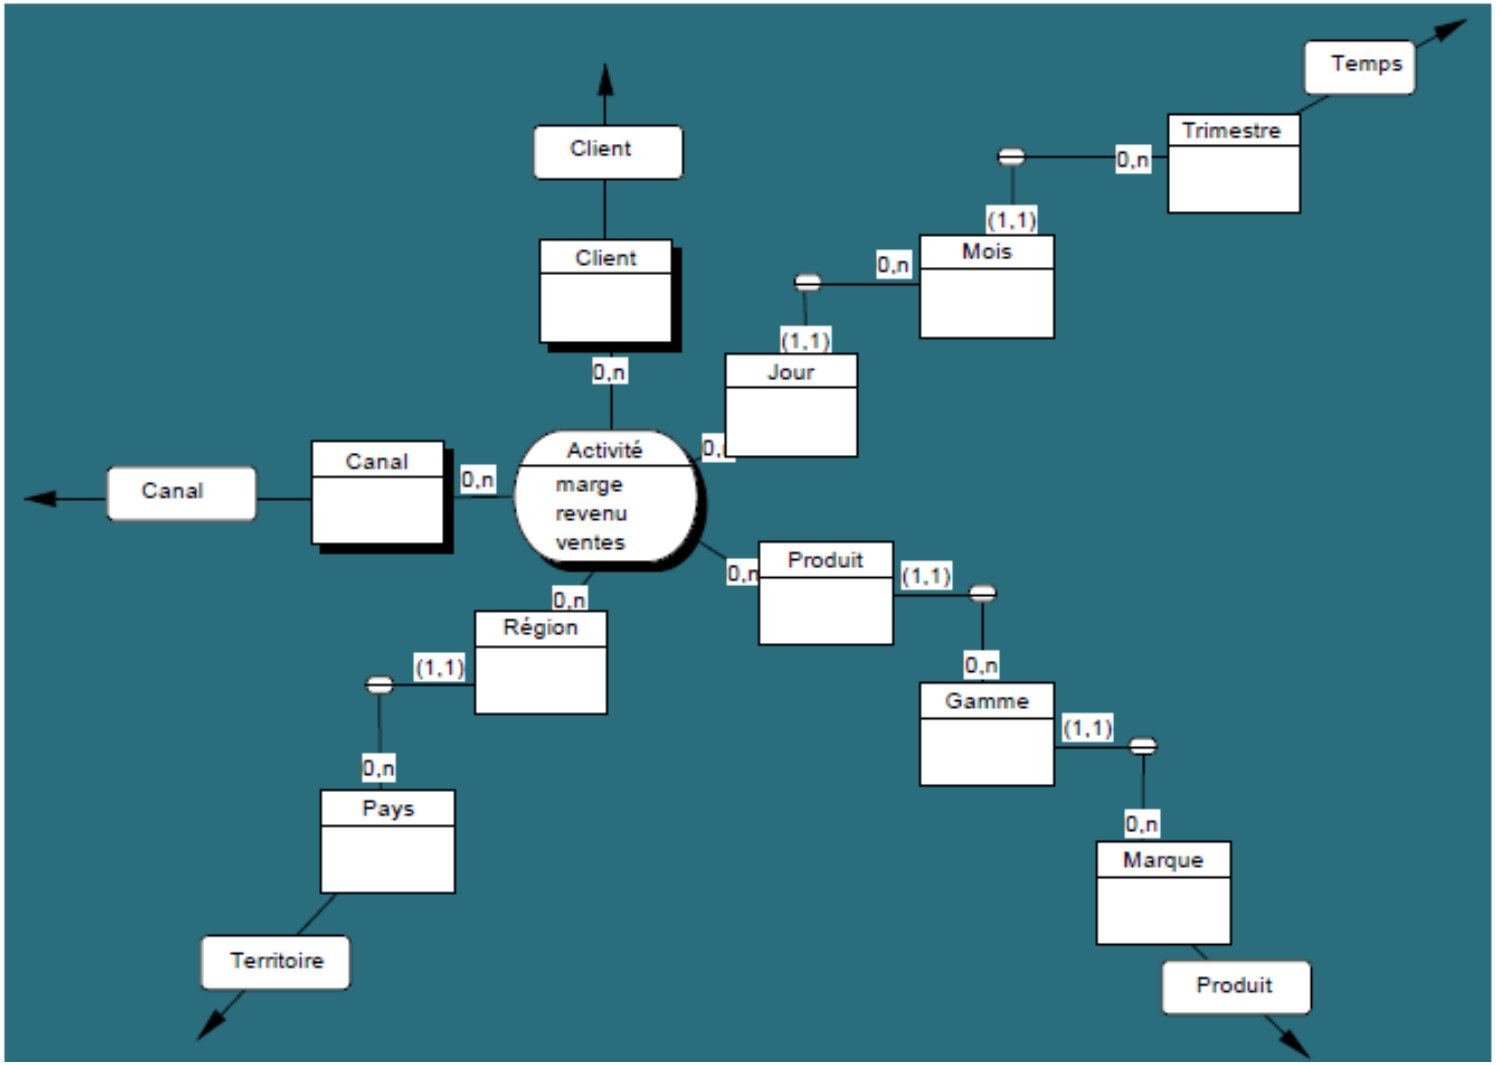
- Généralement une hiérarchie correspond à une dimension.
- Dans certains cas, une même dimension peut comporter une ramification de hiérarchies.



Démarche de synthèse de vues en contextes

- Identifier les faits de l'association
- Identifier les liens de dépendance entre les entités.
- Regrouper les entités dépendantes dans une même dimension.
- Nommer les dimensions :
  - Les dimensions pour lesquelles on trouve facilement un nom sont dites «Dimensions fortes».
  - Celles pour lesquelles on doute du nom associé sont dites «Dimensions douteuses».
  - La structure d'une dimension douteuse peut varier à terme.

Exemple


Temps
Trimestre
0,n
(1,1)
Mois
0,n
(1,1)
Jour
Client
Client
0,n
Canal
Canal
0,n
Activité
marge
revenu
ventes
0,n
Produit
(1,1)
0,n
Gamme
(1,1)
0,n
Marque
Produit
0,n
Région
(1,1)
0,n
Pays
Territoire

Normalisation des contextes

- Un contexte regroupant un nombre élevé de dimensions a peu de chance de correspondre à une réalité et serait d'un maniement trop complexe.
- En général, le nombre de dimensions d'un contexte varie entre 4 et 12 dimensions.
- Au delà de ce nombre, la probabilité de redondance dimensionnelle devient de plus en plus importante.
- Un contexte est dit cohérent lorsque toutes les vues qu'il autorise ont une signification dans le domaine de l'utilisateur.

Règles de normalisation dimensionnelle

Règle 1 : *Il ne doit pas y avoir de dépendance fonctionnelle entre deux entités appartenant à des dimensions différentes d'un même contexte.*

Conséquence : Regroupement des entités dépendantes dans une même dimension.

Exemple : Si les canaux commerciaux sont organisés par région, on doit intégrer l'entité «Canal» dans la dimension «Territoire».

Règles de normalisation dimensionnelle

Règle 2 : Tous les faits d'un contexte doivent être définis d'une manière cohérente pour toutes les combinaisons dimensionnelles de ce contexte.

Conséquence : Les faits qui ne sont valables que pour certaines dimensions nécessitent l'éclatement du contexte.

Règles de normalisation dimensionnelle

Règle 3 : Tous les faits d'un contexte doivent être définis pour le grain de ce contexte.

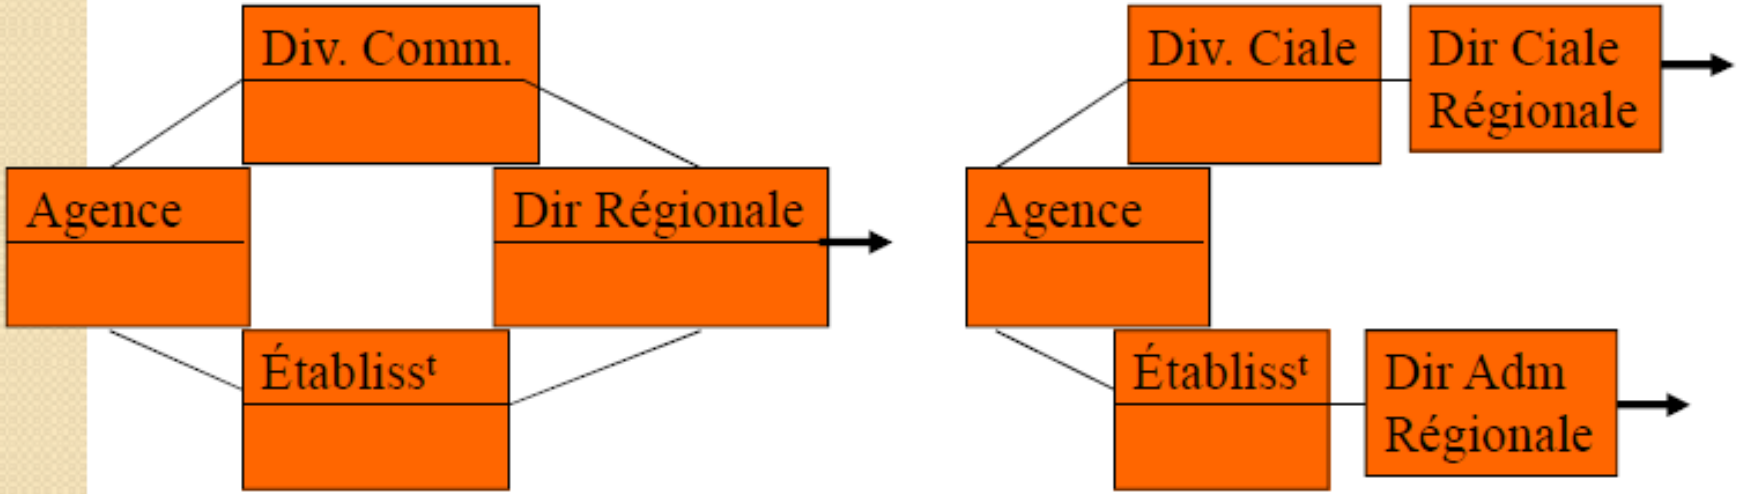
Le **grain d'un contexte** découle de la combinaison des grains de toutes les dimensions.

Le **grain d'une dimension** est le niveau de sélection le plus fin possible de cette dimension.

Règles de normalisation dimensionnelle

Règle 4 : Le graphe de chaque dimension doit être acyclique.
Conséquence : Rompre des cycles.

Exemple :



Forme dimensionnelle normale

- Lorsqu'un contexte respecte les quatre règles, il est dit en forme dimensionnelle normale (FDN).
- Un MDD en FDN présente les particularités suivantes :
  - Il est acyclique : pas de navigation entre les contextes. Une requête porte toujours sur un seul contexte.
  - Les seules associations porteuses de propriétés sont celles contenant les faits : pas besoin de préciser les cardinalités et les noms des associations intra dimensionnelles.

Forme dimensionnelle normale

- Le MDD correspondant à un domaine se présente sous forme de constellation ou de «galaxie» dans laquelle chaque «étoile» correspond à un contexte.
- Une même entité ou un même fait peut appartenir à plus qu'un contexte à condition de conserver une définition unique.
- Pour des raisons pratiques, il est préférable de représenter les contextes sous une forme déconnectée.

Etude de cas : Bibliothèque

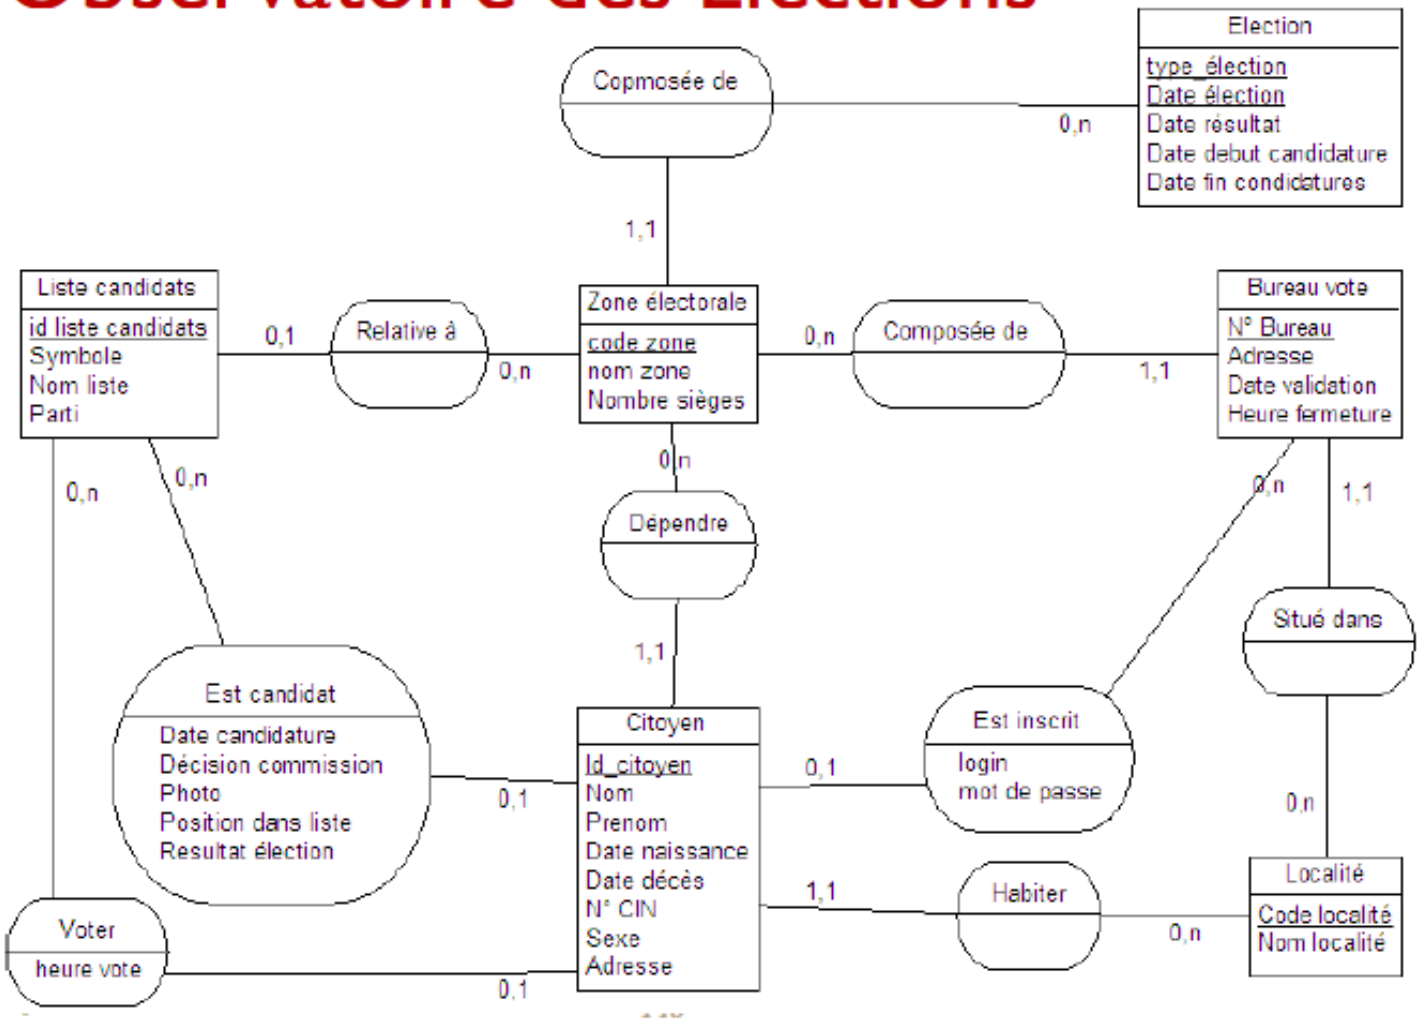
- On souhaite mettre en place un système d'information décisionnel pour une bibliothèque publique.
- Cette bibliothèque dispose d'un ensemble de livres qui sont empruntés par les abonnés. Chaque livre est identifié par un code et dispose d'un titre, un prix d'achat, un nombre de pages, une date d'acquisition et un éditeur. Les livres sont classés en formats (petit, grand, moyen, …) et en spécialités (maths, physique, informatique, …). La bibliothèque dispose de livres écrits dans différentes langues.
- Les abonnés de la bibliothèque sont décrits par un identifient, un nom et prénom, une adresse, une date de naissance, un sexe et une catégorie (élève, étudiant, employé, …).
- L'emprunt des livres est réglementé : un abonné ne peut pas emprunter en même temps plus que trois livres. La durée maximale d'emprunt ne peut pas dépasser 10 jours. Tout retard entraine une sanction égale au nombre de jours de retard. La bibliothèque mémorise l'historique des emprunts (code livre, id abonné, date d'emprunt, date retour et durée de sanction éventuelle).

Etude de cas : Bibliothèque

Les entretiens effectués avec les futurs utilisateurs du système d'information décisionnel ont permis de dégager les requêtes suivantes :

- R1 – Nombre de livres et nombre de pages par spécialité, par format et par langue.
- R2 – Nombre de livres et valeur des livres par année d'acquisition et par éditeur.
- R3 – Nombre de livres empruntés par mois et par catégorie d'abonné.
- R4 – Nombre de livres empruntés par année et par spécialité.
- R5 – Nombre d'abonnés et âge moyen par catégorie et par sexe d'abonné.
- R6 – Nombre d'emprunts par mois et par catégorie d'abonné.
- R7 – Nombre de sanctions par année et par sexe.
- R8 – Nombre d'abonnés sanctionnés par mois et par catégorie d'abonné.
- R9 – Durée moyenne de sanction par trimestre et par catégorie d'abonné.

Etude de cas : Observatoire des Elections



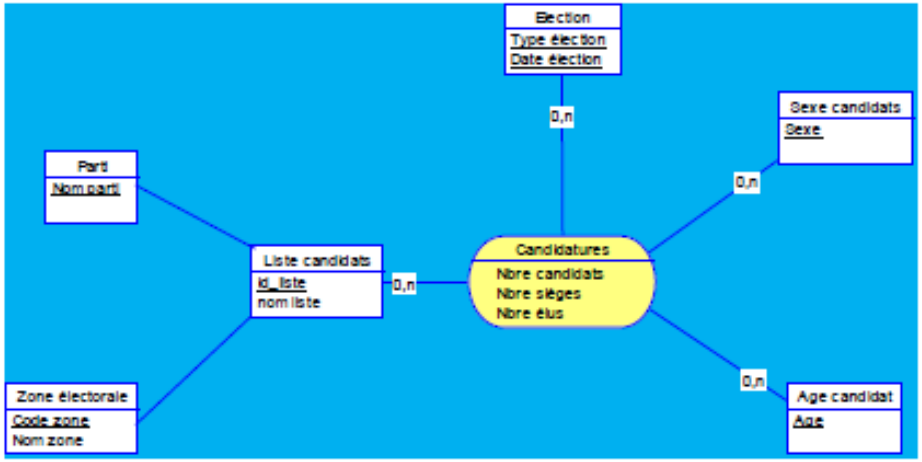
Etude de cas : Observatoire des Elections

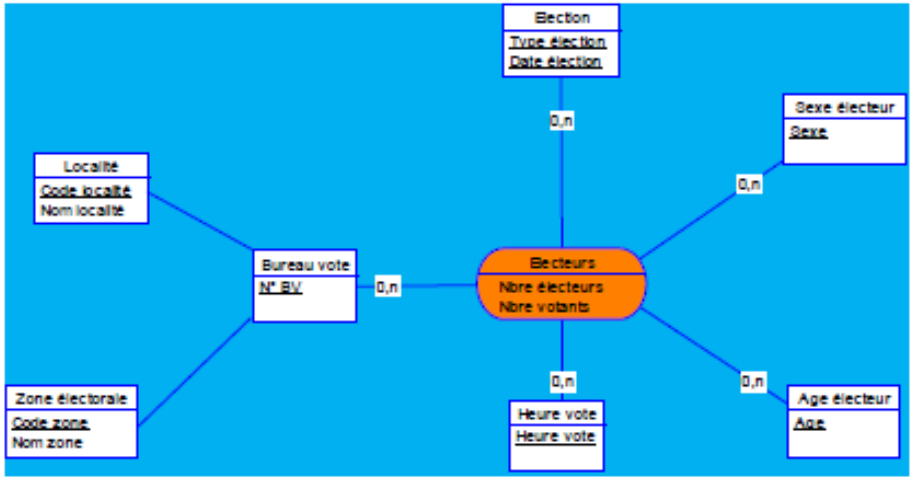
- **Dimensions :**
  - **Liste Candidats :** (id_liste, Nom liste)
  - **Parti :** (Nom Parti)
  - **Election :** (Type élection, Date élection)
  - **Zone :** (Code zone, nom zone)
  - **Sexe candidat :** (sexe)
  - **Age candidat :** (age)
  - **Localité :** (code localité, nom localité)
  - **Bureau vote :** (N° BV)
  - **Sexe électeur :** (sexe)
  - **Age électeur :** (age)
  - **Heure :** (Heure vote)
- **Faits :**
  - Nbre candidats
  - Nbre sièges
  - Nbre élus

  Candidatures
  - Nbre électeurs
  - Nbre votants

  Electeurs

Etude de cas : Observatoire des Elections



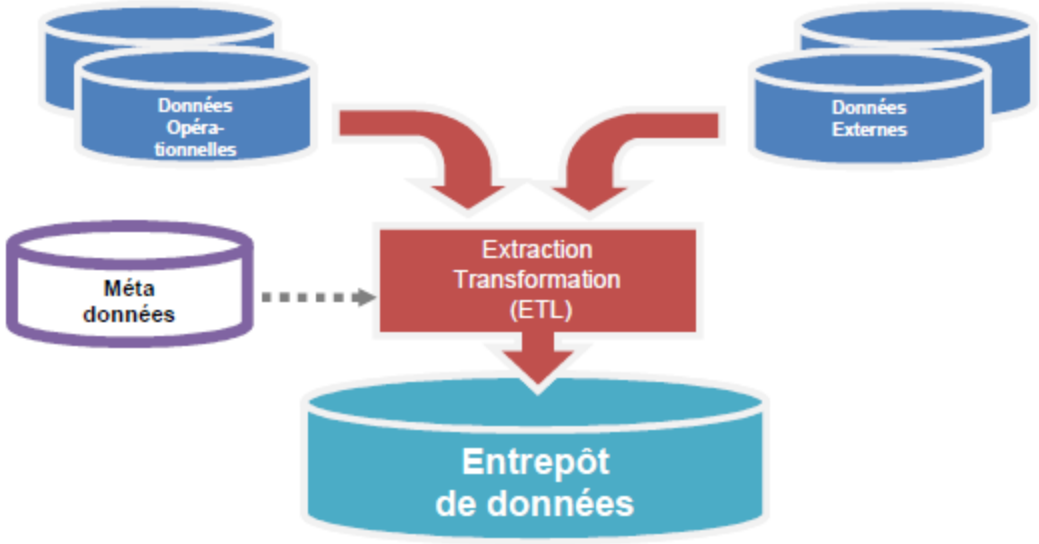


Chapitre 6

ETL
Extraction, Transformation et Chargement de données

Introduction

- L'ETL est une couche logicielle responsable de l'alimentation d'une base de données à partir de sources de données.
- Dans un SID, l'ETL sert à alimenter l'ED ou bien les magasins de données (data marts).
- L'ETL fait partie des middlewares (intergiciels)

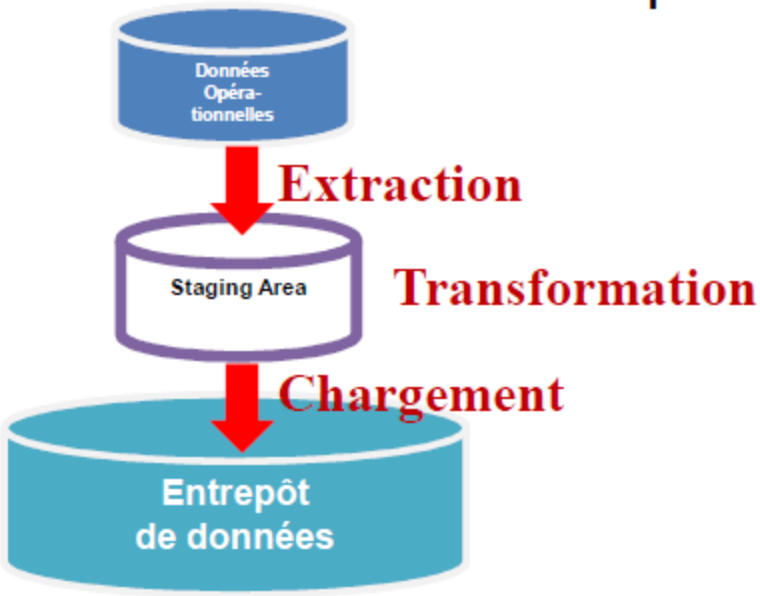


Importance de l'ETL

- Constitue 70 à 80% du temps passé dans un projet décisionnel
- La qualité de l'ED dépend de la qualité de l'ETL :
  - Temps de chargement
  - Fréquence de chargement
  - Qualité des données (QoD)
  - Qualité des services (QoS)

Staging area (zone tampon)

- C'est une zone intermédiaire entre les donnés sources et l'ED.
- Elle sert à stocker les données temporaires.



Extraction

- Extraction des données à partir des sources (BD ou Fichiers) dans le but d'alimenter les tables de faits et les tables de dimensions.
- Les données sont stockées dans des tables temporaires (staging area)

Stratégies d'extraction

- Trois stratégies d'extraction :
  - **Push :** La logique applicative de l'extraction se trouve dans le système source. Elle pousse les données vers la zone d'attente.
  - **Pull :** La logique applicative de l'extraction se trouve dans le système cible (ED). Elle «tire» les données vers la zone d'attente.
  - **Push-Pull :** C'est une combinaison des deux stratégies précédentes.

Transformation

- C'est l'étape intermédiaire entre l'**extraction** et le **chargement**
- Elle consiste à :
  - Transformer les données sources selon les unités de mesure et les formats de l'ED
  - Homogénéiser les données sources
  - Nettoyer les données
  - Dater les données
  - Créer des clés
- Exemples :
  - (m, f), (0, 1), (male, female) → (m, f)
  - TND, EURO, USD → TND
  - CHAR(10), NUMBER(12) → CHAR(20)

Transformation

- Cas de non-conformité des sources différentes.
- Exemple :
  - Source 1 : Secteur Est, Secteur Ouest
  - Source 2 : Secteur Nord, Secteur Sud

Chargement

- Chargement des données de la zone tampon vers l'ED
- Ordre de chargement :
  1. Tables de Dimensions
  2. Tables de Faits
- Optimisations possibles :
  - Désactivation / réactivation des index
  - Chargement parallèle
  - Partitionnement

Fréquence de l'ETL

- Dépend de :
  - la granularité de la dimension Temps
  - La disponibilité des données sources
  - La fréquence d'utilisation de l'ED
- Dans certains cas, pour gagner du temps, on peut avoir une fréquence de chargement inférieure à celle de la granularité de la dimension temps.
- Exemple :
  - Granularité Temps = mois
  - Fréquence de chargement = jour

Cycle de vie de l'ETL

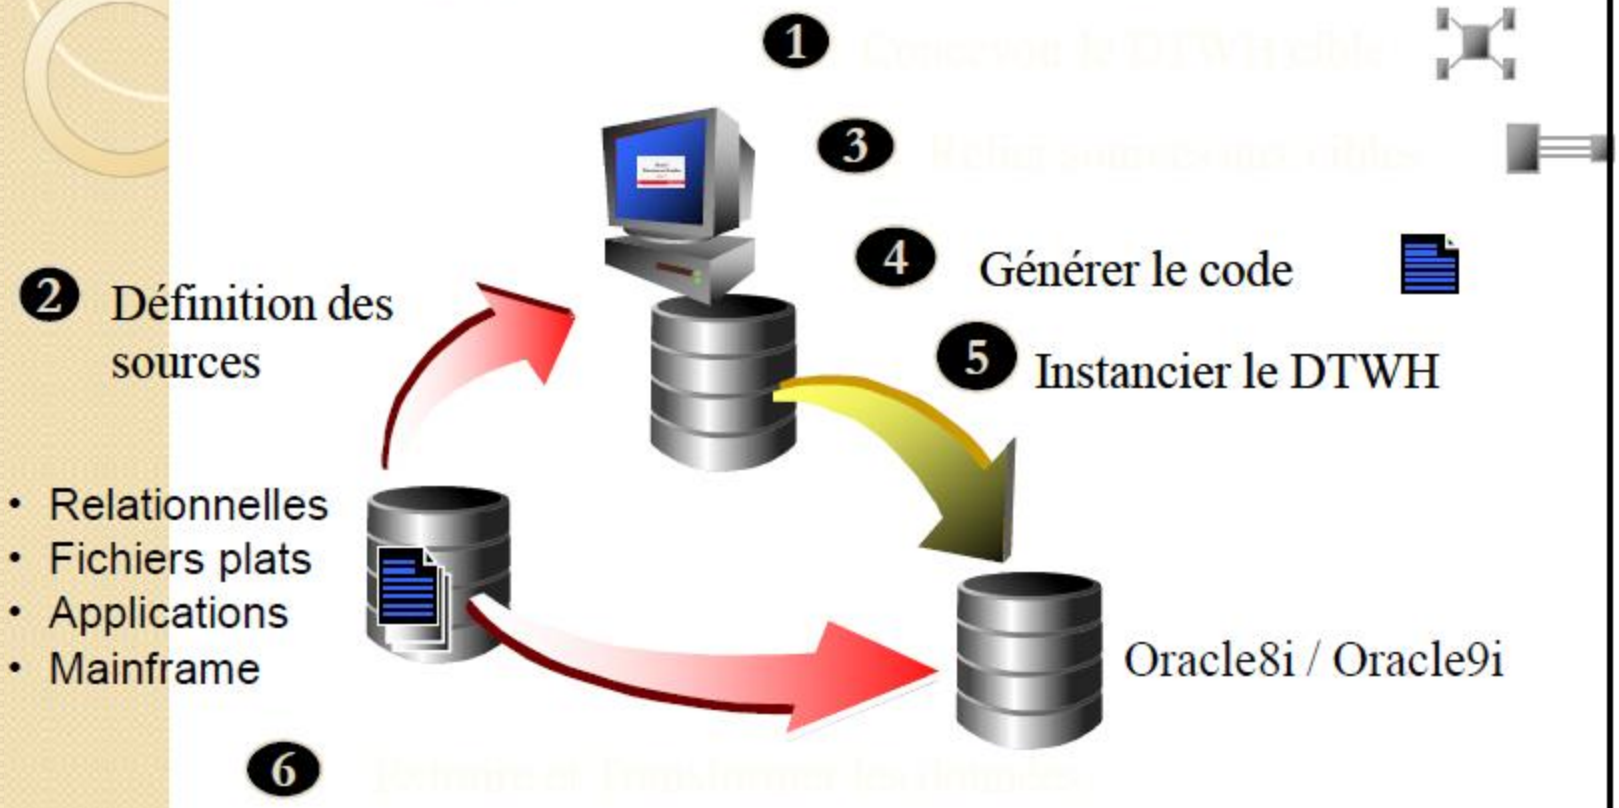
- La mise en place de l'ETL passe par les étapes suivantes :
  1. **Conception de l'ETL :**
     - Identification des sources de données
     - Correspondance des données
     - Définition des transformations
     - Structure de la zone d'attente
  2. **1er chargement :**
     - Chargement de toutes les données sources
  3. **Rafraichissement de l'ED :**
     - Chargement périodique des données
- Mise à jour de l'ETL lorsque les structures sources ou cibles changent

Outils ETL

- **Sans outils :**
  - Commandes SQL et utilitaires du SGBD source et cible
  - Programmation (PL/SQL)
- **Outils propriétaires :**
  - Oracle Warehouse Builder
  - IBM DB2 Warehouse Manager
  - Microsoft Integration Services
  - …
- **Open source :**
  - Talend Open studio
  - Pentaho Data Integration
  - …

Oracle Warehouse Builder

Concevoir et déployer



Oracle Warehouse Builder

Sources et Cibles

- Bases de données cibles
  - Oracle8*i*
  - Oracle9*i*
- Data Sources
  - Oracle
  - Fichiers plats
  - ODBC
  - SAP R/3 *
  - DB2, Sybase, Informix, SQL Server (Oracle Transparent Gateways)
  - Mainframe (Oracle Pure Extract)

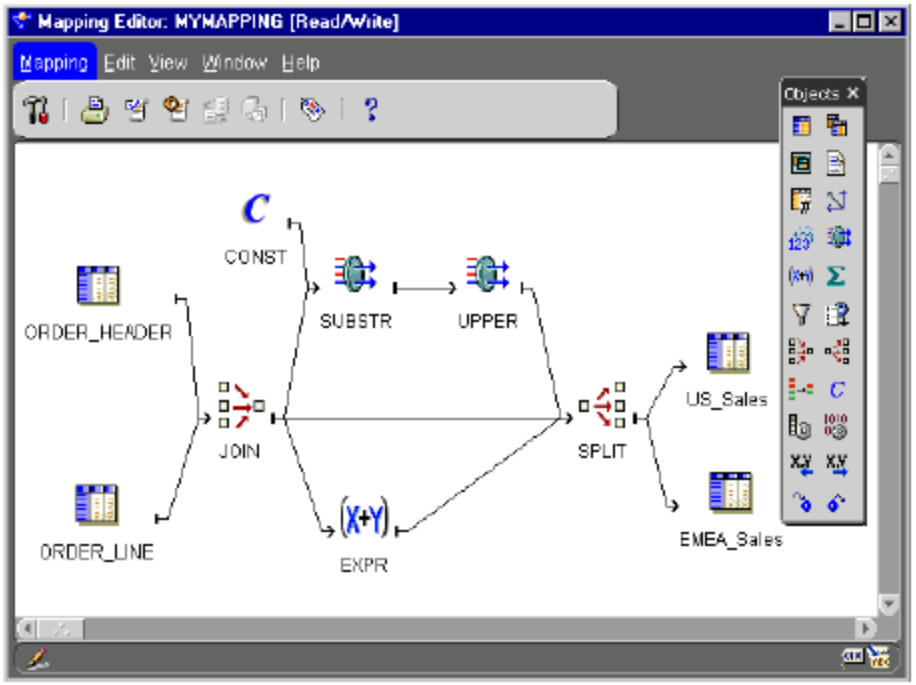
* In Oracle Warehouse Builder 3i Release 2 (Oracle 9i DS release 2)

Oracle Warehouse Builder

Mapping Sources / Cibles

- Joiner
- Filter
- Aggregator
- Deduplicator
- Sorter
- Splitter
- Sequence
- Inline Expressions
- Transformations
- Pre/Post Mapping Process

Editeur de Mapping



Oracle Warehouse Builder

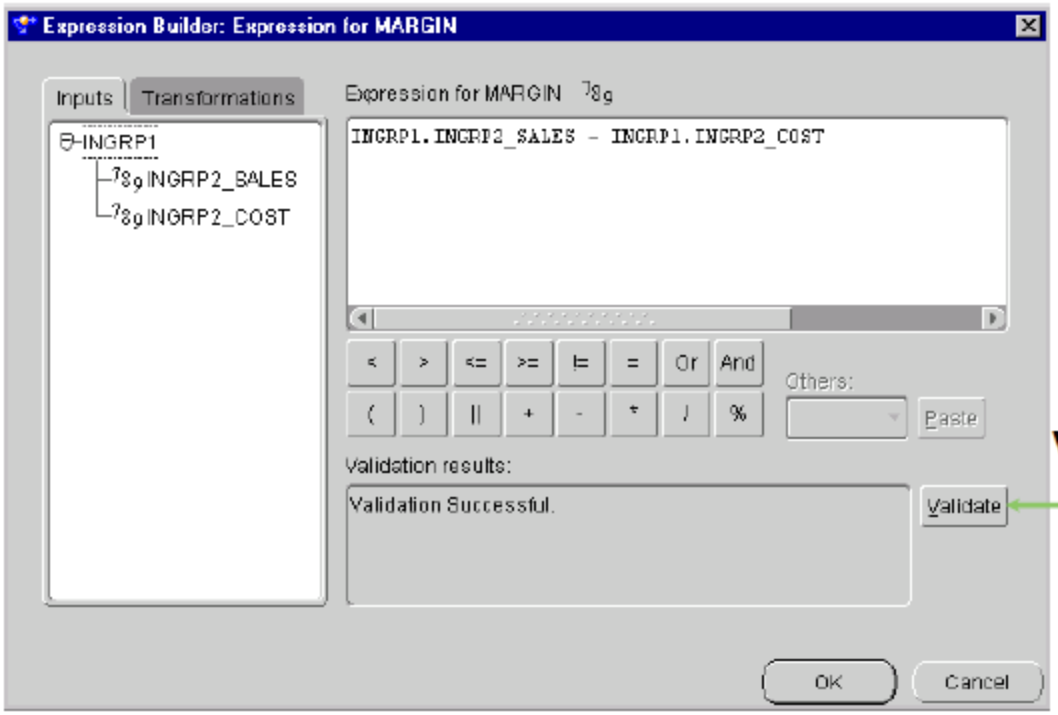
Transformations

- Transformations gérées avec l'interface Expression Builder
- Transformations pré-packagées
  - Toutes les fonctions scalaires du SQL Oracle
  - Plus de 40 fonctions et procédures OWB
    - WB_DISABLE_ALL_CONSTRAINTS
    - WB_TRUNCATE_TABLE
    - …
- Ecriture de transformations personnalisées en PL/SQL
- Partage et ré-utilisation via la Global-Shared-Library

Oracle Warehouse Builder

Transformations

OWB3i Expression Builder



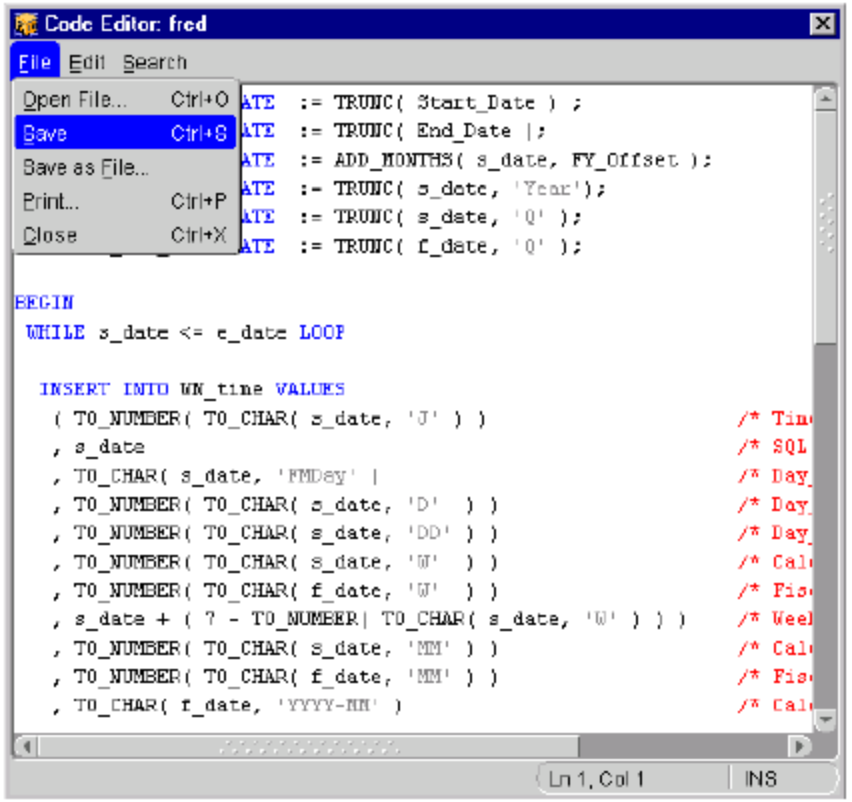
Vérification de syntaxe

Oracle Warehouse Builder

Editeur de code PL/SQL

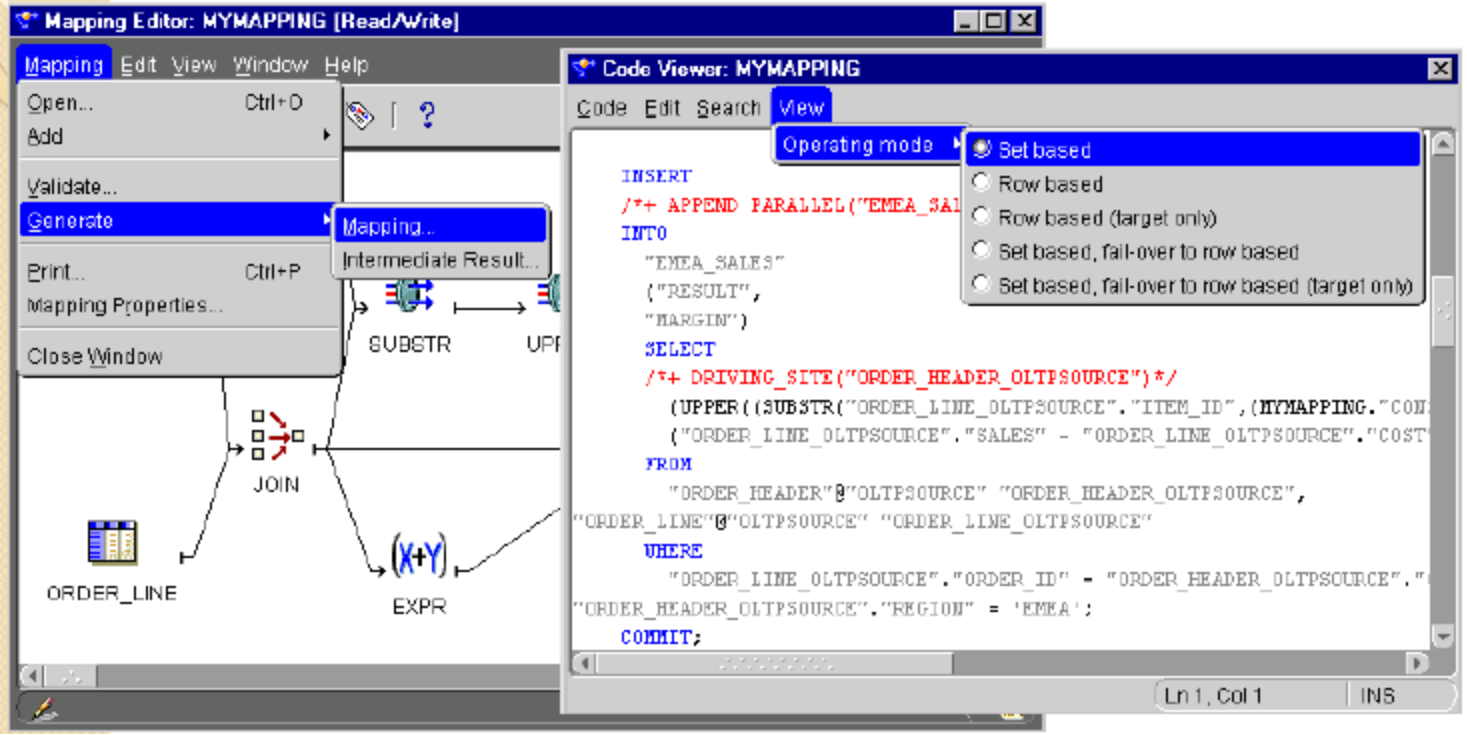
L'éditeur de code supporte:

- **Lecture / Ecriture de fichiers**
- **Impression**
- **Rechercher / Remplacer**
- **Mise en évidence des mots clés**



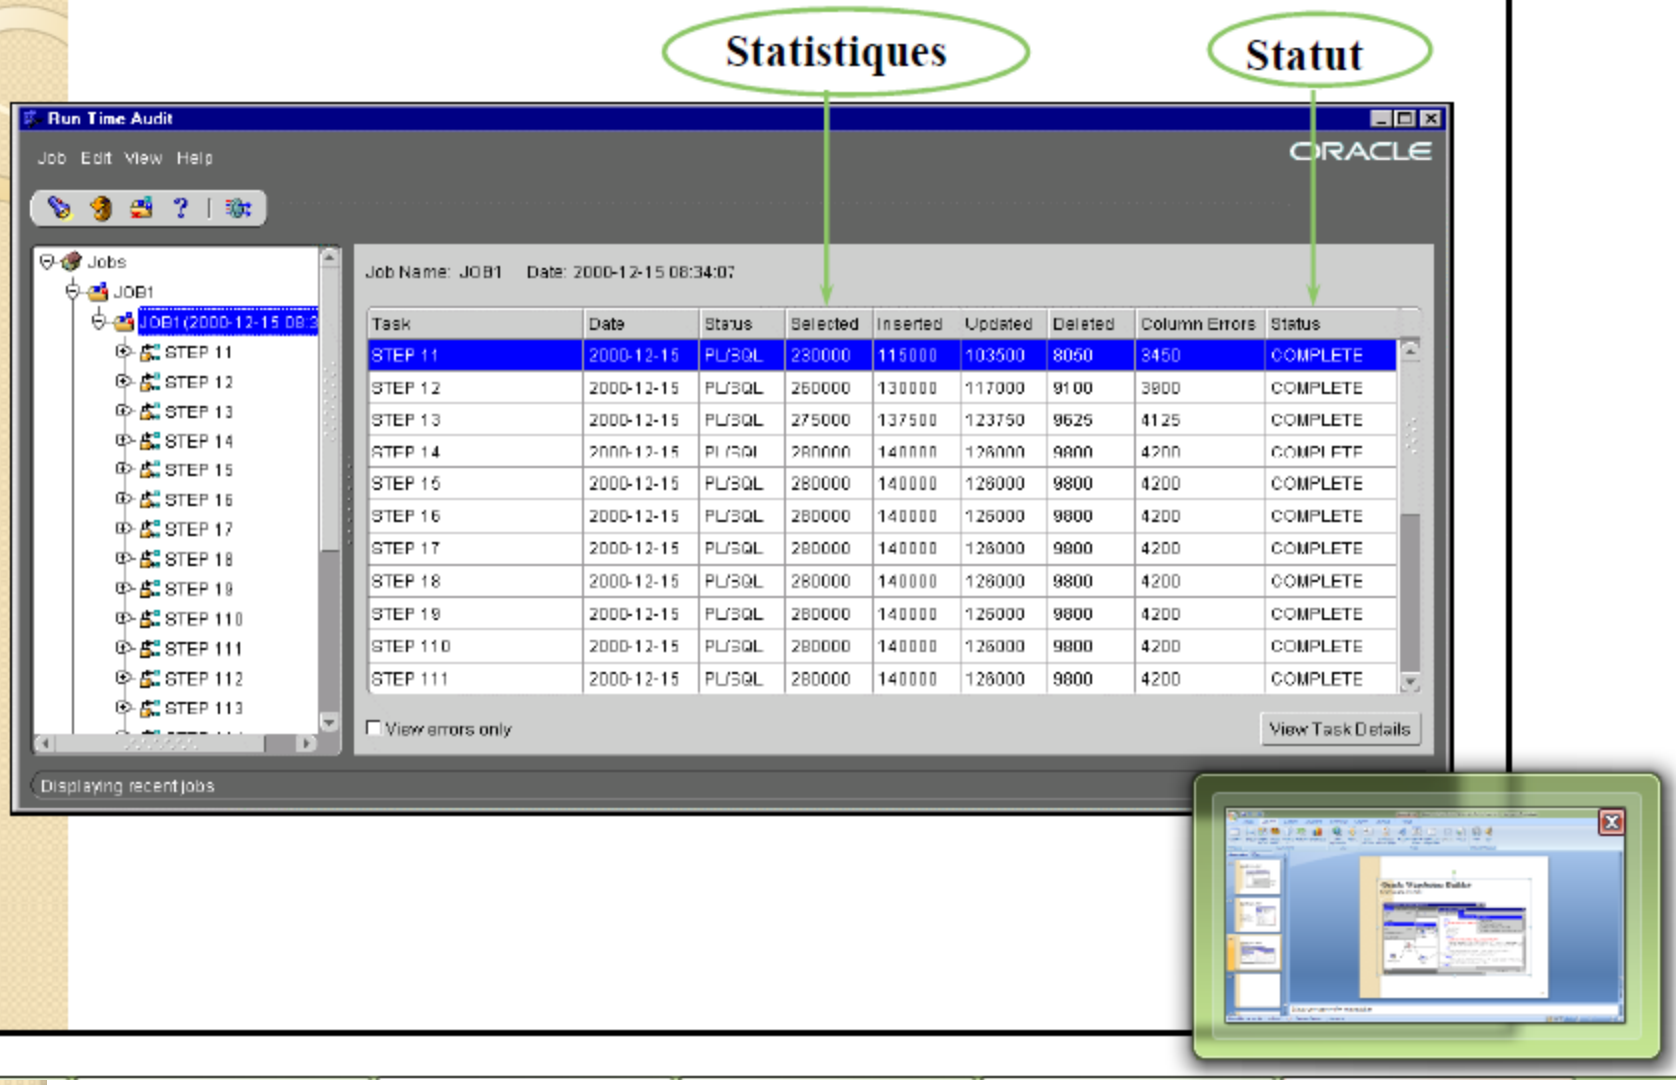
Oracle Warehouse Builder

Génération du code



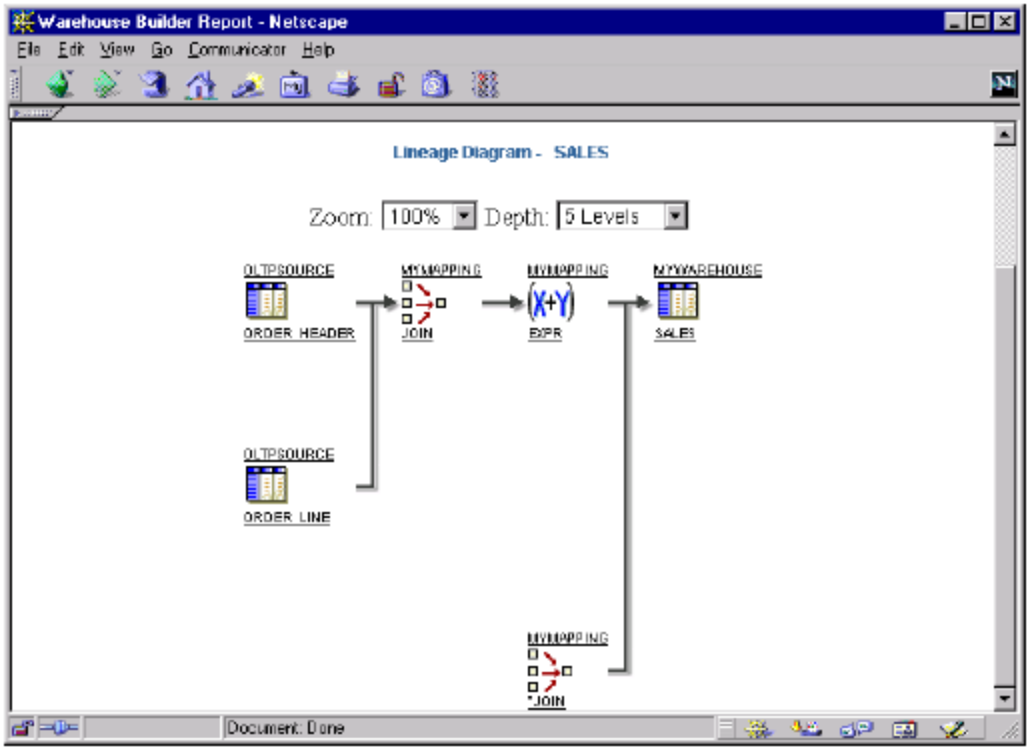
Oracle Warehouse Builder

Rapports d'audit



Oracle Warehouse Builder

Reporting et Analyse d'impact



Oracle Warehouse Builder

Intégration des métadonnées

- OMG CWM
  - Standard ouvert
  - XML Metadata Interchange (XMI)
  - Puissance de modélisation adaptée aux modèles DTWH
- Passerelles Oracle Warehouse Builder
  - Oracle Discoverer, Oracle Express
  - CA ER*win*
  - Sybase PowerDesigner
  - OMG CWM
- Echange de métadonnées avec Oracle Designer, Oracle Pure integrate, Oracle Pure Extract

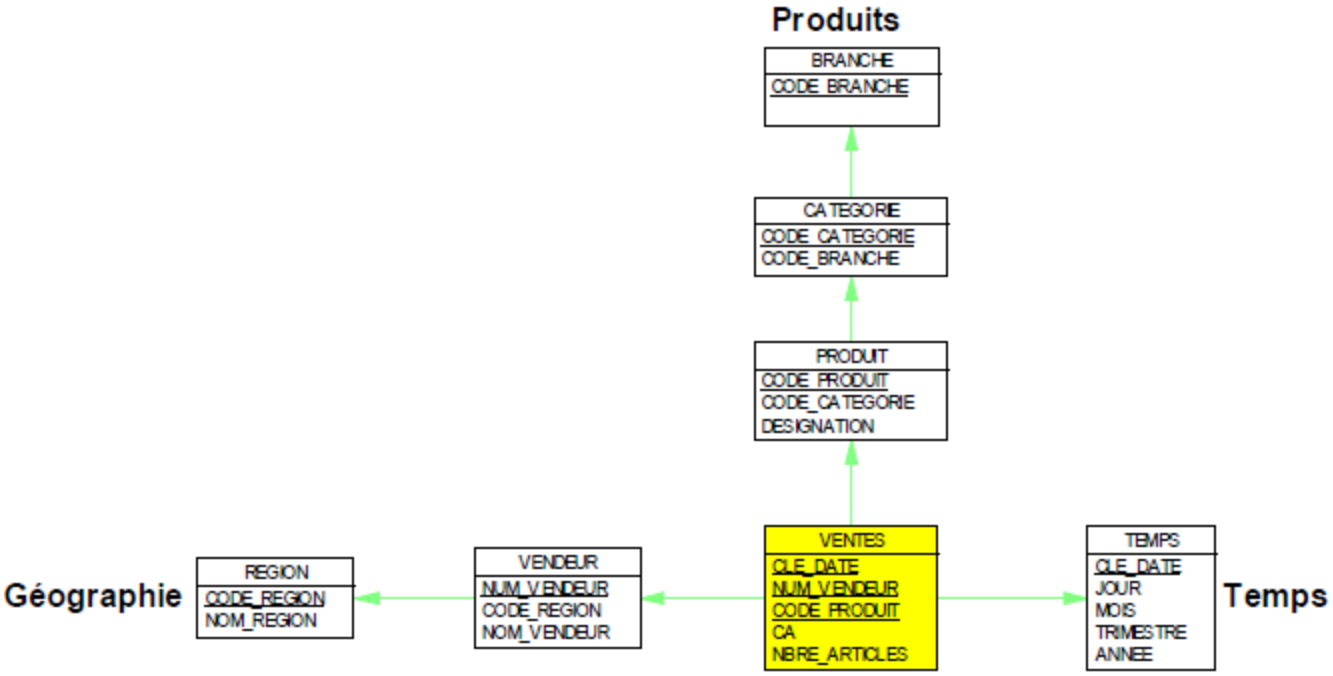
Chapitre 7

Outils d'analyse et de reporting

Analyse multidimensionnelle

- C'est la capacité à manipuler des données qui ont été agrégées selon différentes dimensions
- Exemple :
  - Données : Ventes et CA /mois/Magasin/Produit
  - Analyse : Evolution des ventes d'un produit P dans un magasin M pendant les 2 dernières années

Exemple : Cube ventes



Structures OLAP

L'analyse multidimensionnelle utilise les structures suivantes :

- Dimensions
- Hiérarchies
- Niveaux
- Membres
- Cellules

Structure OLAP : Dimension

- Données utilisées comme contraintes (filtres) ou en-têtes dans les rapports.
- Exemples :
  - Temps
  - Géographie
  - Produits

Structures OLAP : Hiérarchie et Niveau

- Une dimension peut être élémentaire ou bien hiérarchisée
- Lorsqu'elle est hiérarchisée, elle est composée d'un ensemble de niveaux
- Exemples :
  - **Dimension Temps** : Année, Semestre, Trimestre, Mois, Jour
  - **Dimension Géographie** : Région, Ville, Vendeur
  - **Dimension Produit** : Branche, Catégorie, Produit

Structures OLAP : Membre d'un niveau

- Valeur prise par un niveau d'une hiérarchie
- Exemples :
  - **Produit::Branche** : Alimentation, Electro-ménager, …
  - **Produit::Branche.Catégorie** : Alimentation.Légume, Electro-ménager.Instrument
  - **Produit::Branche.Catégorie.Produit** : Alimentation.Légume.Carottes

Structures OLAP : Cellule

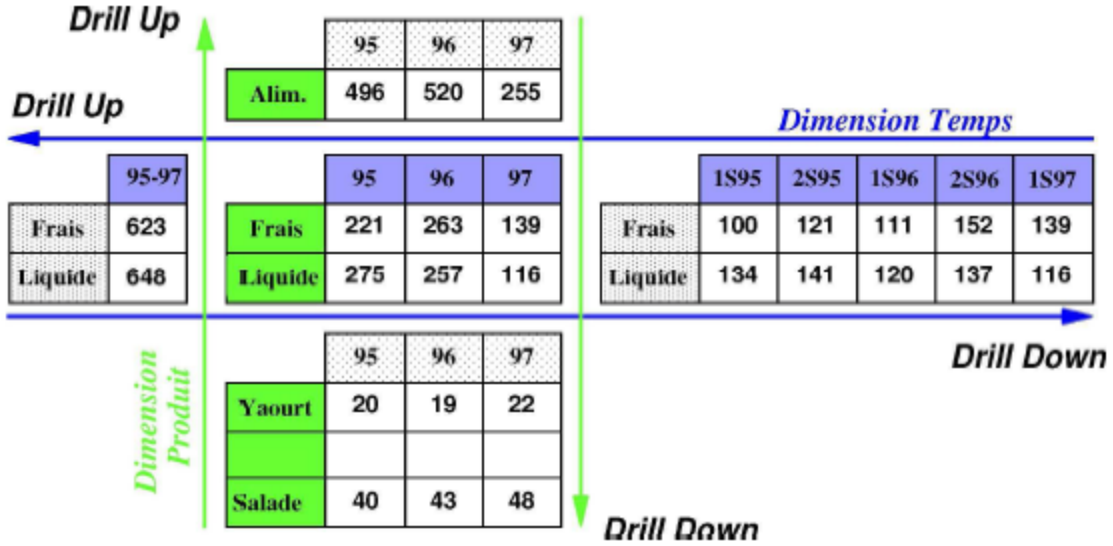
- Intersection des membres des différentes dimensions
- Exemples :
  - (Alimentation.Légume.Carottes, Tunis.Vend21, 2010.S2.Octobre.21) ➔ **(2500, 3000)**

Opérations OLAP

- L'analyse OLAP utilise les opérations suivantes :
  - Drill Down (Forage vers le bas)
  - Drill Up (Forage vers le haut)
  - Rotate (Rotation)
  - Slicing (Tranchage : découpage en tranches)
  - Scoping (Cadrage)

Drill Down / Drill Up

Consiste à analyser les données (Faits) en allant du général vers le détail (par rapport aux niveaux hiérarchiques d'une dimension) ou inversement.



	95-97
Frais	623
Liquide	648

	95	96	97
Alim.	496	520	255
Frais	221	263	139
Liquide	275	257	116
Yaourt	20	19	22
Salade	40	43	48

	1S95	2S95	1S96	2S96	1S97
Frais	100	121	111	152	139
Liquide	134	141	120	137	116

Rotate (Pivotement)

Consiste à analyser les données en maintenant une dimension et en changent une autre dimension

	95	96	97
Frais	221	263	139
Liquide	275	257	116

	95	96	97
NordPdC	101	120	52
IdF	395	400	203



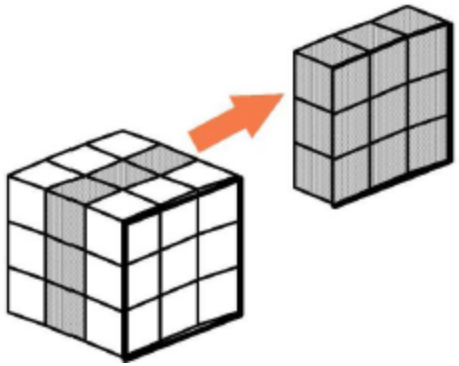
Slicing (Découpage en tranches)

C'est le fait de découper un cube en tranches selon les valeurs d'une dimension

		1995	1996	1997
Frais	IdF	220	265	284
	Province	225	245	240
Liquide	IdF	163	152	145
	Province	187	174	184

→

		1996
Frais	IdF	265
	Province	245
Liquide	IdF	152
	Province	174

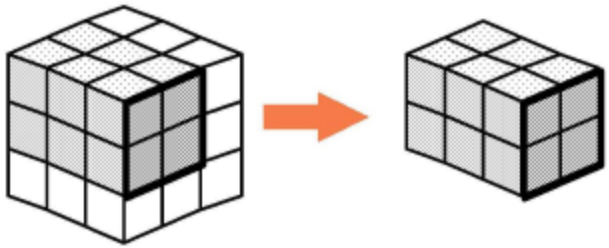


Scoping (Cadrage)

- Consiste à réduire la visibilité des données selon les valeurs d'un certain nombre de dimensions

		1995	1996	1997
Frais	IdF	220	265	284
	Province	225	245	240
Liquide	IdF	163	152	145
	Province	187	174	184

		1995	1996
Frais	IdF	220	265
	Province	225	245



Types d'outils

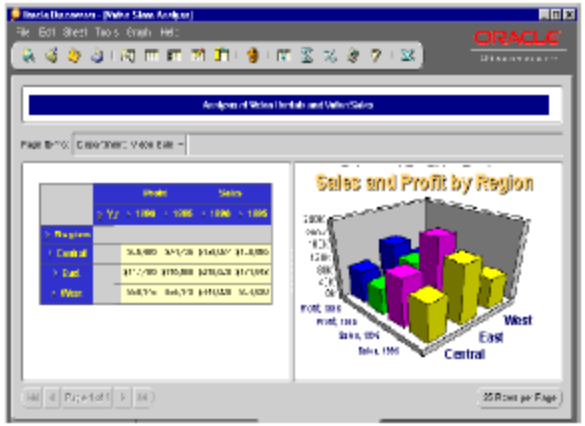
- L'analyse multidimensionnelle peut être effectuée en utilisant les types d'outils suivants :
  - Requeteurs
  - Outils de reporting
  - Executive Information Systems (EIS)

Types d'outils : Requeteurs

- Outils interactifs permettant d'obtenir une réponses à une question plus ou mois complexe
- Génèrent des requêtes SQL
- La requête et la réponse peuvent être mémorisées pour une utilisation ultérieure.
- Font partie souvent du SGBD
- **Exemple :** Query Builder d'Oracle

Outils de reporting

- Intègrent les fonctionnalités de requeteurs
- Possibilités de mise en forme avancées
- Intégration avec les outils bureautiques
- Sans programmation (pour non informaticiens)
- Possibilités de développement avancées (pour informaticiens)



Oracle Discoverer

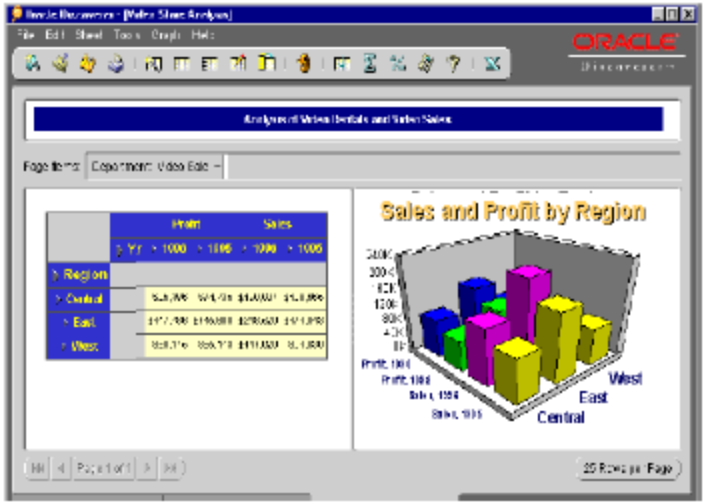
Packaging



Discoverer Plus

Requêtes Web interactives

- Destiné à l'utilisateur averti
- Visualisation ET construction, modification, formattage de requêtes
- Support tableaux et/ou graphes
- Exports bureautique
- Drill et pivot dynamiques
- Analyses via fonctions
  SQL analytiques
- Support des Firewalls



Discoverer Plus

Exploitation des fonctions SQL analytiques Oracle

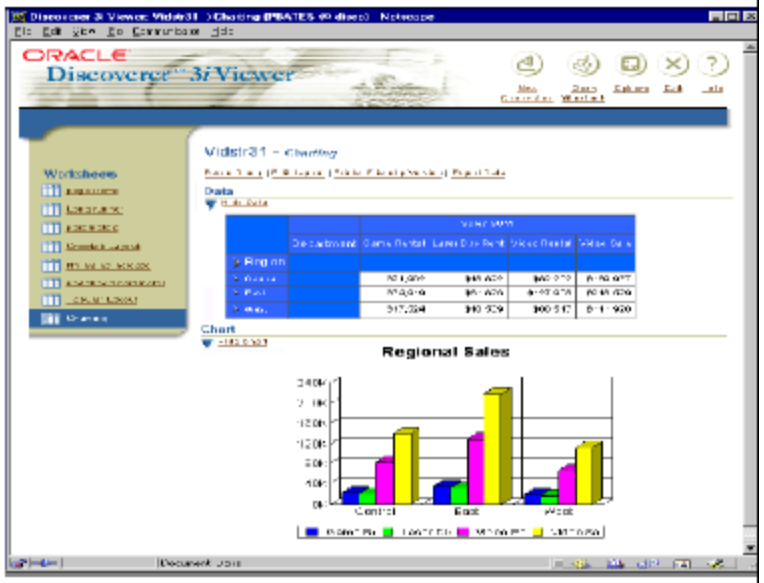
- Ranking, Calculs glissants, LAG/LEAD, Poids (Ratio to report)…
- Exploitable dans les manipulations classiques : Pivot, Totaux, Sous-totaux, Conditions, Tris…
- Possibilité d'imbrication

➔ Fonctions pré-définies (sélection par liste)

➔ Création de fonctions par l'utilisateur

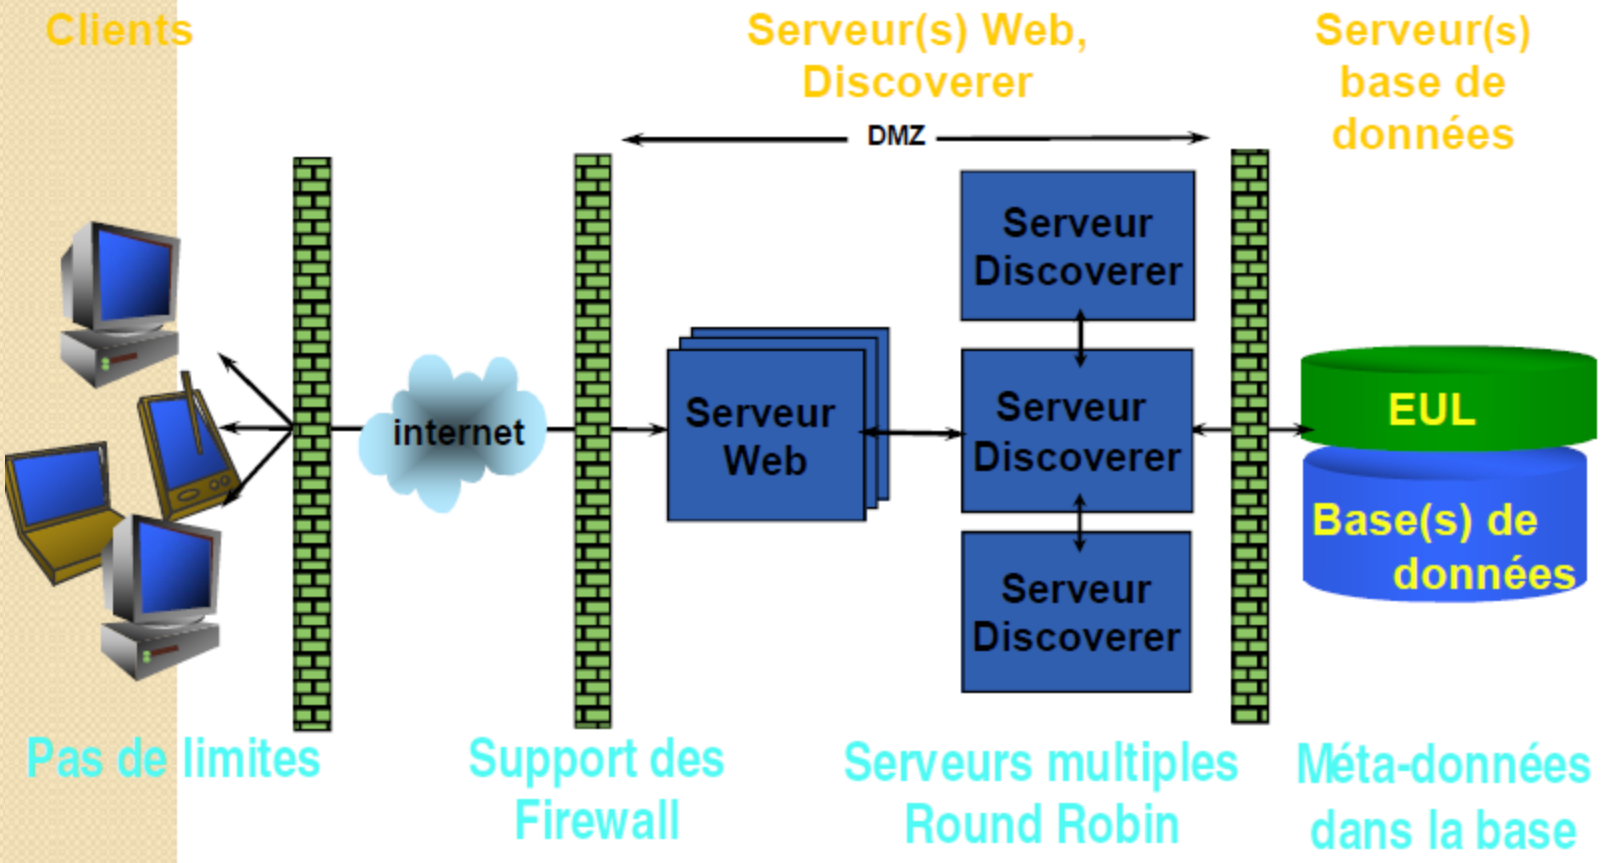
Discoverer Viewer

- Accès à des requêtes Web
  - Destiné à l'utilisateur occasionnel
  - Accès aux dossiers existants depuis le navigateur
  - Interface relookable (feuille de style XSL)
  - Drill et graphes dynamiques
  - Pivot
  - Export Excel



Architecture de Discoverer Web

Tenue à la montée en charge



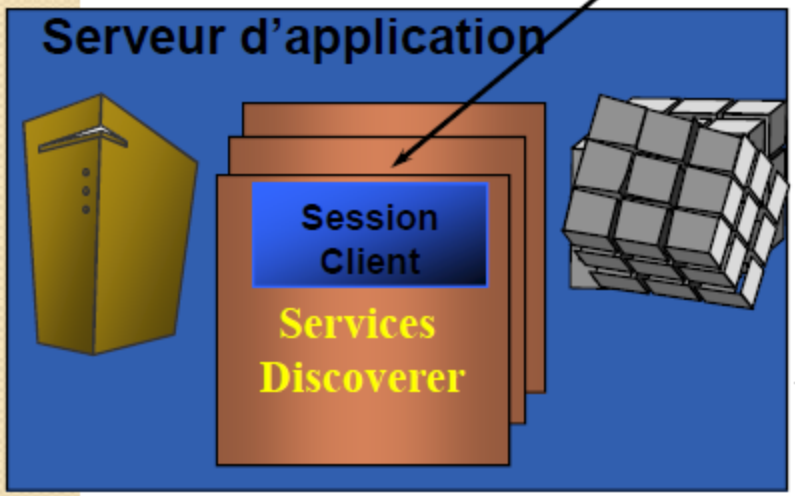
Cache cubique sur le serveur d'appication

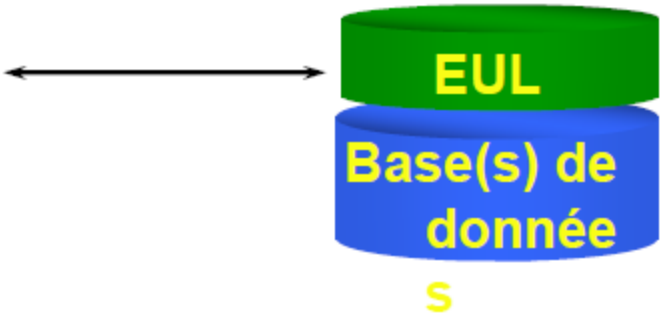
Performance



Client

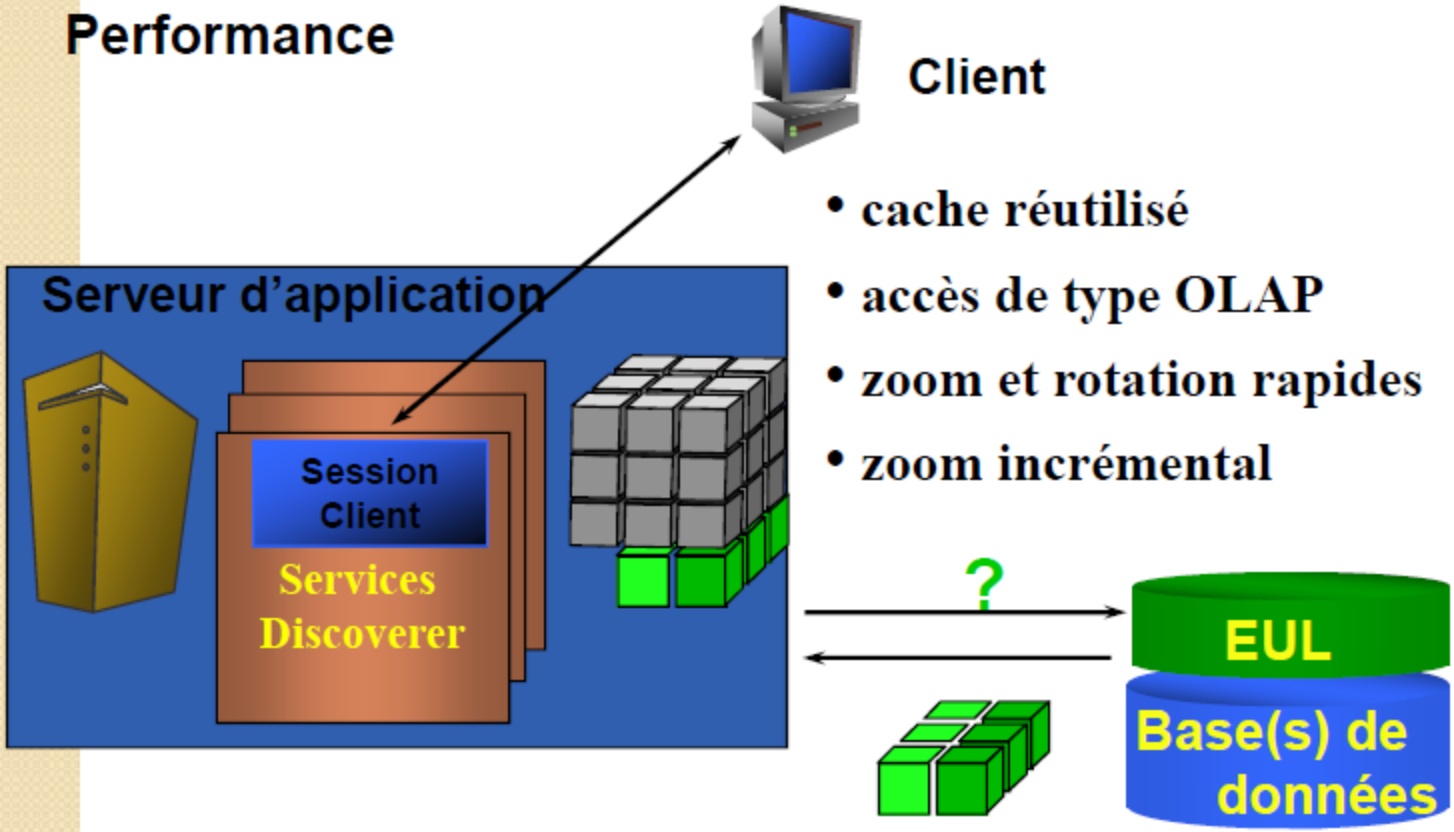
- cache réutilisé
- accès de type OLAP
- zoom et rotation rapides





Cache cubique sur le serveur d'appication

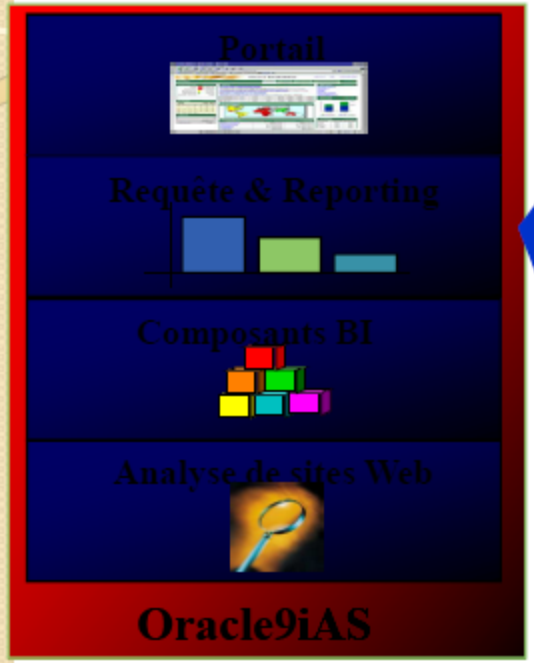
Performance



- cache réutilisé
- accès de type OLAP
- zoom et rotation rapides
- zoom incrémental

Oracle9iAS pour la Business Intelligence

Requête et Reporting



Oracle9*i*AS Discoverer

- Outil de requête et d'analyse
- Simplicité
- Performance

Oracle9*i*AS Reports

- Solution de reporting d'entreprise
- Puissante
- Publication internet et médias traditionnels

Oracle Reports 9i

Reports 9*i* Developer

- Environnement de développement déclaratif pour la création de rapports Web et papier





Oracle 9*i*AS Reports

- Publication des rapports Web ou papier de l'entreprise en garantissant une haute performance

- Production avec Oracle9iAS Release 2 (Décembre 2001)

Oracle Reports 9i

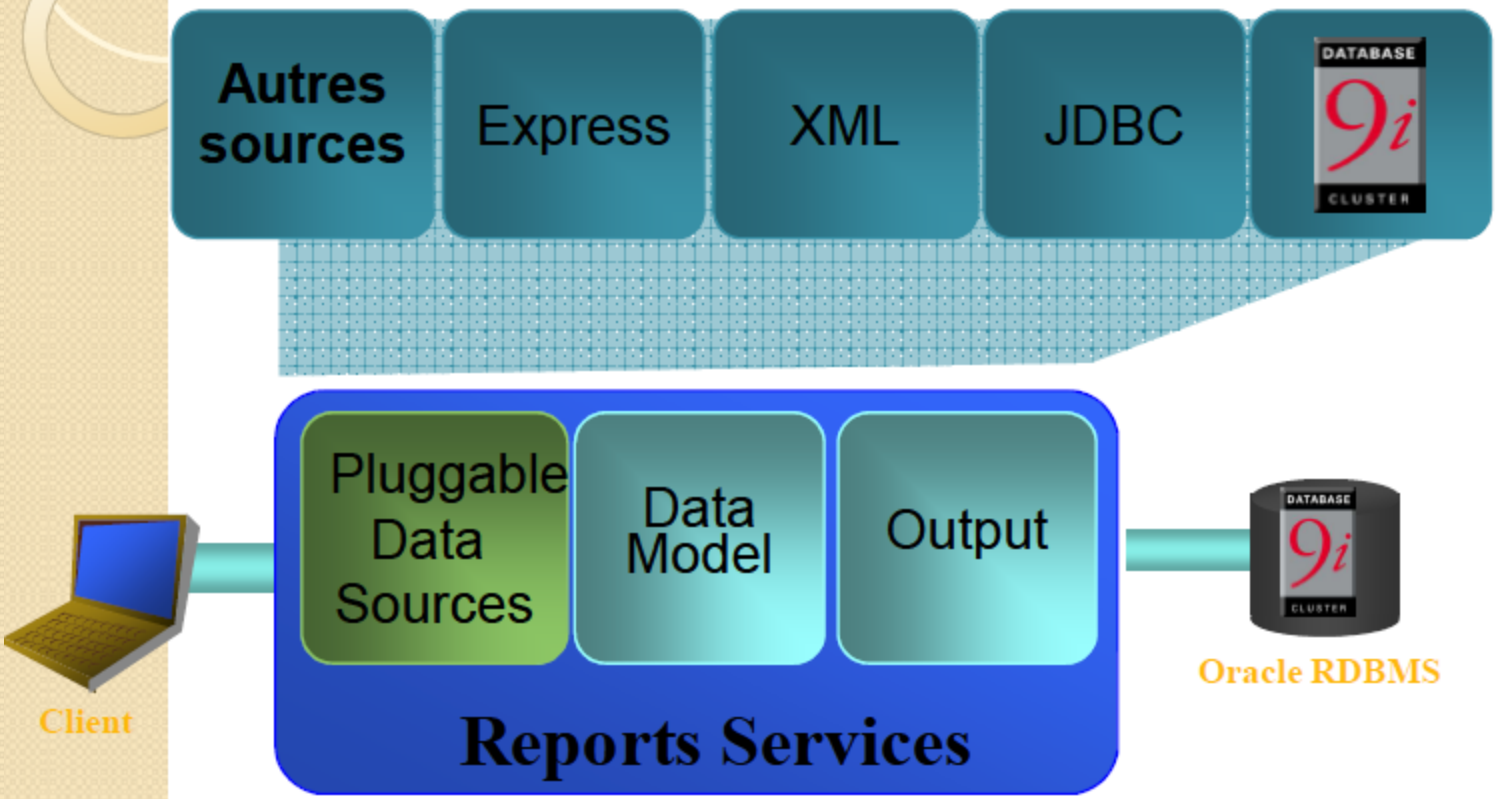
Intégration Oracle Reports / Oracle Portal

- Intégration à l'infrastructure de gestion de la sécurité d'Oracle Portal
- Single-signon
- Intégration via Portlets



Oracle Reports 9i

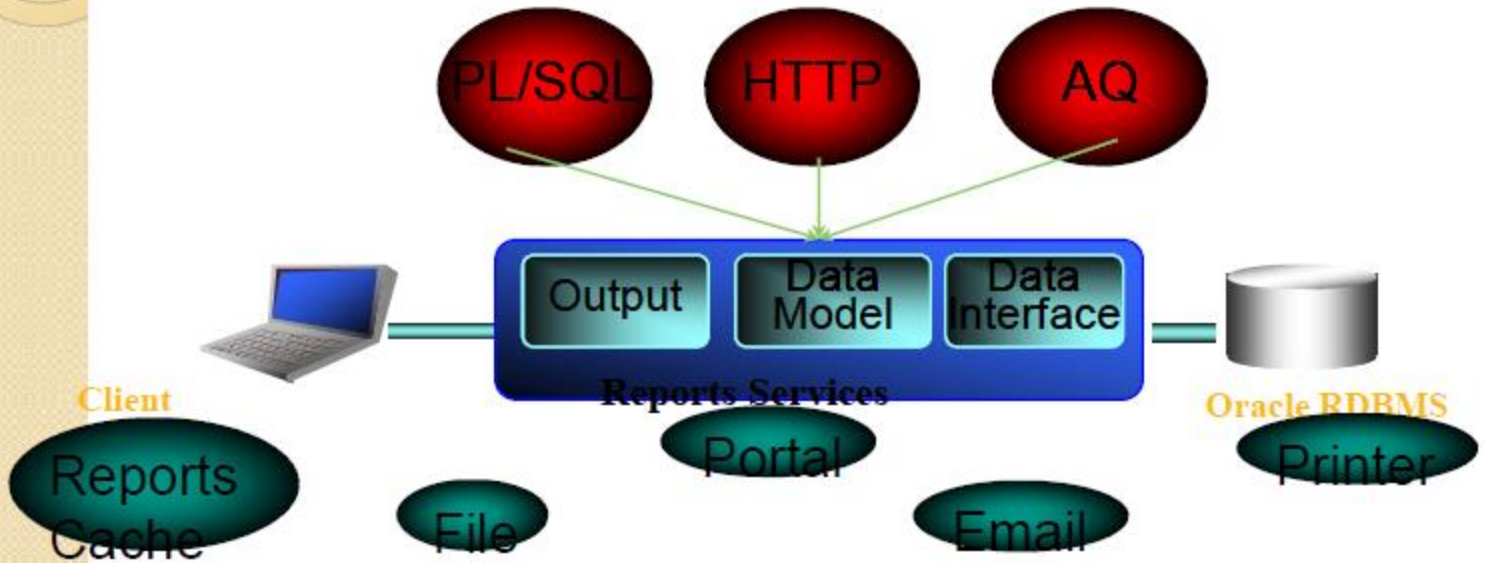
Datasources pluggables



Oracle Reports 9i

Event-based Reporting

Utilise des triggers dans la database



Executive Information Systems (EIS)

- Système d'information pour décideurs
- Outils de visualisation et de navigation dans les données
- Sous forme de tableau de bord composé d'un ensemble d'indicateurs
- Possibilité d'effectuer les opération de *drill down*, *drill up*, *slicing*, *rotate* et *scoping*
- *Démonstration*

Chapitre 8

Mise en œuvre d'entrepôt de données

Techniques de mise en œuvre d'ED

La mise en œuvre d'un entrepôt de données fait appel aux techniques suivantes :

- Choix de clé primaire
- Indexation
- Dénormalisation
- Partitionnement
- Utilisation des vues matérialisées
- Choix d'architecture
- Administration de l'espace disque

Choix de clé primaire

- L'identification des enregistrements des tables de faits peut être faite par :
  - Utilisation d'une clé primaire multiple
  - Création d'une nouvelle clé unique

Indexation

- Index sur clé primaire
- Index sur clé étrangères
- Index de jointure (bitmap index)

Dénormalisation

- Tables de dimensions :
  - Passage d'un schéma en flocon de neige vers un schéma en étoile
- Tables de faits :
  - Ajout des libellés des tables de dimensions
  - Ajout de propriétés calculées

Partitionnement

- Principe :
  - Répartition physique des tables de faits
- Avantages :
  - Optimisation du temps d'accès
  - Répartition des données sur différents disques
- Contraintes :
  - Transparence du partitionnement

Utilisation des vues matérialisées

- Principe :
  - Stockage du résultat d'une requête
- Avantage :
  - Optimisation du temps d'accès à certaines données
- Inconvénients :
  - Risque d'incohérence
  - Nécessité de rafraichissement
- Problématique :
  - Sélection des vues à matérialiser
  - Stratégie de rafraichissement (quoi, quand et comment)

Choix d'architecture de l'ED

- Différentes architectures possibles :
  - Architecture centralisée : un ED
  - Architecture répartie : un {MD} :
    - Répartition géographique
    - Répartition logique
  - Architecture mixte : un ED + {MD} :
    - Un seul ETL ou plusieurs ETL
    - Réplication des données

Administration de l'espace disque

- Gestion des tablespaces des données :
  - Pour les tables
  - Pour les indexes
- Gestion des tablespaces temporaires :
  - Création
  - Affectation aux utilisateurs
- Séparation données/indexes
- Mise en place de stratégie de sauvegarde