Département des Technologies de l'Informatique

Devoir Surveillé

Unité d'Enseignement : BIG DATA
Durée : 1 Heure
Date : 05/11/2025
Enseignant : Mr Ons Ben Rejeb

Nb de pages : 2
Classe : M21SID
Heure de début : 12H00
Documents Autorisés : NON

Questions de cours : (6 pts)

1) Donner les termes liés aux définitions suivantes (3pts) :
   a) Domaine lié au Big Data qui permet l'extraction des données intelligentes ;
   b) Projet qui consiste en deux grandes parties : HDFS et Map Reduce ;
   c) Collection de machines utilisée pour le stockage et le traitement de très gros volumes de données ;
   d) Script simple orienté traitement par flux (Data flow) dans le domaine du Big Data ;
   e) Couche de l'écosystème de Hadoop pour la gestion des métadonnées ;
   f) Petits programmes qui commencent par traiter chacun une petite partie des données et qui fonctionnent en parallèle.
2) Donner les différentes caractéristiques des bases de données NOSQL ? (1.5 pt)
3) Citer les différents types des bases de données NOSQL ? (1.5 pt)

Problème (HDFS-MapReduce) : (14 pts)

Soit un fichier texte qui stocke la liste des notes des étudiants pour chaque matière. Ce fichier s'appelle notes-étudiants. La taille du fichier est 290 MO.

Chaque ligne de ce fichier est composée de plusieurs champs séparés par des espaces. Voici un extrait du fichier :

07100022 01/02/2021 BenMohamed Sameh BaseDeDonnees 14 2

08581210 01/02/2021 Bensalah Amine BaseDeDonnees 14 2

25364863 01/02/2021 BenMansour Mouna BaseDeDonnees I8 2

07100022 15/02/2021 BenMohamed sameh 101 12 1

25364863 15/0272021 BenMansour Mouna 101 10 1

35681311 01/02/2021 Raddadi chaima BaseDeDonnees 16 2

15681111 21/0272021 Raddadi Chaim POA 12 4

07100022 21/02/2021 BenMohamed Sameh POA P 4

08581230 21/02/2021 Bensalah Amine POA 15 4

25464861 21/02/2021 BenMansour Nouna POA 19 4

35681331 15/02/2021 Raddadi Chaima 101 10 1

08581249 15/02/2021 Bensalah Amine 101 1 4

Où chaque ligne du fichier est formée de ces propriétés :

NumeroInscription Date NomEtudiant PrenomEtudiant Matière Note Coefficient

Questions

1) Combien de nœuds au minimum avons-nous besoin dans notre cluster Hadoop afin de stocker le fichier notes-étudiants. (1 pt)
2) Donner dans un schéma la répartition des différents blocs du fichier notes-étudiants sur les différents data node du cluster. (2 pts)
3) Quelle est la solution proposée par HDFS pour faire face à la perte de données. (1 pt)
4) Si le disque du NameNode (NN) est défaillant, quelle est la solution proposée par Hadoop pour ce problème ? (1 pt)
5) Si l'un des DataNodes (DN) tombe en panne, quel est le comportement du système hadoop (donner toutes les étapes nécessaires) ? (2.5 pts)
6) Donner le schéma qui expose le fonctionnement de Map-reduce en général, en spécifiant les différentes étapes. (1.5 pt)
7) Proposer un schéma qui récapitule le processus de calcul de la moyenne des notes de chaque étudiant en respectant le modèle MapReduce (spécifier la elé et la valeur). (2 pts)
8) Si on veut calculer la moyenne pour chaque matière, quel changement devrons-nous apporter à la solution de la question précédente ? (1 pt)
9) Nous comptons calculer la moyenne générale de toutes les matières, quels sont les changements à effectuer à la solution de la question 8. (2 pts)

Bon Travail