ISET de ZAGHOUAN

Département des Technologies de l'Informatique

DS

Unité d'Enseignement : BIG DATA	**Classes : ISID2**
Durée : 1 Heure	**Nombre de pages : 2**
Date : 05/11/2025	**Heure de début : 12H00**
Proposé par : Mr Ons Ben Rejeb	**Documents Autorisés : NON**

NB :

- **Il vous est demandé d'apporter un soin particulier à la présentation de votre copie.**

Questions de cours : (6 pts)

1) Donner les termes liés aux définitions suivantes **(3pts)** :
   a) Domaine lié au Big Data qui permet l'extraction des données intelligentes ;
   b) Projet qui consiste en deux grandes parties : HDFS et Map Reduce ;
   c) Collection de machines utilisée pour le stockage et le traitement de très gros volumes de données ;
   d) Script simple orienté traitement par flux (Data flow) dans le domaine du Big Data ;
   e) Couche de l'écosystème de Hadoop pour la gestion des métadonnées ;
   f) Petits programmes qui commencent par traiter chacun une petite partie des données et qui fonctionnent en parallèle.
2) Donner les différentes caractéristiques des bases de données NOSQL ? **(1.5 pt)**
3) Citer les différents types des bases de données NOSQL ? **(1.5 pt)**

Problème (HDFS-MapReduce) : (14 pts)

Soit un fichier texte qui stocke la liste des notes des étudiants pour chaque matière. Ce fichier s'appelle **notes-étudiants**. La taille du fichier est **290 MO**.

Chaque ligne de ce fichier est composée de plusieurs champs séparés par des espaces. Voici un extrait du fichier :

```
07100022 01/02/2021 BenMohamed Sameh BaseDeDonnees 15 2
08581239 01/02/2021 BenSalah Amine BaseDeDonnees 14 2
25364863 01/02/2021 BenMansour Nouna BaseDeDonnees 18 2
07100022 15/02/2021 BenMohamed Sameh IOI 12 1
25364863 15/02/2021 BenMansour Nouna IOI 10 1
35681333 01/02/2021 Raddadi Chaima BaseDeDonnees 16 2
35681333 21/02/2021 Raddadi Chaima POA 17 4
07100022 21/02/2021 BenMohamed Sameh POA 15 4
08581239 21/02/2021 BenSalah Amine POA 15 4
25364863 21/02/2021 BenMansour Nouna POA 19 4
35681333 15/02/2021 Raddadi Chaima IOI 10 1
08581239 15/02/2021 BenSalah Amine IOI 15 1
```

Où chaque ligne du fichier est formée de ces propriétés :

NuméroInscription Date NomEtudiant PrenomEtudiant Matière Note Coefficient

Questions

1) Combien de nœuds au minimum avons-nous besoin dans notre cluster Hadoop afin de stocker le fichier **notes-étudiants. (1 pt)**
2) Donner dans un schéma la répartition des différents blocs du fichier **notes-étudiants** sur les différents data node du cluster. **(2 pts)**
3) Quelle est la solution proposée par HDFS pour faire face à la perte de données. **(1 pt)**
4) Si le disque du **NameNode (NN)** est défaillant, quelle est la solution proposée par Hadoop pour ce problème ? **(1 pt)**
5) Si l'un des **DataNodes (DN)** tombe en panne, quel est le comportement du système hadoop (donner toutes les étapes nécessaires)? **(2.5 pts)**
6) Donner le schéma qui expose le fonctionnement de Map-reduce en général, en spécifiant les différentes étapes. **(1.5 pt)**
7) Proposer un schéma qui récapitule le processus de calcul de la moyenne des notes de chaque étudiant en respectant le modèle MapReduce (spécifier **la clé et la valeur**). **(2 pts)**
8) Si on veut calculer la moyenne pour chaque matière, quel changement devrons-nous apporter à la solution de la question précédente? **(1 pt)**
9) Nous comptons calculer la moyenne générale de toutes les matières, quels sont les changements à effectuer à la solution de la **question 8. (2 pts)**

Bon Travail