Cours de data engineering

Data Warehouse, Data Lake et Data Lakehouse



Trois architectures pour stocker et analyser les données de l'entreprise

Enseignante : Safa Chmengui

Plan du cours



01

Le Data Warehouse

Définition, ETL, nettoyage, transformation, modélisation en étoile



02

Le Data Lake

Stockage de toutes les données brutes, types de données, limites



03

Le Data Lakehouse

Le meilleur des deux mondes : formats de table ouverts, architecture médaillon

Pourquoi une plateforme analytique ?

Les bases de production ne sont pas faites pour l'analyse



OLTP : faire tourner l'activité

- Exemples : ERP (Odoo), CRM, site e-commerce
- Requêtes courtes sur quelques lignes
- Écritures fréquentes, forte concurrence
- Stockage orienté lignes, schéma normalisé



OLAP : analyser l'activité

- Exemples : data warehouse, lakehouse
- Requêtes sur des millions de lignes
- Surtout des lectures et des agrégations
- Stockage orienté colonnes, schéma dénormalisé

Analyser directement sur la base de production ralentit les utilisateurs : on copie donc les données vers un système dédié.

01

Le Data Warehouse

L'entrepôt de données structurées, fiable et prêt pour la BI

Qu'est-ce qu'un data warehouse ?

Une base de données centrale qui regroupe les données de plusieurs systèmes sources, nettoyées et organisées pour l'analyse.

Orienté sujet

Organisé par thème métier : ventes, clients, stock

Intégré

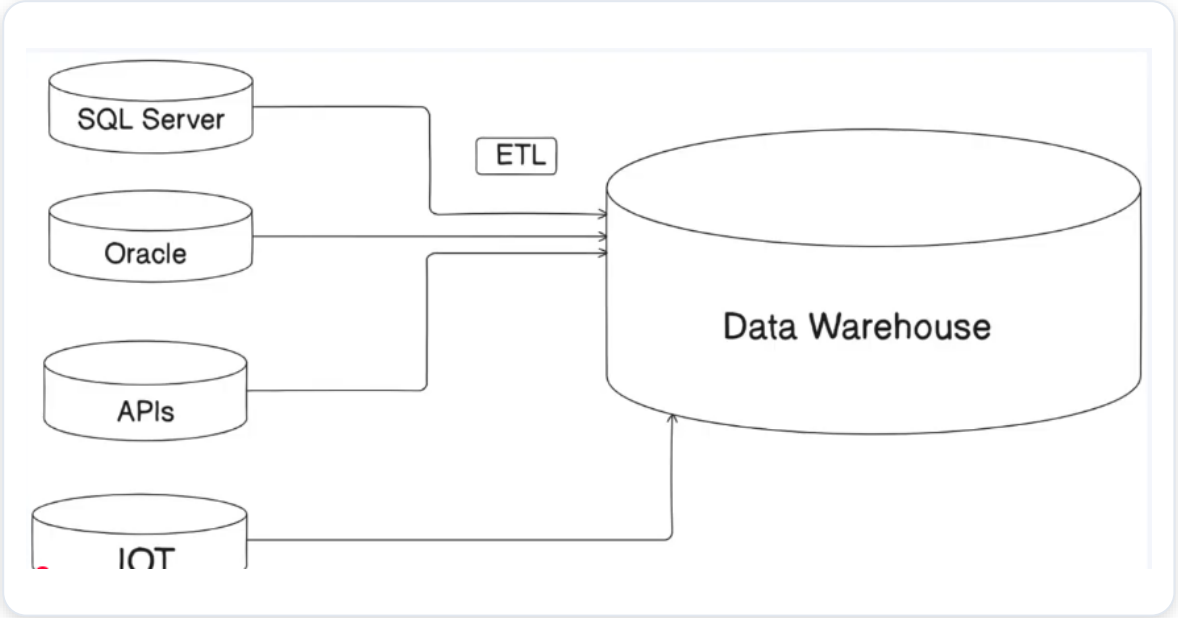
Les sources sont harmonisées : mêmes codes, mêmes formats

Non volatile

Les données chargées ne sont pas modifiées par l'activité

Historisé

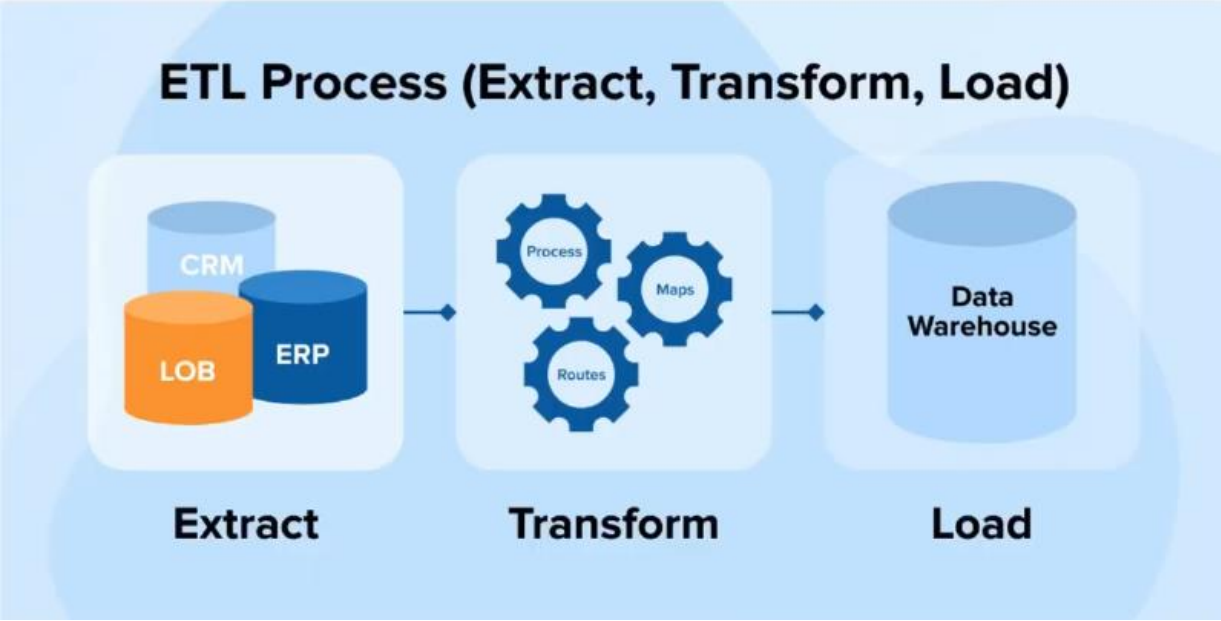
On conserve l'évolution dans le temps



Plusieurs sources (SQL Server, Oracle, APIs, IoT) alimentent un entrepôt unique via l'ETL.

Le processus ETL

Extract, Transform, Load : comment les données arrivent dans l'entrepôt



1

Extract

Lire les données des sources : ERP, CRM, applications métier, fichiers.

2

Transform

Nettoyer, convertir, relier et calculer dans une zone intermédiaire.

3

Load

Charger le résultat dans les tables de l'entrepôt.

ETL ou ELT ? En ETL, on transforme avant de charger (approche classique du warehouse). En ELT, on charge d'abord les données brutes puis on les transforme dans la plateforme (approche moderne du lake et du lakehouse).

Étape clé : le nettoyage des données

Des données sales donnent des indicateurs faux



« Garbage in, garbage out » : la qualité des analyses dépend directement de la qualité des données chargées.

Doublons

Supprimer les clients ou commandes saisis deux fois

Valeurs manquantes

Compléter, remplacer par une valeur par défaut ou isoler

Formats

Uniformiser dates, téléphones, codes pays, majuscules

Valeurs aberrantes

Repérer un montant négatif ou une date en 2099

Cohérence

Vérifier qu'une facture pointe vers un client existant

Validation

Contrôles automatiques avant chaque chargement

Étape clé : la transformation des données

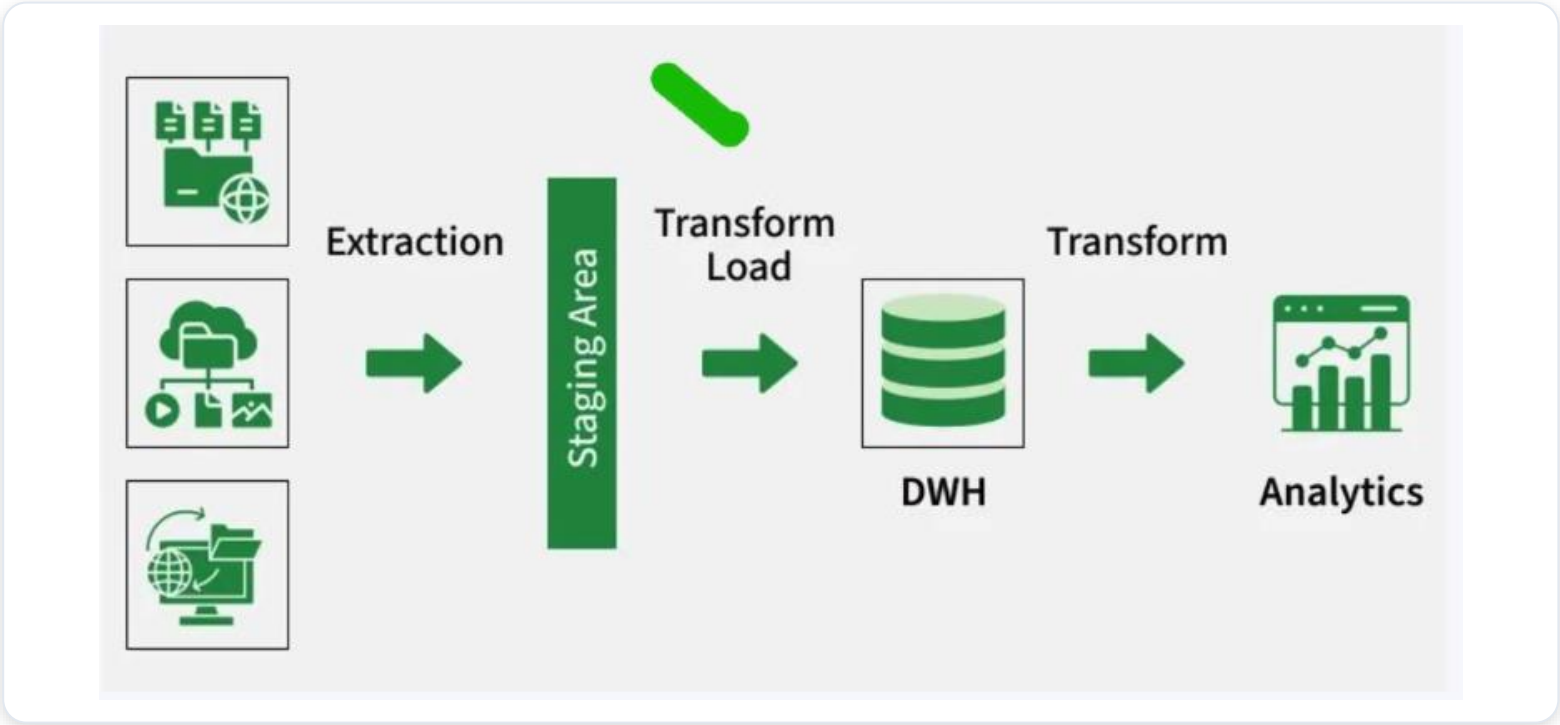
Passer de données dispersées à une structure organisée

- Jointures : relier commandes, clients et produits
- Agrégations : totaux par jour, par mois, par région
- Calculs : marge, TVA, montant converti en devise de référence
- Conversion de types : texte vers date, nombre, booléen
- Dénormalisation : préparer des tables simples à interroger
- Historisation : garder les anciennes valeurs d'un client



Des blocs épars deviennent une structure cohérente, prête pour l'analyse.

Architecture d'un data warehouse



Zone de staging

Copie temporaire des données extraites, avant transformation. Elle protège les sources.

Entrepôt (DWH)

Données intégrées, historisées et modélisées, la source de vérité de l'entreprise.

Analytics

Data marts, tableaux de bord et rapports pour les équipes métier.

Modélisation : le schéma en étoile

Proposé par Ralph Kimball, standard de la BI

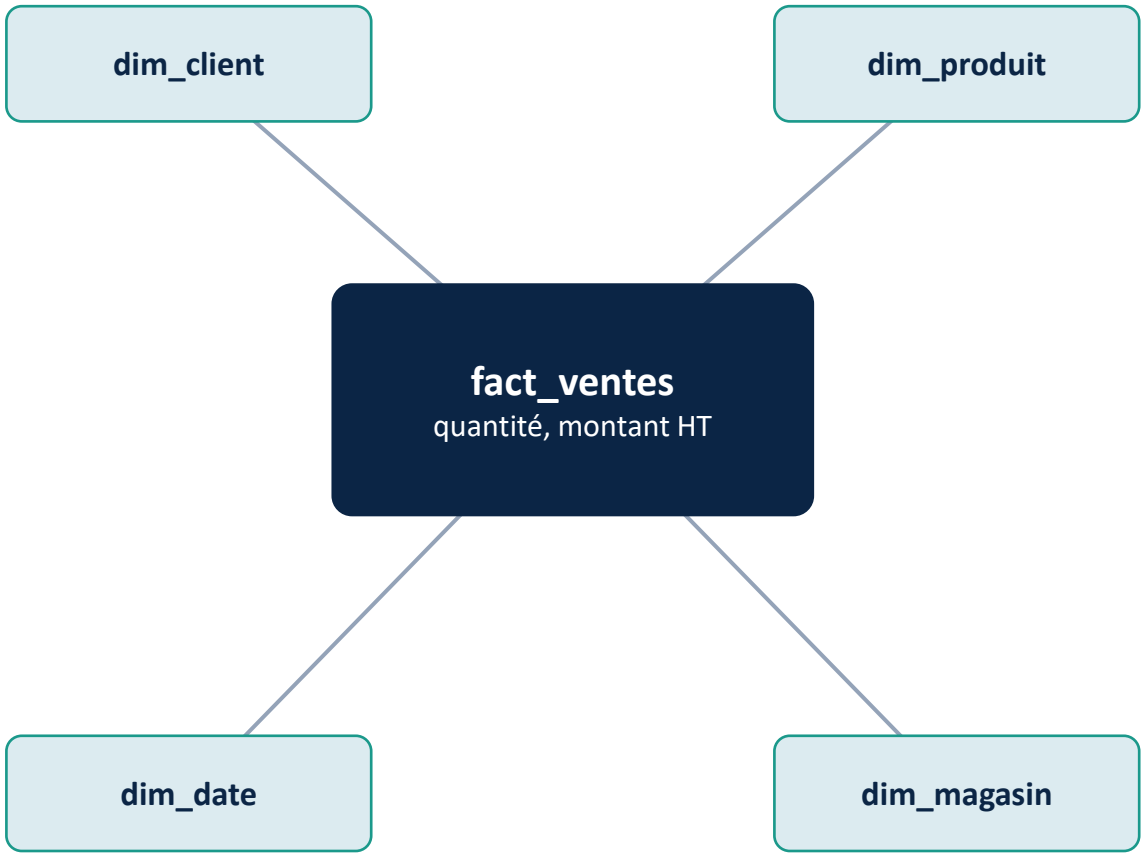


Table de faits

Les événements mesurables : une ligne par vente, avec des clés et des mesures numériques.

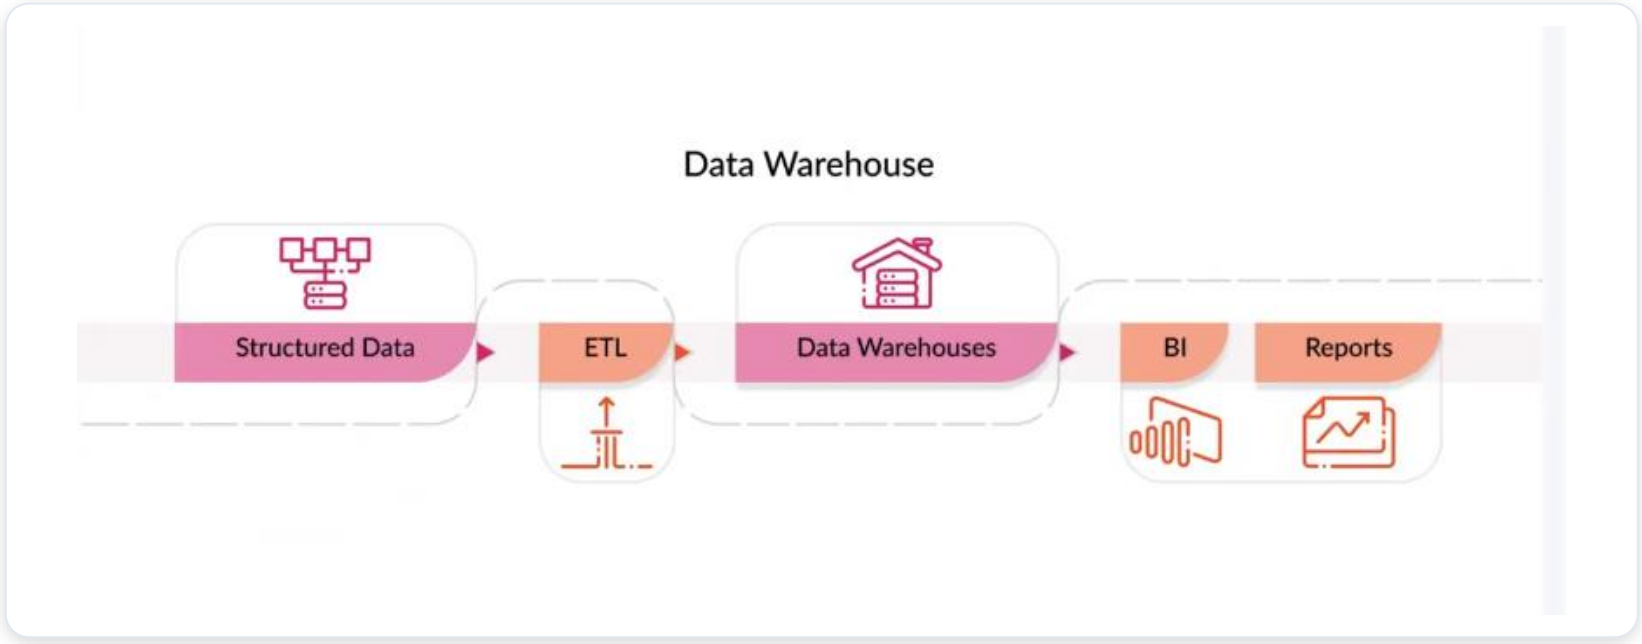
Tables de dimensions

Le contexte : qui, quoi, quand, où. Elles servent à filtrer et regrouper.

Granularité

Le niveau de détail d'une ligne de faits : à définir en premier.

Usages, forces et limites du data warehouse



Forces

- Données fiables, cohérentes et gouvernées
- SQL très performant pour la BI et le reporting
- Outils et pratiques matures

Limites

- Coût élevé du stockage et des licences
- Données structurées uniquement, schéma rigide
- Peu adapté au machine learning et aux gros volumes bruts

02

Le Data Lake

Stocker toutes les données, brutes, à faible coût

Qu'est-ce qu'un data lake ?

Un espace de stockage qui conserve toutes les données de l'entreprise dans leur format d'origine, structurées ou non, à grande échelle et à faible coût.

Schema-on-read

La structure est appliquée à la lecture, pas à l'écriture

Stockage objet

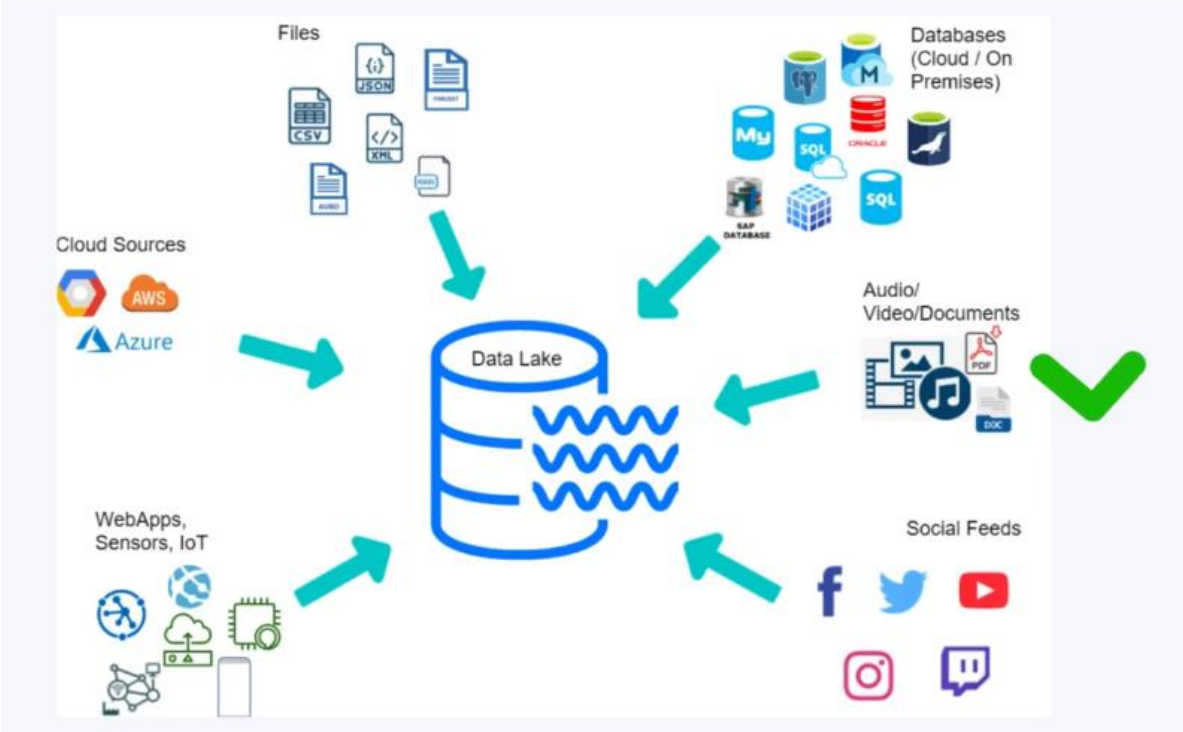
Amazon S3, Azure Data Lake, Google Cloud Storage, MinIO

Tous les formats

CSV, JSON, Parquet, images, vidéos, logs, documents

Coût faible

Stockage bon marché, extensible presque sans limite



Trois types de données

Le data lake accepte les trois ; le data warehouse surtout le premier



Structurées

Lignes et colonnes avec un schéma fixe.

Exemples : Tables SQL, exports CSV, factures ERP

Environ 20 % des données



Semi-structurées

Une structure souple, avec des balises ou des clés.

Exemples : JSON d'API, XML, logs, e-mails

Format des échanges web



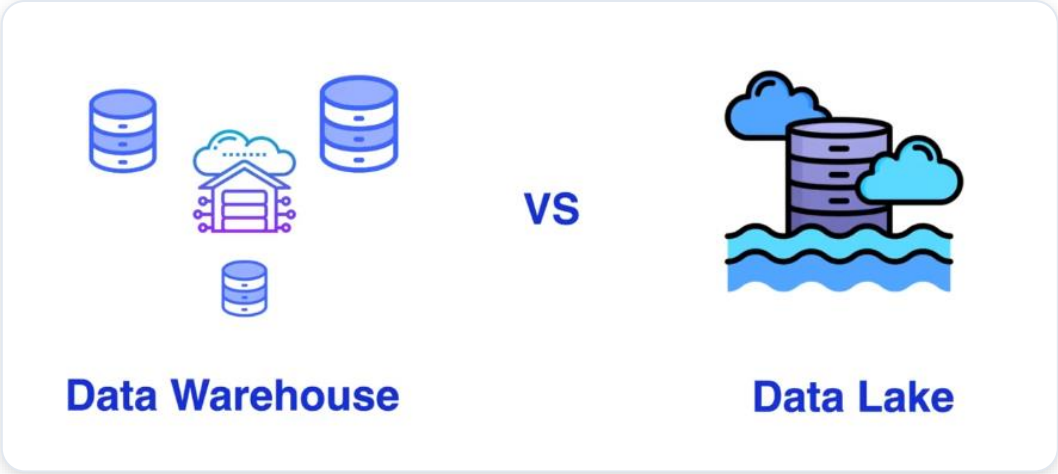
Non structurées

Pas de structure exploitable directement.

Exemples : Images, vidéos, audio, PDF, textes libres

Environ 80 % des données

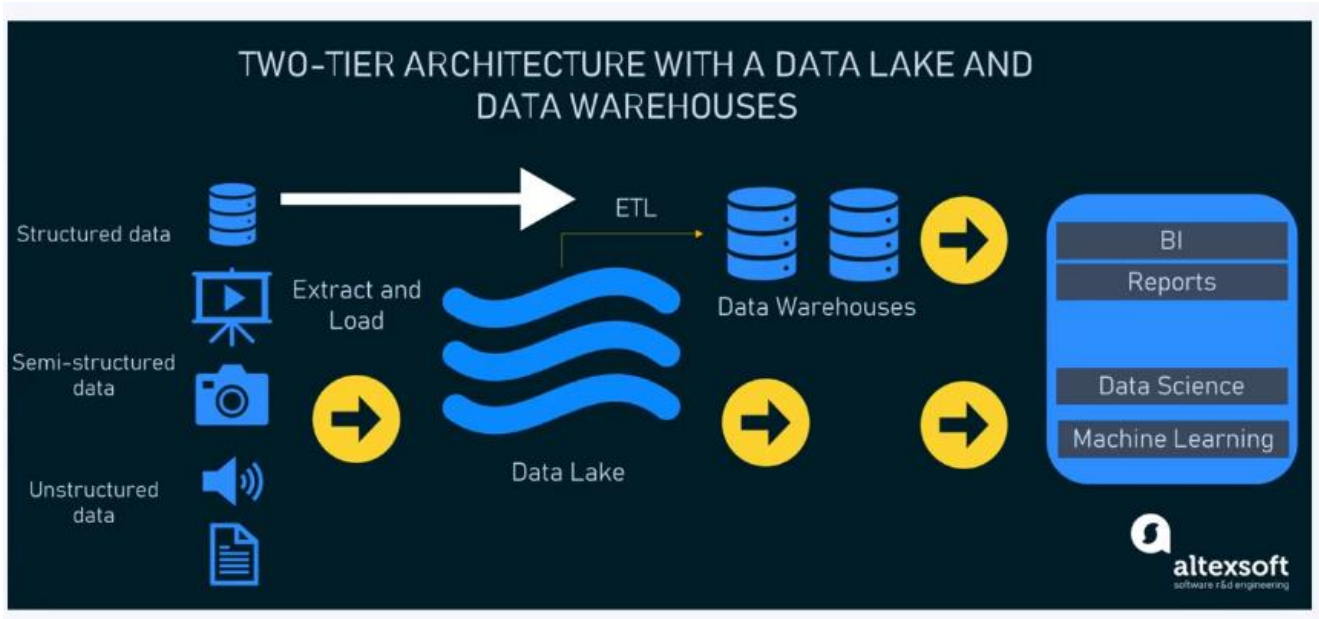
Data warehouse ou data lake ?



Critère	Data warehouse	Data lake
Données	Structurées, nettoyées	Toutes, brutes
Schéma	Défini à l'écriture	Appliqué à la lecture
Coût de stockage	Élevé	Faible
Utilisateurs	Analystes métier, BI	Data engineers, data scientists
Fiabilité	Forte, transactions ACID	Faible sans gouvernance
Usage principal	Reporting, tableaux de bord	Exploration, machine learning

L'architecture à deux niveaux

Un data lake pour tout stocker, des data warehouses pour la BI



Les données passent d'abord par le lake, puis une partie est recopiée par ETL dans un ou plusieurs warehouses.

Les problèmes

Données en double

Même donnée stockée deux fois

Données en retard

Le warehouse attend l'ETL

Coûts cumulés

Deux plateformes à payer et maintenir

Data swamp

Lake sans contrôle ni qualité

03

Le Data Lakehouse

La fiabilité du warehouse sur le stockage ouvert du lake

Qu'est-ce qu'un data lakehouse ?

Une architecture unique qui ajoute les garanties d'un data warehouse (transactions, schéma, performance SQL) directement sur le stockage bon marché et ouvert d'un data lake.

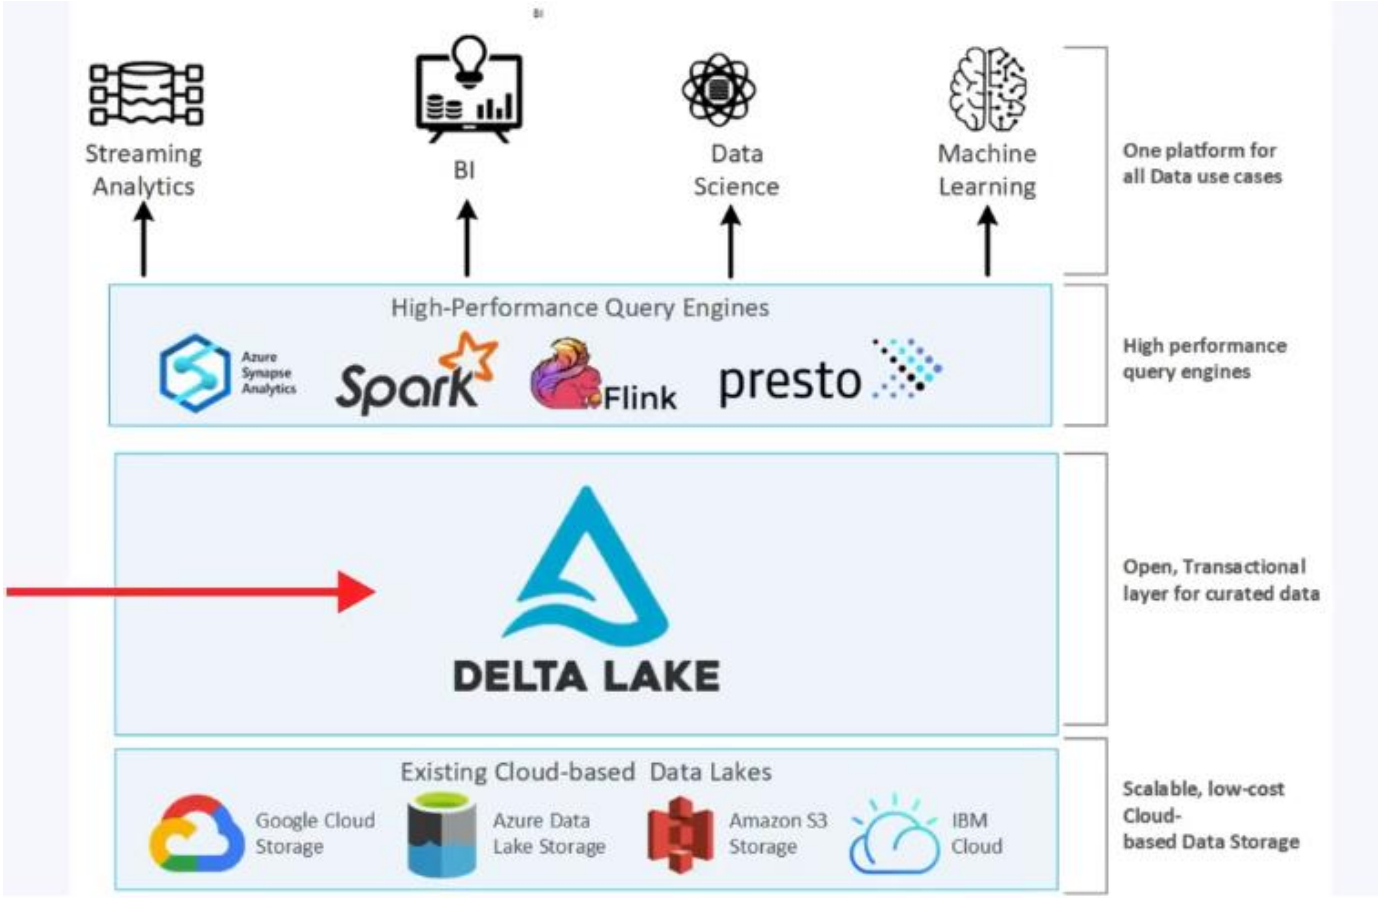
Stockage du lake + fiabilité du warehouse

= une seule plateforme

- Une seule copie des données pour la BI et l'IA
- Formats ouverts : pas d'enfermement chez un fournisseur
- Batch et streaming sur les mêmes tables



L'architecture en couches du lakehouse



4. Usages

BI, streaming, data science, machine learning : une plateforme pour tous les cas d'usage.

3. Moteurs de calcul

Spark, Flink, Presto/Trino, Synapse : ils lisent et écrivent les mêmes tables.

2. Couche transactionnelle

Delta Lake (ou Iceberg, Hudi) : ACID, versions, schéma. C'est le cœur du lakehouse.

1. Stockage objet

S3, ADLS, GCS : fichiers Parquet, bon marché et extensibles.

Ce qu'apportent les formats de table ouverts

Delta Lake, Apache Iceberg et Apache Hudi transforment des fichiers en vraies tables

Transactions ACID

Pas de lecture incohérente pendant une écriture

UPDATE, DELETE, MERGE

Modifier et synchroniser les données comme en SQL

Time travel

Relire la table telle qu'elle était hier

Gestion du schéma

Refuser les mauvais types, ajouter des colonnes

Formats ouverts

Parquet + journal de transactions, lisibles par tous

Batch et streaming

Les mêmes tables pour les deux modes

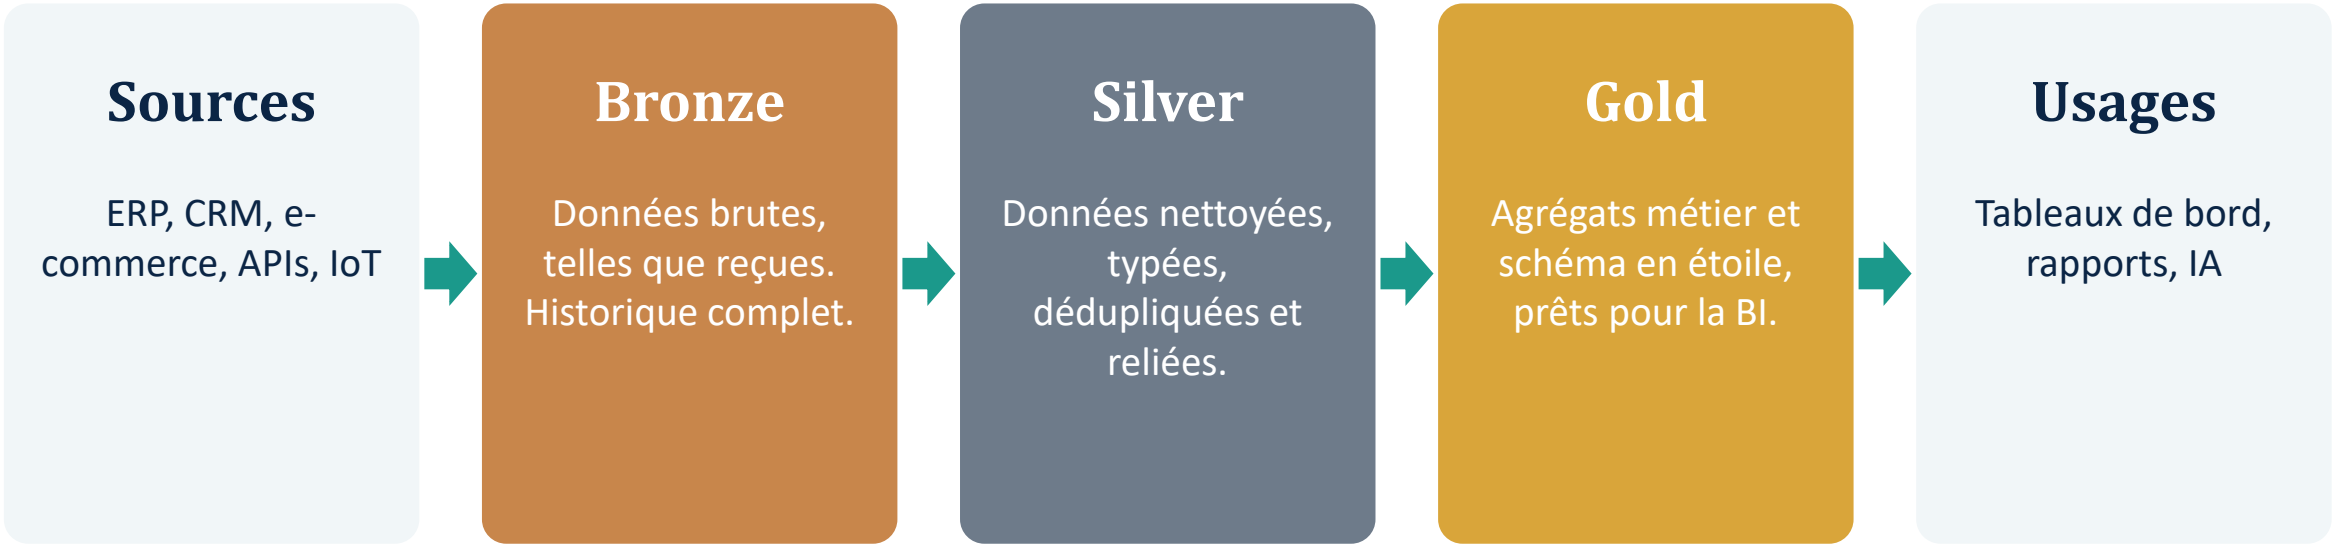
Delta Lake créé par Databricks

Apache Iceberg créé par Netflix

Apache Hudi créé par Uber

L'architecture médaillon

Organiser le lakehouse en trois couches de qualité croissante



Pourquoi garder le bronze ? Si une règle de nettoyage était fausse, on reconstruit silver et gold à partir des données brutes, sans réinterroger les systèmes sources.

Comparatif des trois architectures

Critère	Data warehouse	Data lake	Data lakehouse
Types de données	Structurées	Toutes	**Toutes**
Coût de stockage	Élevé	Faible	**Faible**
Transactions ACID	Oui	Non	**Oui**
Mises à jour et suppressions	Oui	Difficiles	**Oui**
Format	Propriétaire	Ouvert	**Ouvert**
BI en SQL	Excellente	Faible	**Bonne à excellente**
Machine learning	Limité	Bon	**Bon**
Gouvernance	Forte	Faible	**Forte, via un catalogue**
Exemples	Teradata, Redshift	S3, ADLS, HDFS	**Databricks, Fabric, Iceberg**

Quelle architecture choisir ?



Data warehouse

- Données surtout structurées
- Besoin principal : reporting et BI
- Équipe orientée SQL, volume modéré



Data lake

- Gros volumes de données brutes et variées
- Archivage à faible coût
- Exploration et data science



Data lakehouse

- BI et IA sur les mêmes données
- Besoin de formats ouverts
- Nouveau projet de plateforme data

Tendance actuelle : la plupart des nouvelles plateformes adoptent le lakehouse, souvent en commençant petit (DuckDB, Delta Lake) avant de passer à l'échelle.

À retenir

1 Data warehouse

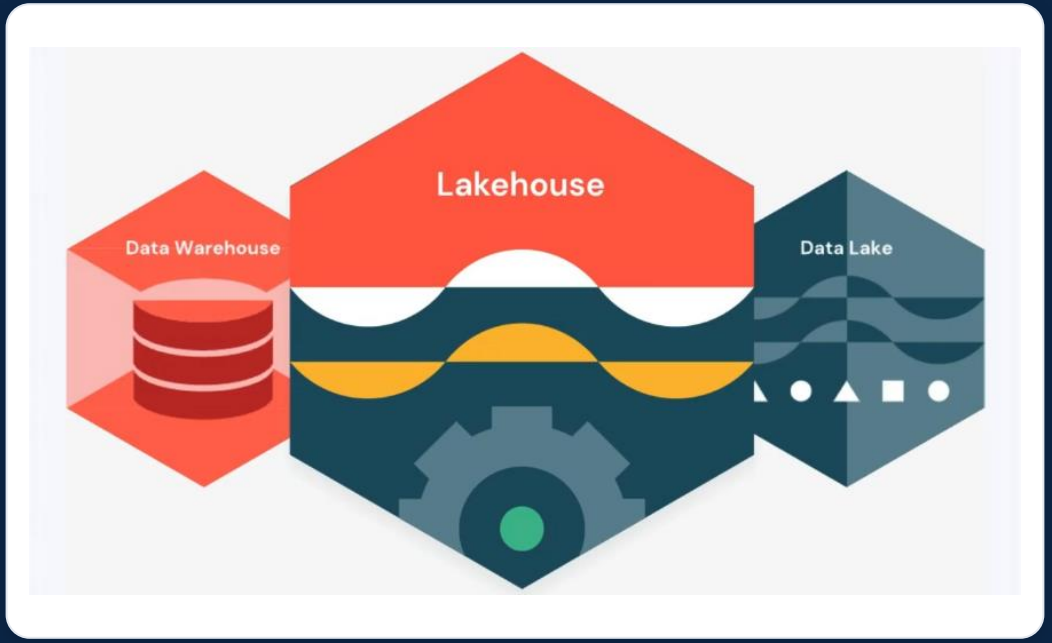
Fiable et performant pour la BI, mais coûteux et limité aux données structurées.

2 Data lake

Stocke tout à faible coût, mais sans transactions ni garantie de qualité.

3 Data lakehouse

Ajoute transactions, schéma et performance au stockage ouvert du lake : une seule plateforme pour la BI et l'IA.



Prochaine étape : les travaux pratiques avec DuckDB et Delta Lake.